## UNIVERSIDADE FEDERAL DO PARANÁ

JULIANO PIEREZAN

METAHEURÍSTICAS DE OTIMIZAÇÃO MULTIOBJETIVO APLICADAS A UM PROBLEMA DE ROBÓTICA HUMANOIDE

CURITIBA 2016

## JULIANO PIEREZAN

# METAHEURÍSTICAS DE OTIMIZAÇÃO MULTIOBJETIVO APLICADAS A UM PROBLEMA DE ROBÓTICA HUMANOIDE

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em Sistemas Eletrônicos, Departamento de Engenharia Elétrica, Setor de Tecnologia, Universidade Federal do Paraná, como requisito parcial para a obtenção do título de Mestre em Engenharia Elétrica.

Orientador: Prof. Dr. Leandro dos Santos

Coelho

Coorientador: Prof. Dr. Lucas Weihmann

CURITIBA 2016

Pierezan, Juliano

Metaheurísticas de otimização multiobjectivo aplicadas a um problema de robótica humanoide / Juliano Pierezan. – Curitiba, 2016. 117 f. : il., tabs.

Dissertação (mestrado) – Universidade Federal do Paraná, Setor de Tecnologia, Programa de Pós-Graduação em Engenharia Elétrica. Orientador: Leandro dos Santos Coelho Coorientador: Lucas Weihmann

1. Robôs. 2. Robótica. 3. Algoritmos. I. Coelho, Leandro dos Santos. II. .Weihmann, Lucas. III. Título.

CDD 629.892

## TERMO DE APROVAÇÃO

## JULIANO PIEREZAN

# METAHEURÍSTICAS DE OTIMIZAÇÃO MULTIOBJETIVO APLICADAS A UM PROBLEMA DE ROBÓTICA HUMANOIDE

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em Sistemas Eletrônicos, Departamento de Engenharia Elétrica, Setor de Tecnologia, Universidade Federal do Paraná, como requisito parcial para a obtenção do título de Mestre em Engenharia Elétrica.

$\circ$	rı	0	n	ta	a	0	r.

Prof. Dr. Leandro dos Santos Coelho

Universidade Federal do Paraná, UFPR

Coorientador:

Prof. Dr. Lucas Weihmann

Universidade Federal de Santa Catarina, UFSC

Prof. Dr. Alessandro Zimmer

Universidade Federal do Paraná, UFPR

Prof. Dr. Gideon Villar Leandro

Universidade Federal do Paraná, UFPR

Prof. Dr. Roberto Zanetti Freire

Pontifícia Universidade Católica do Paraná, PUCPR

### **AGRADECIMENTOS**

Agradeço primeiramente ao professor Leandro dos Santos Coelho pela oportunidade de fazer parte do seu grupo de pesquisa, pelo apoio nos momentos mais difíceis e pela orientação nesses últimos anos de pesquisa. Não menos importante, agradeço imensamente ao professor Lucas Weihmann, que me ajudou a dar os primeiros passos na pesquisa e até hoje me orienta nos momentos em que preciso. E o que falar do professor Roberto Zanetti Freire, responsável por "segurar as pontas" quando eu estava prestes a ficar de fora da pesquisa. Sem dúvida os três são pessoas incríveis e tiveram um papel muito importante na realização dessa pesquisa.

Agradeço também à minha família pelo apoio desde o início dessa jornada que começou na universidade, alguns anos atrás, e que eu espero que continue durante toda a minha vida. Desculpem-me pelos momentos em que não estive junto à família, garanto a vocês que eu fiz o melhor que pude e assim continuarei, me dedicarei e ainda orgulhar-lhes-ei muito.

Agradeço, ainda, a todos os amigos que proporcionaram momentos de alegria, principalmente nesses últimos dois anos, e que me ajudaram muitas vezes a esquecer os problemas que apareceram. Primeiro, aos amigos tangaraenses, incomparáveis! Aos amigos da graduação, parceiros até hoje, nas horas boas e nas ruins. Aos amigos do futebol, que são tantos, mas tantos... enfim, são muitos! Aos amigos da música: fantásticos, sou muito grato por tê-los conhecido! Aos demais amigos de festas, viagens, ferrugem, etc. Um grande abraço a todos vocês e obrigado por compartilharem felicidade comigo.

Agradeço, por fim, aos professores da PUCPR e da UFPR que conheci durante essa trajetória, desde a graduação até o presente momento. Aprendi muito com vocês e sou muito, muito grato pelo conhecimento compartilhado. Um abraço a todos vocês.

#### **RESUMO**

A demanda da sociedade por soluções inteligentes e aptas a substituir o humano em determinadas tarefas, juntamente com o cenário tecnológico atual, impulsionaram o desenvolvimento de sistemas mecatrônicos avançados e programados para suprir essa necessidade. Dentre esses sistemas estão os robôs humanoides, que são máquinas que buscam imitar o comportamento humano em determinados aspectos. Tais robôs podem ser utilizados na sociedade em tarefas que exigem força extrema, para preservar a saúde de trabalhadores, no tratamento psicológico de crianças e até para auxiliar idosos em tarefas do cotidiano. Porém, os robôs humanoides são mecanismos que, em contato o com meio, estão sujeitos a ação gravitacional, podendo sofrer deslizamento e tombamento, assim como os humanos. Portanto, essas máquinas requerem técnicas eficientes para projetá-las e controlá-las, respeitando as respectivas limitações e integrando seu funcionamento em contato com o meio. A presente pesquisa avalia o desempenho das Metaheurísticas de Otimização Multiobjetivo (MOMs) denominadas Algoritmo Genético de Ordenação Não Dominante II (Non-dominated Sorting Genetic Algorithm II – NSGA-II), Evolução Diferencial para Otimização Multiobjetivo (Differential Evolution for Multiobjective Optimization - DEMO), Otimização por Enxame de Partículas Multiobjetivo (Multiobjective Particle Swarm Optimization - MOPSO) e Busca Harmônica Multiobjetivo (Multiobjective Harmony Search - MOHS) aplicadas ao problema de máxima força estática e menor requisição de torque de um robô humanoide programado para executar uma tarefa de força horizontal. A metodologia adotada para cumprir tal objetivo é uma extensão à proposta de Weihmann, na qual são otimizadas as capacidades de força de manipuladores robóticos seriais e paralelos. Diferentemente de tal proposta, na presente pesquisa o problema de otimização é modelado com duas funções de custo e, por se tratar de um humanoide, considera os fatores rugosidade nos contatos com o meio e Zero Moment Point. As métricas de desempenho Número de Soluções não Dominadas (NSND), Distância Euclidiana Média (DEM), Hipervolume (HV) e Espaçamento (E) são aplicadas aos conjuntos de soluções obtidas pelas MOMs e o teste de significância estatística não-paramétrico de Wilcoxon é aplicado aos resultados com o intuito de verificar o desempenho das MOMs. Os resultados obtidos mostram que a DEMO e o NSGA-II apresentam desempenho superior em relação à MOHS e MOPSO, com vantagem sutil por parte da DEMO. Ainda, os operadores que fazem parte das MOMs são discutidos em termos de desempenho das soluções encontradas. As soluções promissoras são expostas graficamente e comparadas em termos de desempenho dos objetivos de otimização. Por fim, os parâmetros que influenciam na força estática e na requisição de torque do robô humanoide são detectados, discutidos e comparados entre as soluções da presente pesquisa e de outros resultados da literatura especializada.

**Palavras-chave**: Robôs humanoides. Metaheurísticas de Otimização Multiobjetivo. Capacidade de força estática. Otimização multiobjetivo com restrições.

#### **ABSTRACT**

The society's demand for intelligent solutions able to replace the human in certain tasks along with the current technological landscape has encouraged the development of advanced mechatronic systems to meet this need. Among the increasing research topics in robotics are the humanoid robots, which are machines designed to simulate the human behavior. Such robots can be employed in the society to perform unhealthy tasks in order to preserve the workers' health, to help and to care of elderly and to treat children with mental illness. However, the humanoid robots are complex mechanisms exposed to the gravitational forces, which can cause the sliding and the tumbling effects, as well as it happens with humans. Hence, advanced techniques are required to design and to control these machines. always complying with those constraints. The current research evaluates performance of the Non-Dominated Sorting Genetic Algorithm (NSGA-II), the Differential Evolution for Multiobjective Optimization (DEMO), the Multiobjective Particle Swarm Optimization (MOPSO) and the Multiobjective Harmony Search (MOHS), which are Multiobjective Optimization Metaheuristics (MOMs), applied to a humanoid robot programmed to perform a task of maximum horizontal static force and lower torque's requirement. The adopted methodology is an extended version of the Weihmann proposal, in which the static force capacity is optimized for serial and parallel manipulators. Differently from Weihmann, the current research treats an optimization problem with two objectives that considers the friction forces and the Zero Moment Point of a humanoid robot. The performance measures Number of Non-Dominated Solutions (NSND), Mean Euclidean Distance (DEM), Hypervolume (HV) and Spacing (E) are employed to evaluate the set of solutions provided by the MOMs and the statistical non-parametric significance test of Wilcoxon is applied to the results obtained in order to verify the MOMs performances. The results show that the DEMO and the NSGA-II show better performance compared to MOHS and MOPSO, wherein DEMO is slightly better than NSGA-II. The MOMs internal mechanisms are discussed, as well as the promising solutions, which are all graphically exposed and compared in terms of optimization objectives performances. Finally, the parameters that most influence in the optimization objectives are detected, discussed and compared between the current results and the literature.

**Key-words:** Humanoid robots. Multiobjective Optimization Metaheuristics. Static force capacity. Constrained multiobjective optimization.

## LISTA DE ILUSTRAÇÕES

Figura 1 – Manipulador RRRR que apresenta redundância cinemática	30
Figura 2 – Cinemática de um manipulador serial com dois GDL	31
Figura 3 – Exemplo de DCL	32
Figura 4 – Exemplo de uma estrutura cinemática e de um grafo	33
Figura 5 – Projeção do CG no solo: ZMP	38
Figura 6 – Conjunto de soluções dominadas e não-dominadas	42
Figura 7 – Ranqueamento das soluções no NSGA-II	45
Figura 8 – Pseudocódigo do NSGA-II.	47
Figura 9 – Pseudocódigo do algoritmo DEMO	49
Figura 10 – Divisão do espaço em hipercubos	52
Figura 11 – Pseudocódigo do algoritmo MOPSO	53
Figura 12 – Pseudocódigo do algoritmo MOHS	55
Figura 13 – Distância Euclidiana entre as soluções e a origem	57
Figura 14 – Utilização da métrica hipervolume	58
Figura 15 – Espaçamento: duas situações	59
Figura 16 – Representação da metodologia adotada	60
Figura 17 – Modelo adotado	63
Figura 18 – Diferentes posições para o robô	64
Figura 19 – Configuração da cinemática	64
Figura 20 – Influência do contato com o meio	65
Figura 21 – Equilíbrio estático utilizando o método de Davies	66
Figura 22 – Processo experimental de otimização com múltiplas metaheurísticas	73
Figura 23 – Fronteira de Pareto da metaheurística DEMO	78
Figura 24 – Posicionamento resultante da solução de melhor compromisso da	
metaheurística DEMO	78
Figura 25 – Fronteira de Pareto da metaheurística MOHS	80
Figura 26 – Posicionamento resultante da solução de melhor compromisso da	
metaheurística MOHS	80
Figura 27 – Fronteira de Pareto da metaheurística MOPSO	81
Figura 28 – Configuração resultante da solução de melhor compromisso da	
metaheurística MOPSO	82

Figura 29 – Fronteira de Pareto da metaheurística NSGA-II	.83
Figura 30 – Configuração resultante da solução de melhor compromisso da	
metaheurística NSGA-II	.84
Figura 31 – Conjunto das fronteiras de Pareto encontradas pelas metaheurísticas.	86
Figura 32 – Exemplo de fronteira de Pareto com todas as soluções penalizadas	.87
Figura 33 – Gráfico de caixa das métricas empregadas.	.89
Figura 34 – Fronteira de Pareto filtrada de todas as metaheurísticas	.93
Figura 35 – Fronteira de Pareto filtrada e soluções destacadas	.95
Figura 36 – Cinemática da solução de menor requisição de torque	.96
Figura 37 – Cinemática da solução de melhor compromisso da pesquisa	.96
Figura 38 – Cinemática da solução de maior força estática da pesquisa	.97
Figura 39 – Melhor posicionamento encontrado na literatura	.97

## **LISTA DE TABELAS**

Tabela 1 – Características do robô humanoide	63
Tabela 2 – Espaço de busca das variáveis de decisão	69
Tabela 3 – Torques calculados para as juntas internas da solução de melhor	
compromisso: DEMO	79
Tabela 4 – Torques calculados para as juntas internas da solução de melhor	
compromisso: MOHS	81
Tabela 5 – Torques calculados para as juntas internas da solução de melhor	
compromisso: MOPSO	82
Tabela 6 – Torques calculados para as juntas internas da solução de melhor	
compromisso: NSGA-II	84
Tabela 7 – Estatística descritiva dos resultados obtidos pelas metaheurísticas	90
Tabela 8 – Significâncias dos testes de Wilcoxon entre as metaheuristicas	91
Tabela 9 – Ranqueamento final das metaheurísticas conforme as métricas de	
desempenho	92
Tabela 10 – Comparativo entre as variáveis das soluções promissoras	98

## LISTA DE ABREVIATURAS E SIGLAS

CG Centro de Gravidade CM Centro de Massa

DCL Diagrama do Corpo Livre

DE Evolução Diferencial (*Differential Evolution*)

DEM Distância Euclidiana Média

DEMO Evolução Diferencial para Otimização Multiobjetivo (Differential

Evolution for Multiobjective Optimization)

E Espaçamento

FP Fronteira de Pareto

GA Algoritmo Genético (Genetic Algorithm)

HV Hipervolume

IA Inteligência Artificial

MOHS Busca Harmônica Multiobjetivo (*Multiobjective Harmony Search*)

MOM Metaheurísticas de Otimização Multiobjetivo

MOPSO Otimização por Enxame de Partículas Multiobjetivo (Multiobjective

Particle Swarm Optimization)

NSGA-II Algoritmo Genético de Ordenação Não Dominante II (Non-dominated

Sorting Genetic Algorithm II)

NSND Número de Soluções Não Dominadas PLM Mutação Polinomial (*Polinomial Mutation*)

SBX Cruzamento Binário Simulado (Simulated Binary Crossover)

ZMP Zero Moment Point

## LISTA DE SÍMBOLOS

$\$^p_{\lambda,\mathcal{C}_n}$	Matriz de heliforças das variáveis primárias
$\$_{Fx}$	Heliforça da componente $F_r$
$\$_{FZ}$	Heliforça da componente $F_z$
$\$_{Ty}$	Heliforça da componente $T_{\gamma}$
$\$_{\lambda,\lambda k}^{s}$	Matriz de heliforças das variáveis secundárias
$F_{x_A}$	Força horizontal calculada para o punho 1
$F_{x_D}$	Força horizontal calculada para o punho 2
$F_{z_I}$	Força vertical calculada para o tornozelo 1
$F_{z_L}$	Força vertical calculada para o tornozelo 2
$\mu_s$	Coeficiente de atrito estático
$A_{\lambda k,C_b}$	Matriz de ações de equilíbrio
$C_b$	Grau bruto de restrições de uma cadeia cinemática
$C_i$	i-ésimo corte de equilíbrio
$C_n$	Grau líquido de restrições de um mecanismo
$N_p$	Tamanho da população da NSGA-II
$N_s$	Tamanho do enxame da MOPSO
$P_{C_{n},1}$	Matriz com as componentes primárias do equilíbrio estático
$P_{c}$	Probabilidade de cruzamento da NSGA-II
$P_m$	Probabilidade de mutação da NSGA-II
$S_{\lambda k,1}$	Matriz com as componentes secundárias do equilíbrio estático
$f_1$	Custo do primeiro objetivo de otimização
$f_2$	Custo do segundo objetivo de otimização
$f_m$	<i>m</i> -ésimo custo da função objetivo
$n_h$	Número de hipercubos da MOPSO
$v^{max}$	Porcentagem de velocidade máxima da MOPSO
$x_5$	Centro do tronco em x
$x_I$	Contato x do tornozelo 1
$x_L$	Contato x do tornozelo 2
$Z_5$	Centro do tronco em z
$Z_A$	Contato z do punho 1
$Z_D$	Contato z do punho 2
$\eta_m$	Parâmetro de ajuste da distribuição de probabilidade da PLM
$\mu_A$	Coeficiente de atrito calculado para o punho 1
$\mu_D$	Coeficiente de atrito calculado para o punho 2
$\mu_I$	Coeficiente de atrito calculado para o tornozelo 1
$\mu_L$	Coeficiente de atrito calculado para o tornozelo 2
$ au_B$	Torque do cotovelo 1 Torque do ombro 1
$ au_C$	Torque do cotovelo 2
$ au_E$	TOTARE AD COLOVEIO Z

$ au_F$	Torque do ombro 2
$ au_G$	Torque do quadril 1
$ au_H$	Torque do joelho 1
$ au_{J}$	Torque do quadril 2
$ au_K$	Torque do joelho 2
$ au_k$	Torque do joelho 2
$ au_{max}$	Torque máximo suportado por uma junta rotativa
$arphi_1$	Parâmetro de ajuste da constante cognitiva da MOPSO
$arphi_2$	Parâmetro de ajuste da constante social da MOPSO
CR	Probabilidade de recombinação da DEMO
F	Fator de escala da mutação da DEMO
FW	Porcentagem de largura de banda da MOHS
HMCR	Taxa de consideração de memória de harmonias da MOHS
HMS	Número de harmonias da MOHS
N	Tamanho da população da DEMO
PAR	Probabilidade de ajuste de tons da MOHS
fs	Fator de escala na capacidade de força estática
g	Aceleração gravitacional
k	Número de cortes de equilíbrio necessários para definir a estática
γ	Conjunto das juntas internas ao robô
$\eta$	Parâmetro de ajuste da distribuição de probabilidade do SBX
heta	Inclinação do tronco
λ	Dimensão do espaço da tarefa
ho	Conjunto das juntas de contato com o meio
$\sigma$	Conjunto de todas as juntas do humanoide
τ	Torque calculado para uma junta rotativa
arphi	Conjunto das juntas de contato superior

# SUMÁRIO

1	INTRODUÇÃO	23		
1.1	PROBLEMATIZAÇÃO	24		
1.2	JUSTIFICATIVA E MOTIVAÇÃO	25		
1.3	OBJETIVOS	25		
1.4	ORGANIZAÇÃO DA DISSERTAÇÃO	26		
2	ROBÓTICA HUMANOIDE	28		
2.1	CINEMÁTICA DE MANIPULADORES			
2.1.1	Mobilidade			
2.1.2	Redundância Cinemática	29		
2.1.3	Cinemática Direta	30		
2.1.4	Cinemática Inversa	31		
2.2	ESTÁTICA DE MANIPULADORES	32		
2.2.1	Diagrama do Corpo Livre (DCL)	32		
2.2.2	Método de Davies	33		
2.3	CAPACIDADE DE FORÇA ESTÁTICA DE MANIPULADORES	35		
2.3.1	Técnicas Diretas	35		
2.3.2	Método de Weihmann	36		
2.4	CENTRO DE MASSA E CENTRO DE GRAVIDADE	37		
2.5	ZERO MOMENT POINT (ZMP)	38		
2.6	FORÇA DE ATRITO ESTÁTICO	39		
3	OTIMIZAÇÃO MULTIOBJETIVO	40		
3.1	FUNDAMENTOS DA OTIMIZAÇÃO MULTIOBJETIVO	40		
3.1.1	Conceito de dominância	41		
3.1.2	Otimalidade de Pareto	42		
3.2	METAHEURÍSTICAS DE OTIMIZAÇÃO MULTIOBJETIVO	43		
3.2.1	NSGA-II	43		
3.2.2	DEMO	47		
3.2.3	MOPSO	49		
3.2.4	MOHS	53		
3.3	MÉTRICAS DE DESEMPENHO	55		
3.3.1	Número de Soluções Não Dominadas (NSND)	56		
3.3.2	Distância Euclidiana Média (DEM)	56		

3.3.3	Hipervolume (HV)	57
3.3.4	Espaçamento (E)	58
4	OTIMIZAÇÃO MULTIOBJETIVO DE ROBÔS HUMANOIDES	60
4.1	ROBÔ HUMANOIDE	62
4.1.1	Características	62
4.1.2	Cinemática	63
4.1.3	Contato com o meio	65
4.1.4	Estática	66
4.2	MODELAGEM DO PROBLEMA DE OTIMIZAÇÃO	68
4.2.1	Objetivos	68
4.2.2	Parâmetros	68
4.2.3	Restrições	69
4.3	DELINEAMENTO EXPERIMENTAL	72
4.3.1	Metaheurísticas e seus parâmetros	72
4.3.2	Parâmetros experimentais	72
4.4	PROCESSO DE OTIMIZAÇÃO	73
4.5	ETAPAS DE ANÁLISE DE RESULTADOS	74
4.5.1	Critérios de desempenho	74
4.5.2	Ferramentas estatísticas	75
4.5.3	Representação gráfica	76
5	RESULTADOS	77
5.1	RESULTADOS OBTIDOS INDIVIDUALMENTE	77
5.1.1	DEMO	77
5.1.2	MOHS	79
5.1.3	MOPSO	81
5.1.4	NSGA-II	83
5.2	COMPARAÇÃO DE DESEMPENHO ENTRE AS METAHEURÍSTICAS	85
5.2.1	Fronteiras de Pareto	85
5.2.2	Métricas de desempenho	87
5.2.3	Fronteira única	92
5.3	COMPARATIVO ENTRE AS SOLUÇÕES PROMISSORAS	94
5.3.1	Soluções promissoras	94
5.3.2	Comparação entre as soluções	
6	CONSIDERAÇÕES FINAIS	.101

REFERÊNCIAS BIBLIOGRÁFICAS108			
	PERSPECTIVAS FUTURAS		
6.5	PUBLICAÇÕES RELACIONADAS	105	
6.4	CONTRIBUIÇÕES DA DISSERTAÇÃO	104	
6.3	CONCLUSÕES SOBRE AS METAHEURÍSTICAS	103	
6.2	CONCLUSÕES SOBRE O PROBLEMA DE OTIMIZAÇÃO	103	
6.1	DISCUSSÃO	101	

## 1 INTRODUÇÃO

As pretensões da sociedade por sistemas mecatrônicos inovadores, altamente sofisticados e inteligentes tiveram início no século passado, período em que as ambições tecnológicas e os investimentos econômicos na indústria superavam os recursos eletrônicos disponíveis para o alcance de tais objetivos. O cenário atual, entretanto, apresenta avanço tecnológico sólido e distribuído entre todas as áreas envolvidas na criação de sistemas mecatrônicos. Uma das consequências disso é a concepção de robôs inteligentes, os quais, segundo Dirican (2015), são importantes no desenvolvimento da sociedade do ponto de vista econômico e de operações.

Além disso, os robôs inteligentes podem ser explorados para proporcionar benefícios à sociedade em outros diversos aspectos. Primeiramente, trabalhadores que sofrem por esforços excessivos na indústria podem ser substituídos por máquinas robóticas, com o intuito de reduzir o número de casos de doenças físicas relacionadas ao trabalho, tais como distúrbios osteomusculares relacionados ao trabalho (DORTs) e lesões por esforços repetitivos (LERs), as quais tem causado preocupação aos profissionais da área da saúde ocupacional nas últimas décadas (DA COSTA E VIEIRA, 2010; ORMELEZ E ULBRICHT, 2010; NEGRI *et al.*, 2014; OAKMAN E CHAN, 2015; SOKAS E PRINCE, 2008). Além disso, pessoas com deficiência física ou mental, distúrbios de déficit de atenção e ainda idosos, por exemplo, podem receber auxílio de robôs que sejam projetados especificamente para as suas respectivas necessidades, sejam essas relacionadas à força física ou até mesmo à interação social (ISMAIL *et al.*, 2012; MICHEL, 2012; RABBITT, KAZDIN E SCASSELLATI, 2015). Esses são apenas exemplos das diversas aplicações em que robôs podem ser beneficamente empregados na sociedade.

Uma solução com potencial para suprir essa demanda de maneira genérica e eficiente são os robôs humanoides, cujo desenvolvimento teve início há séculos com o projeto mecânico de Leonardo da Vinci (MORAN, 2006) e, nas últimas décadas, é um tema que está em destaque na literatura (KNASEL, 1986; WANG E LI, 2008; PIEREZAN, FREIRE E WEIHMANN, 2012). Tratando-se de máquinas cujo objetivo é o funcionamento em contato com seres humanos, a modelagem dos aspectos físicos relacionados à tarefa de interesse torna-se complexa; a tarefa pode

alternar entre seguir uma trajetória, reconhecer padrões e realizar força extrema, por exemplo. Para cada uma dessas tarefas existem possíveis projetos de humanoides e, consequentemente, determinada requisição de torque, tema esse apontado como um dos mais preocupantes na área de robótica móvel na última década (LIU E SUN, 2011; HAO *et al.*, 2013; ROY E PRATIHAR, 2013; LIU E SUN, 2014; PELLEGRINELLI, *et al.*, 2015). Portanto, o projeto de um humanoide requer técnicas suficientemente avançadas e aptas a tratar todos esses fatores, simultaneamente.

A metodologia em evidência na literatura para solucionar problemas como esse é a utilização de metaheurísticas de otimização (WEIHMANN, 2011), que são algoritmos computacionais que pertencem à área da Inteligência Artificial (IA) ou mesmo da área denominada Computação Natural. Segundo Manjarres (2013), muitas metaheurísticas advém de inspirações da natureza, tais como inteligência coletiva observada em enxames de animais e algoritmos baseados na evolução de uma população. A integração entre essas metaheurísticas e projetos robóticos aparece como um tema motivador e que tem apresentado ótimos resultados em diversas aplicações (FONG, DEB E CHAUDHARY, 2015), principalmente por permitir a implementação do problema de otimização complexo em códigos computacionais. Para aplicações envolvendo múltiplos objetivos de otimização, entretanto, são recomendadas as Metaheurísticas de Otimização Multiobjetivo (MOM) (BOUSSAÏD, LEPAGNOT E SIARRY, 2013; MAHDAVI, SHIRI E RAHNAMAYAN, 2015), pois essas apresentam flexibilidade de projeto, do ponto de vista dos objetivos desejados, e também porque oferecem um conjunto de soluções que apresentam compromisso entre esses objetivos. Embora esse seja um tema com mais de uma década de existência na literatura, há ainda muito a ser explorado visando a criação de novos algoritmos e a melhoria dos existentes (YANG, KOZIEL E LEIFSSON, 2014).

## 1.1 PROBLEMATIZAÇÃO

Do ponto de vista da estática, um robô humanoide é uma estrutura mecânica formada por juntas rotativas e por corpos rígidos denominados elos. Os membros do robô (pernas e braços) são associações entre elos e juntas, e podem ser entendidos como manipuladores seriais, tendo o tronco como base. Ao receber forças e

momentos externos, os elos transmitem estas forças e momentos às juntas, que, por sua vez, devem possuir capacidade de torques individuais conforme as suas características físicas de forma a manter o equilíbrio estático. Ao fechar o contato com o meio, o robô humanoide passa a ser um robô paralelo, apresentando em geral redundância cinemática de posição. Esta característica torna a busca por uma solução ideal para o problema de configuração do robô bastante complexa. (WEIHMANN, 2011).

Além de redundância cinemática, o humanoide é submetido à força gravitacional, sendo assim possível ocorrerem dois fatores: o deslizamento, devido à insuficiência de rugosidade nos contatos com o meio, e o tombamento, devido à má projeção do centro de gravidade do robô no solo (PIEREZAN, FREIRE E WEIHMANN, 2012).

## 1.2 JUSTIFICATIVA E MOTIVAÇÃO

As pesquisas relacionadas a robôs humanoides estão cada vez mais em destaque na literatura, principalmente tratando-se do desenvolvimento de funções cognitivas e de locomoção. Entretanto, apenas Pierezan, Freire e Weihmann (2012) aborda a otimização da capacidade de força de um humanoide, sendo modelado um problema de único objetivo. Porém, tratando-se de um problema multiobjetivo, no qual a segunda meta é a solução de menor requisição de torque, é necessária a utilização de técnicas aptas a tratar as soluções de dimensão não unitária.

Além disso, o tema de robótica humanoide é um dos mais desafiadores na literatura e uma das expectativas é que a sua integração com as metaheurísticas resulte, futuramente, em máquinas aptas a substituir o ser humano em tarefas insalubres e que exigem esforços excessivos, a auxiliar pessoas idosas, deficientes físicos e mentais e, ainda, a fazer parte da sociedade em diversas outras aplicações.

## 1.3 OBJETIVOS

O principal objetivo desta pesquisa é avaliar metaheuristicas de otimização multiobjetivo para solucionar problemas complexos modelados a partir de um robô humanoide em contato com o meio.

Os objetivos específicos são:

- a) Selecionar na literatura metaheurísticas de otimização multiobjetivo que tenham seu funcionamento comprovado e possuam características distintas em termos de estratégias de otimização;
- b) Modelar o problema de otimização multiobjetivo de máxima força estática e menor requisição de torque de um robô humanoide em termos de parâmetros, restrições e funções de custo;
- c) Aplicar as metaheurísticas ao problema de otimização modelado através de uma série de experimentos controlados e armazenar os resultados obtidos para análise;
- d) Selecionar um conjunto de critérios de desempenho das metaheuristicas de otimização multiobjetivo presentes na literatura e aplicá-los aos resultados obtidos;
- e) Comparar o desempenho das metaheuristicas e apontar a técnica mais adequada para o problema de otimização multiobjetivo de robótica humanoide:
- f) Apresentar as soluções de melhor desempenho visando os objetivos individualmente e sugerir, ainda, uma solução que apresente o melhor compromisso entre todos os objetivos e;
- g) Comparar as soluções mais promissoras com resultados apresentados na literatura.

## 1.4 ORGANIZAÇÃO DA DISSERTAÇÃO

O presente documento é organizado da seguinte maneira. O capítulo 1 apresenta uma introdução ao tema da presente pesquisa e os respectivos objetivos, a problematização, a justificativa, a motivação e a caracterização da mesma. O mesmo capítulo, na presente subseção, demonstra a organização do presente documento.

Os capítulos 2 e 3 contêm a revisão bibliográfica. Primeiramente há os conceitos relacionados à cinemática e à estática humanoide, incluindo os fatores de contato com o meio, e ainda uma contextualização histórica de alguns robôs conhecidos na literatura. Em seguida estão os fundamentos da otimização

multiobjetivo, os critérios de avaliação dos algoritmos e algumas das técnicas mais difundidas.

O capítulo 4 apresenta os materiais e os métodos adotados para a integração entre os dois temas principais deste documento; o modelo de robô humanoide utilizado e suas características, a modelagem do problema de otimização multiobjetivo, o delineamento experimental e os procedimentos de execução de testes e avaliação dos resultados.

No capítulo 5 encontram-se os resultados das simulações computacionais, os quais estão separados em: resultados individuais de cada metaheurística, comparativo entre as metaheurísticas e, por fim, comparação de resultados com a literatura. Finalizando, o capítulo 6 apresenta a interpretação de todo o documento com as considerações finais: uma discussão relacionada à pesquisa, uma conclusão acerca da metodologia adotada e dos resultados obtidos, as contribuições do documento para a área de pesquisa em questão, as publicações relacionadas a esta pesquisa e, por fim, as perspectivas futuras relacionadas aos temas explorados e à integração dos mesmos.

## **2 ROBÓTICA HUMANOIDE**

Há séculos o ser humano tenta desenvolver máquinas capazes de reproduzir seus próprios movimentos. Segundo Moran (2006), o desenvolvimento de humanoides teve início há pouco mais de cinco séculos com o projeto mecânico de Leonardo da Vinci. Desde tal época, o objetivo dessas máquinas é a imitação da estrutura corporal humana, sendo uma das evoluções do tema a réplica de alguns dos movimentos do ser humano (VUKOBRATOVIĆ *et al.*, 1977; KNASEL, 1986).

Estudos mais concretos tiveram início há aproximadamente quatro décadas com o desenvolvimento do WABOT-1, o primeiro robô antropomórfico construído à escala real no mundo, que na década seguinte evoluiu para o WABOT-2, sendo capaz até de reproduzir sons e tocar instrumentos musicais (KATO et al., 1987). Na mesma época, a empresa japonesa HONDA iniciou o desenvolvimento de seu próprio robô, chamado ASIMO, que atualmente é conhecido pela capacidade em executar tarefas similares aos humanos (SAKAGAMI et al., 2002; OKITA, NGTHOW-HING E SARVADEVABHATLA, 2009). Nos anos seguintes, as pesquisas nessa área intensificaram-se e muitos outros robôs surgiram (BRUEMMER E SWINSON, 2003). Como exemplo pode-se citar o robô Johnnie (LOHMEIER et al., 2004), o WABIAN-RIV (CARBONE et al., 2006), o HRP-2W (INAMURA et al., 2009), o HanSaRam (YOO, LEE E KIM, 2009), o NAO (SHAMSUDDIN et al., 2011; ISMAIL et al., 2012) e o Bonten-Maru (YUSSOF, 2012).

Atualmente, a definição de robôs humanoides pode ser expandida para "sistemas mecatrônicos complexos que buscam imitar a estrutura corporal humana e replicar seu comportamento de maneira robusta, confiável e flexível a ponto de trabalhar de maneira autônoma ou cooperativa com o ser humano em ambientes dinâmicos" (GOUAILLIER E BLAZEVIC, 2006; WANG E LI, 2008; PIEREZAN, FREIRE E WEIHMANN, 2012; JIE et al., 2015; PFEIFFER E CECILIO, 2015). Evidentemente, esse é um tema que está em destaque na literatura e apresenta muitos desafios para as próximas décadas de pesquisa (STANTON E WILLIAMS, 2008; GOERTZEL, HANSON E YU, 2014; BAUER et al., 2015).

A seguir são apresentados os conceitos da análise cinemática e estática de manipuladores robóticos, as técnicas presentes na literatura para a definição da

capacidade de força estática de manipuladores e também os conceitos aplicados especificamente aos robôs humanoides.

## 2.1 CINEMÁTICA DE MANIPULADORES

A definição da geometria de um manipulador depende das características da tarefa a ser executada. Fatores como o conhecimento ou não do ponto de contato do efetuador e a existência de mecanismos em paralelo influenciam na escolha da estratégia adotada para definição da cinemática. Esses fatores e as estratégias possíveis são apresentados a seguir.

## 2.1.1 Mobilidade

Segundo Weihmann (2011), a mobilidade de uma cadeia cinemática é definida como o número de parâmetros necessários para determinar por completa a configuração da mesma. A mobilidade, ou Graus de Liberdade (GDL), depende da dimensão  $\lambda$  do espaço considerado, a qual é igual a três no plano e igual a seis no espaço tridimensional. O cálculo da mobilidade pode ser representado pela seguinte equação:

$$M = \lambda(n - j - 1) + \sum_{i=1}^{j} f_i, \tag{2.1}$$

onde n é o número de elos do sistema, j é o número de juntas do sistema e  $f_i$  é o grau de liberdade de cada uma das juntas.

Existem diferentes tipos de juntas que podem ser empregadas em cadeias cinemáticas, sendo que as mais comuns no plano são a rotativa e a prismática, enquanto que no espaço são a cilíndrica, a esférica, a plana e a universal. Essas juntas possuem diferentes graus de liberdade e, se a mobilidade calculada for igual a zero, a cadeia é tratada como uma estrutura; se for maior que zero, então a cadeia é considerada um mecanismo.

### 2.1.2 Redundância Cinemática

O termo redundância geralmente é relacionado diretamente à cinemática, na qual um manipulador serial apresenta infinitas possibilidades de posicionamento no

plano ou no espaço (BELFIORE E DI BENEDETTO, 2000) para uma mesma posição e orientação do efetuador final. Um exemplo disso é um manipulador serial plano com quatro juntas rotativas, conforme mostrado na Figura 1. Neste caso, mantendo o efetuador na mesma posição existem infinitas configurações para as posições das juntas A, B, C e D.

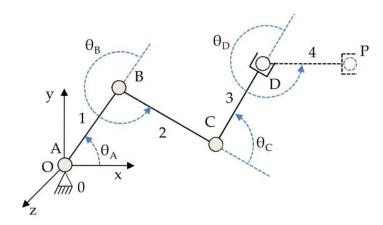


Figura 1 – Manipulador RRRR que apresenta redundância cinemática. Fonte: Weihmann (2011).

Segundo Martins e Carboni (2008), a redundância é uma das análises mais importantes de uma cadeia cinemática, pois a escolha do modo de trabalho influencia diretamente em outros fatores, tais como o cálculo dos esforços. As estratégias para o cálculo da cinemática são discutidas nas próximas subseções.

### 2.1.3 Cinemática Direta

Nesse caso, o posicionamento dos elos e das juntas acontece de forma direta, que é quando se conhece o posicionamento das juntas e pretende-se encontrar a posição final da extremidade do robô. A convenção mais difundida é a de Denavit Hartenberg, a qual utiliza representação matricial e um formato sistemático de localização de coordenadas (ROCHA, TONETTO E DIAS, 2011).

Há também a teoria dos helicoides, a qual é capaz de representar os estados de corpos rígidos no espaço. Essa teoria pode ser empregada tanto na análise cinemática (heligiros) e quanto estática (heliforças) de mecanismos (WEIHMANN, 2011).

## 2.1.4 Cinemática Inversa

A cinemática inversa é um termo adotado quando a posição final do manipulador é conhecida e precisa-se encontrar a posição das juntas intermediárias para definir o seu posicionamento. As relações trigonométricas que descrevam o posicionamento das juntas intermediárias de um mecanismo podem ser adotadas para o cálculo da cinemática inversa (PIEREZAN, FREIRE E WEIHMANN, 2012).

Para manipuladores cinematicamente redundantes, a cinemática inversa apresenta infinitas soluções. Manipuladores sem redundância cinemática podem apresentar mais de uma solução. Como exemplo, um manipulador serial plano com uma junta intermediária pode apresentar duas possíveis configurações ou modos de trabalho, conforme mostrado na Figura 2. Logo, o cálculo da cinemática inversa depende da predefinição da configuração.

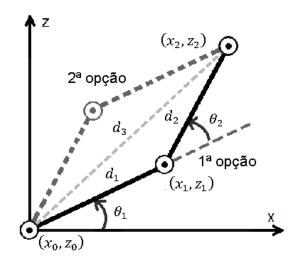


Figura 2 – Cinemática de um manipulador serial com dois GDL. Fonte: Adaptado de Pierezan, Freire e Weihmann (2012).

Nota-se na Figura 2 que o posicionamento final do manipulador  $(x_2,z_2)$  é o mesmo para as duas possíveis configurações. As distâncias  $d_1$  e  $d_2$  representam os comprimentos dos elos e são constantes, bem como a origem do manipulador  $(x_0,z_0)$ . Portanto, a posição da junta intermediária é que precisa ser definida e depende da configuração adotada. Essa posição é calculada através da lei dos cossenos.

## 2.2 ESTÁTICA DE MANIPULADORES

A estática consiste em calcular os esforços resultantes nas juntas de um mecanismo, sem necessariamente se preocupar com os esforços internos aos elos (WEIHMANN, 2011). Existem diversas técnicas para analisar estaticamente um mecanismo. Esses conceitos são descritos nas subseções a seguir.

## 2.2.1 Diagrama do Corpo Livre (DCL)

Para que um sistema esteja em equilíbrio estático, segundo a primeira Lei de Newton, o somatório de forças e de momentos atuando sobre cada um dos corpos que compõe o sistema deve ser nulo. O Diagrama de Corpo Livre (DCL) é a análise individual de cada um dos corpos rígidos levando em consideração todas as forças e momentos que atuam sobre o mesmo (HIBBELER, 2011).

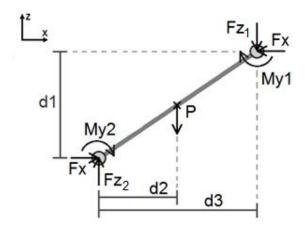


Figura 3 – Exemplo de DCL. Fonte: O Autor (2016).

A Figura 3 contém um exemplo de diagrama para um corpo isolado, onde  $d_1$ ,  $d_2$  e  $d_3$  são as distâncias das ações até o eixo referencial, Fx, e  $Fz_1$  são as forças transmitidas pelo corpo, My1 e My2 são os momentos nas extremidades do corpo, P é a força peso do corpo  $Fz_2$  é a soma da força  $Fz_1$  com a força peso do corpo. Para que a condição de equilíbrio seja atingida, no plano xz, as seguintes condições devem ser satisfeitas:

$$\sum Fx = 0, \tag{2.2}$$

$$\sum Fz = 0 \text{ e} \tag{2.3}$$

$$\sum M y = 0. \tag{2.4}$$

### 2.2.2 Método de Davies

Através do método de Davies (DAVIES, 1983) as equações de equilíbrio são escritas na forma matricial onde todos os momentos são referenciados no mesmo ponto. As variáveis primárias são as forças e momentos conhecidos e as variáveis secundárias são as forças e momentos que se deseja calcular de forma que o equilíbrio estático do sistema seja alcançado.

A cadeia cinemática do robô pode ser representada por um grafo, do qual são obtidas as equações de equilíbrio aplicando-se a lei dos cortes, que estabelece que a soma algébrica das forças e momentos que pertencem ao mesmo corte é igual a zero (TSAI, 1999). Cada corte segmenta o mecanismo em subconjuntos onde, para cada um deles, o equilíbrio estático deve ser preservado. A Figura 4 ilustra um exemplo da estrutura cinemática (Figura 4a) transcrita para um grafo (Figura 4b), onde as letras representam as juntas e os números os elos do mecanismo.

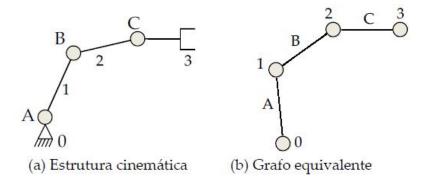


Figura 4 – Exemplo de uma estrutura cinemática e de um grafo. Fonte: Weihmann (2011).

O cálculo da estática depende, então, dos seguintes conceitos:

a) Dimensão do espaço ( $\lambda$ ): número de variáveis necessárias para definir o posicionamento de um objeto no plano ou espaço; se o manipulador estiver no plano,  $\lambda$  é igual a três; no espaço,  $\lambda$  é igual a seis.

- b) Grau bruto de restrições: em uma definição simplificada, é o número total de forças-momento do sistema e pode ser extraído visualmente do grafo.
- c) O grau líquido de restrições, que representa o número de variáveis necessárias para determinar o equilíbrio estático, pode ser calculado pela seguinte equação:

$$C_n = C_h - \lambda k, \tag{2.5}$$

onde  $C_b$  é o grau bruto e k é o número de cortes necessários para o cálculo do equilíbrio (número de arestas menos o número de circuitos independentes).

Para o cálculo do equilíbrio, então, é aplicada a teoria dos helicoides (aqui denominados heliforças), os quais compõem as equações dos cortes de equilíbrio. Cada corte possui  $\lambda$  equações independentes e  $\mathcal{C}_b$  ações (algumas não participam da equação) e o somatório dessas ações deve ser nulo. O *i*-ésimo corte é escrito na forma matricial, tal que:

$$C_i = \{\$_{\lambda,\lambda k}^s\} \{S_{\lambda k,1}\} + \{\$_{\lambda,C_n}^p\} \{P_{C_n,1}\} = 0, \ i = \{1, \dots, k\},$$
 (2.6)

onde  $\{P_{C_n,1}\}$  e  $\{S_{\lambda k,1}\}$  são as matrizes com as componentes primárias e secundárias, respectivamente, e  $\{\$_{\lambda,C_n}^p\}$  e  $\{\$_{\lambda,\lambda k}^s\}$ são as matrizes formadas pelos heliforças dessas componentes. Se a heliforça não faz parte do corte, os elementos correspondentes da matriz assumem valor nulo (WEIHMANN, 2011).

O conjunto de todos os cortes resulta em uma matriz das ações de equilíbrio, a qual possui  $\lambda k$  equações independentes e  $C_b$  ações. Essa matriz é montada da seguinte maneira:

$$A_{\lambda k, C_b} = \begin{cases} C_i \\ \vdots \\ C_k \end{cases} = 0, \ i = \{1, ..., k\}.$$
 (2.7)

Considerando o plano xz, portanto  $\lambda$  igual a 3, a contribuição de cada uma das juntas de uma cadeia para o equilíbrio estático pode ser representada pela matriz a seguir:

$$\{\$_{Fx} \quad \$_{Fz} \quad \$_{Ty}\} \cdot \begin{Bmatrix} Fx \\ Fz \\ Ty \end{Bmatrix} \equiv \begin{Bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ p_z & -p_x & 1 \end{Bmatrix} \cdot \begin{Bmatrix} Fx \\ Fz \\ Ty \end{Bmatrix}$$
 (2.8)

onde  $p_x e p_z$  são as coordenadas horizontal e vertical, respectivamente, dessa junta,  $F_x$  e  $F_z$  são as forças nos sentidos dos eixos,  $T_y$  é o torque da junta em torno do eixo y e  $\$_{Fx}$ ,  $\$_{Fz}$  e  $\$_{Ty}$  são as heliforças dessas componentes. Assim, cada uma das juntas possui três heliforças com as coordenadas geometrias que definem o seu posicionamento em relação a um mesmo referencial, geralmente considerado a origem, ao qual o somatório de momentos é igual a zero.

Como as heliforças dependem apenas das coordenadas geométricas da junta, uma vez conhecida à geometria completa do mecanismo é possível calcular seu equilíbrio estático da seguinte maneira:

$$\{S_{\lambda k,1}\} = [\$_{\lambda k,\lambda k}^s]^{-1} \left(-\{\$_{\lambda k,C_n}^p\} \cdot \{P_{C_n,1}\}\right),$$
 (2.9)

onde o resultado é uma matriz com os valores das variáveis secundárias, que dependem apenas das variáveis primárias e da geometria (WEIHMANN, 2011).

# 2.3 CAPACIDADE DE FORÇA ESTÁTICA DE MANIPULADORES

A capacidade de força é definida como a máxima força suportada por um manipulador robótico em determinada posição respeitando os limites de torque nas juntas. Na existência de redundância cinemática, diferentes posições podem ser exploradas para um mesmo ponto de extremidade em busca de um melhor desempenho ou ainda de menor requisição de torque. Além disso, através do dimensionamento dos elos do robô é possível alterar a capacidade de força do mecanismo (WEIHMANN, 2011).

Existem diferentes estratégias para calcular a capacidade de força, as quais são discutidas a seguir.

#### 2.3.1 Técnicas Diretas

Para avaliar o desempenho de um manipulador no aspecto de força, alguns fatores que servem como indicadores de desempenho podem ser monitorados. Um

exemplo é a saturação, que acontece quando a primeira junta atinge seu limite de torque em determinada situação. Essa junta é chamada de junta crítica. No estudo de Garg, Nokleby e Carratero (2009) foi considerado um fator de escala limitando o torque de cada junta, o qual é calculado por:

$$fs = \left| \frac{\tau_{max}}{\tau} \right|, \tag{2.10}$$

onde  $\tau_{max}$  é dito o torque máximo suportado pela junta e  $\tau$  é o torque calculado para a mesma a partir de uma força F aplicada.

O fator de escala geral, então, é definido como o mínimo dentre os fatores calculados para cada junta. Esse fator indica a proporção em que essa força *F* pode ser aumentada até que ocorra a saturação da junta crítica. Então, maximizando esse fator obtem-se a capacidade de força de um manipulador.

Outra técnica utilizada para calcular a capacidade de força é a metodologia explícita, a qual visa levar o maior número de juntas à saturação. Contudo, segundo Weihmann (2011), essas duas técnicas são restritivas, pois não consideram o posicionamento e tampouco a redundância cinemática do manipulador.

### 2.3.2 Método de Weihmann

A metodologia proposta por Weihmann (2011) visa a otimização do posicionamento geométrico respeitando as restrições impostas pela tarefa usando metaheurísticas de otimização. Portanto, tal metodologia pode ser aplicada à manipuladores seriais, paralelos, com redundância e em contato com meio, pois todos esses aspectos podem ser inclusos em uma função de custo da maneira mais conveniente.

De maneira simplificada e genérica, essa metodologia pode ser descrita através das seguintes etapas:

 a) Definição das características cinemáticas e estáticas do manipulador e do contato com o meio: basicamente trata-se de definir quais pontos geométricos são fixos e quais são os possíveis modos de trabalho do manipulador;

- b) Definição das variáveis do método de Davies: construir o grafo de equilíbrio, os cortes, a matriz de ações e as heliforças, visando, por fim, separar as variáveis primárias e secundárias;
- c) Definição das variáveis de decisão e do espaço de busca do problema: em geral, trata-se das variáveis primárias do método de Davies juntamente com as variáveis geométricas desejadas e os limites físicos de todas essas variáveis;
- d) Definição das restrições do problema: existem infinitas possibilidades, mas, em geral, são os limites de torque das variáveis secundárias do método de Davies e as restrições específicas da tarefa e do contato com o meio;
- e) Definição do objetivo do problema: a força total do manipulador penalizada pelas restrições não atendidas, sendo flexível a outros objetivos;
- f) Definição da metaheurística de otimização: inclui a parametrização adequada da mesma.

É importante observar que tal metodologia é mais completa que a apresentada por Nokleby (2005) e foi aplicada de forma eficiente em diversos estudos de manipuladores seriais e paralelos (PIEREZAN, FREIRE E WEIHMANN, 2012; WEIHMANN, MARTINS E COELHO, 2012; MEJIA, SIMAS E MARTINS, 2014).

#### 2.4 CENTRO DE MASSA E CENTRO DE GRAVIDADE

O centro de massa (CM) é uma característica dos corpos rígidos e pode ser definido como a representação da massa total dos mesmos em uma única localização no espaço. Para corpos simétricos o CM coincide com o centro geométrico, enquanto que para corpos assimétricos o CM é calculado considerando que o corpo é composto por infinitas partículas (HIBBELER, 2011).

Para um sistema com um número finito N de corpos rígidos o cálculo acontece por meio da seguinte equação:

$$CM(x,y,z) = \frac{1}{\sum_{i=1}^{N} m_i} \left( \sum_{i=1}^{N} m_i x_i, \sum_{i=1}^{N} m_i y_i, \sum_{i=1}^{N} m_i z_i \right)$$
 (2.11)

onde  $m_i$  é a massa de cada um dos corpos e  $x_i$ ,  $y_i$  e  $z_i$  são as coordenadas do centro de massa de cada um dos corpos. Pode-se dizer que o CM é o posicionamento médio das massas do sistema.

Quando o sistema de corpos rígidos está sob a ação gravitacional, a força peso de todos os corpos desse sistema é equivalente a uma única força localizada em um ponto denominado Centro de Gravidade (CG). Assim, a força peso total do sistema é definida pela multiplicação entre a aceleração e a massa total do sistema. Se a aceleração for contínua sobre toda a distribuição de massa do sistema de corpos rígidos, então o CG coincide com o CM do sistema.

# 2.5 ZERO MOMENT POINT (ZMP)

O Zero Moment Point (ZMP) é um conceito muito utilizado na locomoção bípede, o qual é a projeção, no solo, do CG do robô. Na locomoção bípede, esse ponto deve estar localizado dentro do polígono de estabilidade do robô, que compreende a região entre os contatos com o solo (KAJITA E ESPIAU, 2008; KEMP et al., 2008). A Figura 5 mostra a projeção do CG do robô no solo, que resulta no ZMP.

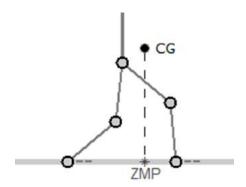


Figura 5 – Projeção do CG no solo: ZMP. Fonte: O Autor (2016).

O cálculo do ZMP é representado pela seguinte equação:

$$x_{zmp} = \frac{-M.g.C_{x} - \sum_{\rho} (F_{x}P_{z}) + \sum_{\rho} (F_{z}P_{x})}{-M.g + \sum_{\rho} F_{z}},$$
(2.12)

onde M é a massa total do robô, g é a aceleração gravitacional,  $C_x$  é a coordenada do centro de massa do robô no eixo x,  $\rho$  é o conjunto das juntas de contato com o

meio,  $F_x$  é o vetor de forças horizontais nas juntas de contato e  $P_z$  são suas respectivas coordenadas no eixo vertical e  $F_z$  é o vetor de forças verticais nas juntas de contato tendo  $P_x$  como suas respectivas coordenadas no solo.

Esse conceito está presente em outros estudos: Pierezan, Freire e Weihmann (2012) adotaram o conceito de ZMP no contexto do equilíbrio estático de um modelo de humanoide. O robô HanSanRam, modelado tridimensionalmente, também foi projetado adotando o ZMP como condição de equilíbrio para evitar o tombamento (YOO, LEE E KIM, 2009).

# 2.6 FORÇA DE ATRITO ESTÁTICO

Quando um objeto está sob uma superfície, existe uma relação de rugosidade decorrente dos materiais que estão em contato. Essa rugosidade é denominada coeficiente de atrito e, muitas vezes, só pode ser visualizada a nível microscópico. Quando o objeto sofre uma ação, haverá sempre uma reação paralela à superfície, a qual é proporcional à força normal (perpendicular) que está sendo aplicada a esse plano. Essa reação é denominada força de atrito. Quando o objeto está em movimento, o atrito é dito dinâmico, enquanto que, quando não está, é dito estático (HIBBELER, 2011).

Considerando a condição estática, a partir de uma força normal à superfície em que o objeto está, é possível determinar a força máxima paralela a essa superfície que pode ser aplicada a esse objeto sem que aconteça o deslizamento, tal que:

$$F_{max} = N. \,\mu_{\rm s} \tag{2.13}$$

onde N é a força normal ao plano e  $\mu_s$  é o coeficiente de atrito estático.

O coeficiente de atrito é adimensional, ou seja, expressa apenas uma proporção e não possui unidade. Além disso, diferentes combinações de materiais em contato possuem coeficientes distintos, sendo que esses valores são obtidos experimentalmente.

# 3 OTIMIZAÇÃO MULTIOBJETIVO

A meta de um processo de otimização de único objetivo é determinar a solução de menor custo possível para uma determinada função. Para isso, os parâmetros de entrada dessa função são manipulados dentro de um espaço de busca pré-definido, retornando como resultado apenas a melhor solução encontrada (STORN E PRICE, 1995).

No caso de um processo de otimização com múltiplos objetivos, também chamado de otimização multiobjetivo, a função avaliada retorna, a partir de um conjunto de parâmetros de entrada, múltiplos valores de custos relacionados ao problema. Esses custos geralmente são concorrentes, ou seja, a dificuldade está em encontrar soluções que sejam simultaneamente satisfatórias para todos os objetivos abordados (DEB, 2001).

A otimização multiobjetivo está presente em diversas áreas do conhecimento, tais como bioinformática (HANDL, KELL E KNOWLES, 2007), economia (PONSICH, JAIMES E COELLO COELLO, 2013), genética (JEONG *et al.*, 2015), engenharias (PÉREZ ABRIL, 2014; ABHISHEK *et al.*, 2015; CARLUCCI *et al.*, 2015), dentre muitas outras (COLLETTE E SIARRY, 2003). Diversas pesquisas obtiveram resultados satisfatórios na otimização de projetos mecatrônicos e apontam a otimização multiobjetivo como uma ferramenta adequada para tal tipo de aplicação (AFFI, EL-KRIBI E ROMDHANE, 2007; KLÖPPER, AUFENANGER E ADELT, 2012; EL-KRIBI *et al.*, 2013).

A seguir são apresentados os aspectos relacionados à otimização multiobjetivo, tais quais incluem os seus fundamentos, metaheurísticas em destaque na literatura especializada e os critérios de avaliação de desempenho.

# 3.1 FUNDAMENTOS DA OTIMIZAÇÃO MULTIOBJETIVO

Segundo Deb (2001), um problema de otimização multiobjetivo pode ser descrito, sem perda de generalização, por:

Minimizar: 
$$f_m(x)$$
,  $m=1,2,...,M;$   
Sujeito a:  $g_j(x) \ge 0$ ,  $j=1,2,...,J;$  (3.1)

$$h_k(x) = 0, \qquad \qquad k = 1, 2, \dots, K;$$
 
$$x_d^{\min} \le x_d \le x_d^{\max}, \qquad \qquad d = 1, 2, \dots, D;$$

onde  $x \in \Re^n$  representa o vetor de variáveis de decisão,  $x_d^{\min} \le x_d \le x_d^{\max}$  o espaço de busca do sua d-ésima componente (dentre o total de D componentes),  $f_m(x)$  representa o custo da m-ésima função objetivo (no total de M objetivos),  $g_j(x)$  representa a j-ésima das J restrições que devem ser maiores ou iguais a zero e  $h_k(x)$  a k-ésima dentre as K restrições que devem equivaler a zero.

Uma solução é considerada factível se, e somente se, satisfizer os limites das variáveis de decisão e, simultaneamente, e respeitar as demais restrições impostas pelo problema. Um conjunto de soluções factíveis é denominado Fronteira de Pareto (FP) (MEZURA-MONTES, REYES-SIERRA E COELLO COELLO, 2008). Mais informações a respeito da otimização multiobjectivo podem ser encontradas em Weck (2004).

#### 3.1.1 Conceito de dominância

O conceito de dominância está relacionado à análise comparativa entre os custos de duas soluções distintas, cujo objetivo é indicar superioridade de uma relação à outra. Sejam as soluções A, B, C e D, conforme mostrado na Figura 6, sendo  $x^A$ ,  $x^B$ ,  $x^C$  e  $x^D$  as variáveis de decisão das soluções e  $[F_1^A, F_2^A]$ ,  $[F_1^B, F_2^B]$ ,  $[F_1^C, F_2^C]$  e  $[F_1^D, F_2^D]$  os seus respectivos pares de custos.

Pode-se notar graficamente pela Figura 6 que os custos da solução A são ambos menores que os custos da solução C. Portanto, a solução C é dita dominada pela solução A. De maneira formal, a solução A domina a solução C se  $f_m(x^A) \le f_m(x^C)$  para todo m = 1, 2, ..., M e  $f_n(x^A) < f_n(x^C)$  para pelo menos um valor de  $n \in M$  (ABRAHAM, JAIN E GOLDBERG, 2005).

Por outro lado, comparando a solução A com a solução D nota-se a condição de dominância não é atendida por nenhuma das duas soluções. Isso significa que cada uma das duas soluções possui menor custo para um dos objetivos (nesse exemplo,  $F_1^A < F_1^D$  e  $F_2^A > F_2^D$ ). Portanto, essas soluções são denominadas subdominadas. Por definição, as soluções A e D são subdominadas se, simultaneamente,  $f_m(x^A) < f_m(x^D)$  para pelo menos um valor de  $m \in M$  e

 $f_n(x^D) < f_n(x^A)$  para pelo menos um valor de  $n \in M$ . Então, utilizando as definições, as soluções C e D são dominadas pelas soluções A e B, respectivamente, e assim as soluções são separadas por dois grupos: as dominadas e as não dominadas.

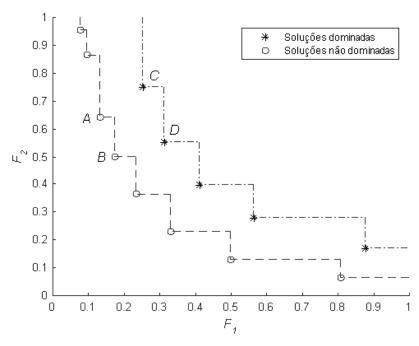


Figura 6 – Conjunto de soluções dominadas e não-dominadas. Fonte: O autor (2016).

### 3.1.2 Otimalidade de Pareto

Na otimização de único objetivo, a solução ótima é aquela cujo custo não pode ser melhorado dentro do intervalo de busca das variáveis de decisão e respeitando as restrições do problema. Na otimização multiobjetivo, devido à existência de múltiplas soluções ótimas, uma noção diferenciada de ótimo deve ser adotada. O termo mais difundido é Pareto Ótimo, o qual representa uma solução que não pode ser superada simultaneamente em todos os objetivos dentro do espaço de busca determinado (DEB, 2001).

Portanto, uma solução  $x^* \in F$  é Pareto ótima se não existir outra  $x \in F$  tal que  $f_m(x) \leq f_m(x^*)$  para todo m=1,2,...,M e  $f_n(x) < f_n(x^*)$  para pelo menos um valor de  $n \in M$ . Logo, um conjunto de soluções que respeitam essa condição resulta em uma Fronteira de Pareto Ótimo, conjunto das soluções que não podem ser dominadas por qualquer outra (ABRAHAM, JAIN E GOLDBERG, 2005).

# 3.2 METAHEURÍSTICAS DE OTIMIZAÇÃO MULTIOBJETIVO

Segundo Manjarres *et al.* (2013), as diversas metaheuristicas conhecidas da literatura podem ser classificadas de acordo com as suas respectivas inspirações. Dentre tais classificações estão os algoritmos evolutivos, inteligência de enxame e os relacionados à Física, os quais, juntos, contém algumas das metaheurísticas de otimização mais difundidas na literatura.

Nesta pesquisa são exploradas quatro metaheurísticas multiobjetivo bioinspiradas em destaque na literatura. Primeiramente, os algoritmos evolutivos Algoritmo Genético de Ordenação Não Dominante II (*Non-Dominated Sorting Genetic Algorithm* — NSGA-II) (DEB et al., 2002) e Evolução Diferencial para Otimização Multiobjetivo (*Differential Evolution for Multiobjective Optimization* — DEMO) (ROBIČ E FILIPIČ, 2005); posteriormente, a Otimização por Enxame de Partículas Multiobjetivo (*Multiobjective Particle Swarm Optimization* — MOPSO) (COELLO COELLO, PULIDO E LECHUGA, 2004), que é classificada como inteligência de enxames; por fim, o algoritmo relacionado à Física denominado Busca Harmônica Multiobjetivo (*Multiobjective Harmony Search* — MOHS) (RICART et al., 2011).

As subseções a seguir contêm os detalhes relacionados às metaheurísticas empregadas nesta pesquisa.

### 3.2.1 NSGA-II

As primeiras versões com múltiplos objetivos (multiobjetivo) dos algoritmos genéticos (AGs) foram propostas na década dos anos 1990 e, posteriormente, foram aprimoradas por vários pesquisadores. O algoritmo NSGA-II, então, proposto por Deb *et al.* (2002), apresentou desempenho superior às demais versões e hoje é um dos mais difundidos na literatura de metaheurísticas de otimização multiobjetivo.

O funcionamento do NSGA-II é baseado no ranqueamento das soluções de acordo, primeiramente, com o conceito de dominância e, posteriormente, com a distância de multidão (*Crowding Distance* – CD). Cada solução recebe, portanto, dois atributos: o *rank* a que pertence e sua distância em relação às soluções vizinhas nesse mesmo ranqueamento (*ranking*). O processo de classificação de acordo com a dominância é iterativo e acontece da seguinte maneira:

Passo 1: Define o ranqueamento atual como 1;

Passo 2: Seleciona todas as soluções que ainda não foram classificadas;

Passo 3: Todas as soluções não dominadas dentre as que foram selecionadas recebem o *rank* atual:

Passo 4: O ranqueamento atual é incrementado e retorna ao Passo 2 até que todas as soluções tenham sido classificadas.

A distância da *i*-ésima solução em relação às soluções vizinhas é igual à soma das distâncias em todos os objetivos de otimização, tal que:

$$cd_{i} = \sum_{m=1}^{M} \frac{d_{m}^{i}}{(f_{m}^{max} - f_{m}^{min})},$$
(3.2)

onde  $f_m^{min}$  e  $f_m^{max}$  são, respectivamente, os custos mínimo e máximo do m-ésimo objetivo dentre as soluções do mesmo rank e  $d_m^i$  é a distância entre soluções vizinhas para o m-ésimo objetivo, cujo valor é obtido pela seguinte equação:

$$d_m^i = f_{i+1\,m} - f_{i-1\,m}\,, (3.3)$$

onde  $f_{i-1,m}$  e  $f_{i+1,m}$  representam os custos do m-ésimo objetivo das soluções vizinhas.

A Figura 7 ilustra como são obtidos os dois atributos para uma *i*-ésima solução, sendo que o primeiro critério de ranqueamento das soluções é o respectivo *rank*. Portanto, as primeiras soluções do ranqueamento final serão aquelas que pertencem ao primeiro *rank*, sendo que a ordem entre elas é definida, então, pela sua distância de multidão. Quanto maior é o valor da distância, mais afastada a solução está da vizinhança. Isso significa que há mais espaço não preenchido por soluções naquela região. Como o objetivo do ranqueamento adotado é obter soluções bem distribuídas no espaço dos objetivos, as soluções com maior valor de distância ficam melhores classificadas no ranqueamento final (DEB *et al.*, 2002).

O restante do algoritmo NSGA-II é similar às versões de único objetivo, sendo que os AGs podem ser representados por variáveis binárias ou reais. Nesta pesquisa, a representação real é adotada (DEB e KUMAR, 1995).

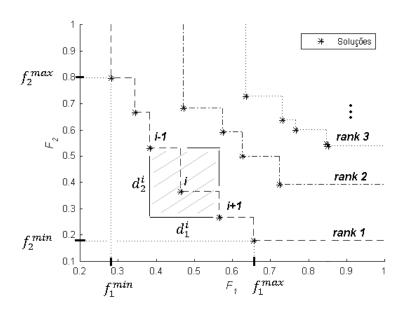


Figura 7 – Ranqueamento das soluções no NSGA-II. Fonte: o Autor (2016).

Cada indivíduo de uma população de tamanho  $N_p$  é formado por um conjunto de D genes que são as variáveis de decisão do problema de otimização, tal que:

$$x_{i,d}^0 = x_d^{\min} + r \cdot (x_d^{\max} - x_d^{\min}),$$
 (3.4)

onde r é um número gerado aleatoriamente com uma distribuição uniforme no intervalo [0,1],  $i=1,2,...,N_p$  e d=1,2,...,D. A avaliação da população ocorre, então, pelo cálculo dos custos vinculados as funções objetivo, ou seja:

$$f_i = [f_{i,1}, f_{i,2}, ..., f_{i,M}] = fobj(x_i).$$
 (3.5)

O primeiro operador genético empregado é o cruzamento (ou recombinação), que ocorre a partir de dois indivíduos geradores com o objetivo de combinar as suas características e obter descendentes mais aptos geneticamente. Existem diferentes estratégias para executar o cruzamento, sendo que na presente pesquisa é utilizado o cruzamento binário simulado (*Simulated Binary Crossover* – SBX) que, segundo Deb e Agrawal (1994), apresenta melhor desempenho comparado às demais estratégias.

Os geradores são escolhidos através do método de torneio: quatro indivíduos aleatórios são escolhidos; o primeiro e o segundo indivíduo competem

para ser o primeiro gerador  $(x_1)$ ; aquele que estiver melhor posicionado no ranking é o vencedor e se torna o gerador; o mesmo procedimento é adotado para o terceiro e o quarto indivíduo para definir o segundo gerador  $(x_2)$ . A d-ésima característica dos descendentes é então definida da seguinte maneira:

$$x'_{1,d} = \begin{cases} 0.5 \cdot \left( (1-B) \cdot x_{1,d} + (1+B) \cdot x_{2,d} \right), & r_{d_1} < P_c \\ x_{1,d} & , & caso \ contr\'{a}rio \end{cases}$$

$$x'_{2,d} = \begin{cases} 0.5 \cdot \left( (1-B) \cdot x_{2,d} + (1+B) \cdot x_{1,d} \right), & r_{d_2} < P_c \\ x_{2,d} & , & caso \ contr\'{a}rio \end{cases}$$

$$(3.6)$$

$$x'_{2,d} = \begin{cases} 0.5 \cdot \left( (1-B) \cdot x_{2,d} + (1+B) \cdot x_{1,d} \right), & r_{d_2} < P_c \\ x_{2,d}, & caso \ contrário \end{cases}$$
(3.7)

onde  $r_{d_1}\,$  e  $r_{d_2}\,$  são números aleatórios de uma distribuição uniforme no intervalo [0,1],  $P_c$  é a probabilidade de cruzamento e:

$$B = \begin{cases} (2u)^{\frac{1}{(\eta+1)}}, & u \le 0.5\\ \left(\frac{1}{2(1-u)}\right)^{\frac{1}{(\eta+1)}}, & caso\ contrário \end{cases}$$
(3.8)

sendo u um número aleatório de uma distribuição uniforme no intervalo [0,1] e  $\eta$  é o parâmetro que ajusta a distribuição de probabilidade do SBX (LADKANY, 2012).

O segundo operador genético é a mutação, o qual é usado para inserir perturbações nas características dos indivíduos e, consequentemente, tornar o algoritmo mais exploratório no espaço de busca. Na presente pesquisa, a mutação polinomial (Polynomial Mutation - PLM) foi adotada (DEB, 2001), sendo que a mesma é aplicada sobre os indivíduos gerados na recombinação, tal que:

$$x''_{i,d} = \begin{cases} x'_{i,d} + \delta \cdot (x_d^{\text{max}} - x_d^{\text{min}}), \ r_d < P_m \\ x'_{i,d}, \ caso \ contrário \end{cases}$$
(3.9)

onde  $r_d$  é um número gerado aleatoriamente com uma distribuição uniforme no intervalo [0,1],  $P_m$  é a probabilidade de mutação e:

$$\delta = \begin{cases} (2u)^{\frac{1}{(\eta_{m+1})}} - 1, & u \le 0.5\\ 1 - (2 \cdot (1-u))^{\frac{1}{(\eta_{m+1})}}, & caso \ contrário \end{cases}$$
(3.10)

u é um número aleatório de uma distribuição uniforme no intervalo [0,1] e  $\eta_m$  é o parâmetro que ajusta a distribuição polinomial de probabilidade do PLM.

Os novos indivíduos são então avaliados, tal que:

$$f''_{i} = [f''_{i,1}, f''_{i,2}, ..., f''_{1,M}] = fobj(x''_{i}).$$
(3.11)

Então, os melhores indivíduos são mantidos para a próxima geração. Note que, na versão de único objetivo do AG, a ordenação de melhores indivíduos acontece pelo único custo conhecido, enquanto que na versão multiobjetivo a ordenação ocorre conforme o ranqueamento previamente detalhado (BÄCK, FOGEL E MICHALEWICZ, 1997).

O pseudocódigo do NSGA-II é então apresentado na Figura 8, sendo  $N_c$  o número de cruzamentos por geração. Outras informações sobre representação, operadores e estratégias dos algoritmos genéticos e do NSGA-II especificamente podem ser encontradas em Deb (2001).

```
Inicia os parâmetros Np, N_c, \eta, \eta_m, P_c e P_m
     Inicia a população (eq. 3.4)
     Avalia a população (eq. 3.5)
     Ranqueamento da população
     Enquanto o critério de parada não for alcançado faca
 5
        Para i de 1 até N<sub>c</sub>
 6
 7
           Seleção dos geradores por torneio
 8
           Cruzamento (eqs. 3.6 e 3.7)
        Fim para
 9
        Para i de 1 até 2 \cdot N_c
10
           Mutação do i-ésimo descendente (eq. 3.9)
11
12
        Fim para
13
        Verificação dos limites das variáveis de decisão
        Avaliação dos novos indivíduos (eq. 3.11)
14
        Ranqueamento de todos indivíduos: população e descendentes
15
        Seleção dos Np primeiros indivíduos do ranking para a próxima
16
     Fim enquanto
17
```

Figura 8 – Pseudocódigo do NSGA-II. Fonte: o Autor (2016).

#### 3.2.2 DEMO

As metaheurísticas de otimização multiobjetivo derivadas da Evolução Diferencial (ED) (STORN E PRICE, 1995 e 1997; DAS e SUGANTHAN, 2011) e baseadas em fronteira de Pareto surgiram na mesma época do NSGA-II (XUE, SANDERSON E GRAVES, 2003; MEZURA-MONTES, REYES-SIERRA E COELLO COELLO, 2008; CHENG e ZHANG, 2013). O algoritmo proposto por Robič e Filipič (2005) denominado Evolução Diferencial para Otimização Multiobjetivo (*Differential Evolution for Multiobjective Optimization* – DEMO) foi adotado na presente pesquisa.

A ED é inspirada na teoria da evolução de Darwin e na utilização de diferenças entre vetores, baseada em uma população de tamanho N que gera novos indivíduos e seleciona os que melhor se adaptam ao ambiente. Os indivíduos são, inicialmente, gerados aleatoriamente dentro espaço de busca do problema de dimensão D,  $\left[x_d^{\max}, x_d^{\min}\right] \ \forall \ d = \{1, 2, ..., D\}$ , tal que:

$$x_{i,d}^{0} = x_{d}^{\min} + r \cdot (x_{d}^{\max} - x_{d}^{\min}),$$
 (3.12)

onde  $r \in [0,1]$  é um número gerado aleatoriamente com distribuição uniforme,  $i=1,2,\ldots,N$  e  $d=1,2,\ldots,D$ .

A geração de novos indivíduos acontece por meio de dois operadores: a recombinação e a mutação. Primeiramente, um indivíduo mutante é gerado a partir de outros indivíduos da população; existem estratégias distintas para a execução desse operador. Em seguida, as características do indivíduo mutante e do gerador são recombinadas; novamente, não há apenas uma estratégia de recombinação. No algoritmo DEMO adotado nessa pesquisa, a estratégia utilizada é a *rand/1/bin*, ou seja, a mutação ocorre por meio de apenas um vetor diferença entre indivíduos aleatórios e a recombinação é binomial. Logo, a *d*-ésima característica do indivíduo descendente é definida através da seguinte equação:

$$x'_{i,d} = \begin{cases} x_{r_1,d} + F \cdot (x_{r_2,d} - x_{r_3,d}), & r_d \le CR \text{ ou } d = d^r \\ x_{i,d}, & \text{caso contrário} \end{cases},$$
(3.13)

onde  $x_{r_1}$ ,  $x_{r_2}$  e  $x_{r_3}$ são indivíduos da população selecionados aleatoriamente,  $x_i$  é o indivíduo gerador, F é o fator de escala da mutação,  $r_d \in [0,1]$  é um numero aleatório de uma distribuição de probabilidade uniforme,  $CR \in [0,1]$  é a taxa de recombinação e  $d^r \in [1,D]$  é uma característica escolhida aleatoriamente para garantir que o descendente não seja idêntido ao gerador. Outras estratégias da ED podem ser encontradas em Das e Suganthan (2011) e Cheng e Zhang (2013).

A avaliação do *i*-ésimo gerador e do *i*-ésimo descendente ocorre, respectivamente, por meio das seguintes equações:

$$f_i = [f_{i,1}, f_{i,2}, \dots, f_{i,M}] = fobj(x_i) e$$
 (3.14)

$$f'_{i} = [f'_{i,1}, f'_{i,2}, ..., f'_{i,M}] = fobj(x'_{i}),$$
 (3.15)

onde fobj é a função que retorna os M custos das funções objetivo.

A abordagem multiobjetivo do DEMO é baseada no conceito de dominância, na qual o indivíduo descendente é comparado diretamente com o seu gerador (filtragem por dominância). Se o descendente dominar o gerador, então este cede seu lugar na população; se o descendente for dominado pelo gerador, então o gerador é mantido na população e o descendente é descartado; caso nenhuma dessas duas condições seja atendida, então ambos são mantidos na população para, posteriormente, serem filtrados apenas os *N* melhores indivíduos. Essa filtragem é similar ao ranqueamento do algoritmo NSGA-II (ROBIČ E FILIPIČ, 2005). O pseudocódigo do algoritmo DEMO é mostrado na Figura 9, onde as equações aparecem na sequência em que são empregadas e os parâmetros de entrada do algoritmo são indicados na primeira linha de execução.

```
Inicia os parâmetros N, F \in \overline{CR}
     Inicia a população (eq. 3.12)
 2
 3
     Avalia a população (eq. 3.14)
     Enquanto o critério de parada não for alcançado faça
        Para i de 1 até N_p
 5
           Gera um descendente (eq. 3.13)
 6
           Verifica os limites das variáveis de decisão
 7
 8
           Avalia o descendente (eqs. 3.15)
 9
           Aplica a filtragem por dominância
        Fim para
10
        Filtra os N_p melhores indivíduos
11
        Ordena aleatoriamente os indivíduos
12
13
     Fim enquanto
```

Figura 9 – Pseudocódigo do algoritmo DEMO. Fonte: o Autor (2016).

#### 3.2.3 MOPSO

A Otimização por Enxame de Partículas (*Particle Swarm Optimization* – PSO) surgiu em 1995 com o objetivo de tratar problemas em espaço contínuo de busca. Sua concepção foi inspirada no comportamento de animais que vivem em bandos, como é o caso dos pássaros e dos peixes (KENNEDY; EBERHART, 1995).

O funcionamento da PSO é baseado em partículas que se movem no intervalo de busca, cujo posicionamento de cada representa uma possível solução para o problema. A posição depende da própria experiência da partícula e também das suas vizinhas, influência a qual acontece devido à relação social no enxame (ENGELBRECHT, 2005).

Seja um enxame de tamanho Ns que se move continuamente em função do tempo t, para cada  $i = \{1, 2, ..., Ns\}$  existe uma partícula localizada em  $x_i$  de dimensão D (dimensão do problema) que representa uma possível solução para o problema. Inicialmente, as partículas são posicionadas aleatoriamente no espaço de busca  $\left[x_d^{\text{max}}, x_d^{\text{min}}\right] \in \mathbb{R}^D \forall d = \{1, 2, \dots D\}$ , tal que:

$$x_{i,d}^{0} = x_d^{\min} + r \cdot (x_d^{\max} - x_d^{\min}). \tag{3.16}$$

As velocidades dessas partículas em todas as dimensões são inicialmente iguais a zero, ou seja:

$$v_{i,d}^0 = 0, d = \{1, 2, ..., D\}.$$
 (3.17)

Para cada instante de tempo, a velocidade e a posição das partículas são atualizados. Segundo Engelbrecht (2005), existem várias estratégias de atualização da velocidade, sendo que, na presente pesquisa, a versão multiobjetivo adotada, proposta por Coello Coello e Lechuga (2002), a equação de atualização é a seguinte:

$$v_i^{t+1} = w \cdot v_i^t + c_1 \cdot r_1 \cdot (y_i^t - x_i^t) + c_2 \cdot r_2 \cdot (\hat{y}_i^t - x_i^t), \tag{3.18}$$

onde  $v_i^t$  e  $x_i^t$  são, respectivamente, a velocidade e a posição da partícula i no instante anterior,  $y_i$  é a melhor posição já ocupada pela partícula i,  $\hat{y_t}$  é a melhor posição conhecida pelo enxame,  $c_1$  e  $c_2$  são constantes cognitiva e social, respectivamente,  $r_1$ e  $r_2$  são valores gerados aleatoriamente com distribuição uniforme no intervalo [0,1] e w é o peso de inércia.

O peso de inércia e as constantes sociais e cognitivas são definidas, respectivamente, pelas seguintes equações:

$$w = \chi, \tag{3.19}$$

$$w = \chi, \tag{3.19}$$

$$c_1 = \chi \cdot \varphi_1 \text{ e} \tag{3.20}$$

$$c_2 = \gamma \cdot \varphi_2, \tag{3.21}$$

onde  $\varphi_1$  e  $\varphi_2$  são parâmetros de entrada que precisam ser configurados para o ajuste das constantes e  $\chi$  é definido por:

$$\chi = \frac{2}{\varphi_1 + \varphi_2 - 2 + \sqrt{(\varphi_1 + \varphi_2)^2 - 4 \cdot (\varphi_1 + \varphi_2)}}.$$
 (3.22)

A posição de cada partícula é então atualizada da seguinte maneira pela utilização da velocidade como se fosse um deslocamento no tempo tal que:

$$x_i^{t+1} = x_i^t + v_i^{t+1}. (3.23)$$

Na otimização com único objetivo,  $y_i$  e  $\hat{y_t}$  seriam determinadas considerando apenas o custo da função objetivo. Tratando-se de otimização multiobjetivo, uma abordagem distinta é adotada, a qual é baseada no conceito de dominância. A melhor posição ocupada pela partícula para o próximo instante de tempo é definida pela seguinte regra:

$$y_i^{t+1} = \begin{cases} y_i^t, & \text{se } y_i^t \text{ domina } x_i^{t+1} \\ x_i^{t+1}, & \text{se } x_i^{t+1} \text{ domina } y_i^t \\ \sigma, & \text{se não há dominância} \end{cases}$$
(3.24)

sendo que  $\sigma$  pode assumir tanto  $y_i^t$  quanto  $x_i^{t+1}$ , tal que:

$$\sigma = \begin{cases} x_i^{t+1}, & r < 0.5 \\ y_i^t, & caso \ contrário \end{cases}$$
 (3.25)

onde r é um valor gerado aleatoriamente com distribuição uniforme no intervalo [0,1].

Além disso, a melhor posição conhecida pelo enxame é tratada como uma partícula líder que será seguida. A escolha dessa partícula, que pertence ao grupo das soluções não dominadas conhecidas, acontece por meio da divisão do espaço dos objetivos em hipercubos, como mostra a Figura 10, onde existem  $n_h^2$  hipercubos. Cada j-ésimo hipercubo ocupado por pelo menos uma solução recebe um valor de aptidão compartilhada, a qual é calculada pela seguinte equação:

$$p_j = ns_j^{-1}, (3.26)$$

onde  $ns_j$  é o número de soluções localizadas no j-ésimo hipercubo. Portanto, quanto maior for o número de soluções em determinado hipercubo, menor será sua aptidão compartilhada.

A escolha da partícula líder é executada por meio do método da roleta, na qual a probabilidade de uma partícula ser escolhida como líder é igual à aptidão compartilhada do hipercubo à qual pertence. Logo, as chances de uma partícula que

está sozinha em um hipercubo ser escolhida como líder são maiores. Na Figura 10, por exemplo, a partícula cuja solução está localizada no *k*-ésimo hipercubo tem maior chance com relação à que está no *i*-ésimo hipercubo. O objetivo desse mecanismo é melhor distribuir as partículas nos hipercubos e, portanto, obter soluções mais diversificadas (COELLO COELLO E LECHUGA, 2002).

Outro mecanismo empregado no algoritmo é a correção da velocidade das partículas, a qual acontece em duas ocasiões: quando a velocidade ultrapassa um valor máximo estipulado e quando a posição atualizada da partícula está localizada fora do espaço de busca. Para o primeiro caso, a velocidade é ajustada para uma porcentagem limite  $(v^{max} \in ]0,1])$  do espaço de busca; para o segundo caso, o sentido de movimento da partícula é invertido, tal que:

$$v_{i,d}^{t} = \begin{cases} -v_{i,d}^{t}, & x_{i,d}^{t} > x_{d}^{\max} OU x_{i,d}^{t} < x_{d}^{\min} \\ v_{i,d}^{t}, & caso \ contrário \end{cases}$$
(3.27)

e a posição da partícula é ainda corrigida para o limite do espaço de busca.

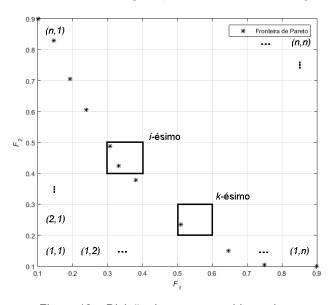


Figura 10 – Divisão do espaço em hipercubos. Fonte: o Autor (2016).

Por fim, o pseudocódigo do algoritmo MOPSO é apresentado na Figura 11, sendo que o procedimento de seleção e armazenamento das soluções não dominadas, mostrado na linha 16, é similar à seleção da partícula líder; quando o número de soluções não dominadas excede o limite de armazenamento estipulado (em geral,  $N_s$ ), então as soluções com maior probabilidade de serem eliminadas são

aquelas localizadas em hipercubos mais preenchidos. Portanto, as probabilidades são calculadas pelo inverso da equação 3.26 e o restante do procedimento é o mesmo.

```
Inicia os parâmetros Ns, \varphi_1, \varphi_2, v^{max} e n
     Configura os demais parâmetros (eqs. 3.19, 2.20 e 3.21)
     Posiciona as partículas aleatoriamente (eq. 3.16)
     Inicia a velocidade das partículas (eq. 3.17)
     Cria hipercubos no espaço de busca (Figura 10)
     Enquanto o critério de parada não for alcançado faça
        Para i de 1 até N<sub>n</sub>
 7
 8
            Seleciona um líder para guiar a i-ésima partícula
 9
           Atualiza a velocidade da i-ésima partícula (eq. 3.18)
10
            Atualiza a posição da i-ésima partícula (eq. 3.23)
            Correção da posição da i-ésima partícula, se necessário
11
            Correção da velocidade da i-ésima partícula, se necessário (eq.3.27)
12
13
            Avaliação da i-ésima partícula
           Atualiza a melhor posição da i-ésima partícula (eq. 3.24)
14
15
        Fim para
16
        Seleciona e armazena apenas as partículas não dominadas
        Atualiza os hipercubos baseado no novo grupo de soluções não dominadas
17
18
     Fim enquanto
```

Figura 11 – Pseudocódigo do algoritmo MOPSO. Fonte: o Autor (2016).

### 3.2.4 MOHS

O algoritmo Busca Harmônica (*Harmony Search* – HS) foi inicialmente proposto por Geem, Kim e Loganathan (2001) e é baseado no ajuste de frequências sonoras de um ponto de vista estético. Em outras palavras, o HS visa ajustar os tons musicais em busca de uma melhor harmonia, que na otimização com único objetivo pode significar a obtenção do ótimo global para o problema estudado.

Seja um conjunto com HMS harmonias, chamado de memória de harmonias ( $Harmony\ Memory\ -\ HM$ ), onde cada uma corresponde à um vetor de harmonias improvisadas por um músico. Inicialmente, essa memória é definida por:

$$HM_{i,d} = x_d^{\min} + r \cdot (x_d^{\max} - x_d^{\min}),$$
 (3.28)

onde i=1,2,...,HMS, d=1,2,...,D (sendo D o número de variáveis do problema),  $r\in[0,1]$  é um número aletório de uma distribuição uniforme e  $\left[x_d^{\max},x_d^{\min}\right]\in\mathbb{R}^D$  é o intervalo de busca para a d-ésima variável.

Cada harmonia é avaliada através da função objetivo do problema, que pode conter um ou mais objetivos, tal que:

$$f_i = [f_{i,1}, f_{i,2}, ..., f_{i,M}] = fobj(HM_i).$$
 (3.29)

As novas harmonias improvisadas são compostas por D improvisos distintos, sendo que existem três opções de improviso: seleção aleatória, consideração de memória e ajuste de tons (RICART *et al.*, 2011). A primeira acontece com probabilidade 1 - HMCR, sendo HMCR a taxa de consideração de memória de harmonias (*Harmony Memory Considering Rate*), tal que:

$$Imp_d = x_d^{\min} + r \cdot (x_d^{\max} - x_d^{\min}), \tag{3.30}$$

onde  $r \in [0,1]$  é um número aletório de uma distribuição uniforme.

A segunda opção acontece com probabilidade HMCR e significa que uma harmonia é selecionada diretamente da HM, ou seja:

$$Imp_d = HM_{i,d}, (3.31)$$

onde  $j \in [1, HMS]$  indica uma harmonia selecionada aleatoriamente da HM.

A terceira opção de improviso consiste em um ajuste de tons e acontece apenas quando uma harmonia já tenha sido retirada da *HM*. Esse ajuste é realizado com probabilidade *PAR* (*Pitch Adjusting Rate*) da seguinte maneira:

$$Imp_d = Imp_d + r \cdot FW \cdot (x_d^{\text{max}} - x_d^{\text{min}}), \tag{3.32}$$

onde  $r \in [0,1]$  é um número gerado aleatoriamente com distribuição uniforme e  $FW \in [0,1]$  implica em uma porcentagem de largura de banda. Portanto, a probabilidade de acontecer esse improviso é  $PAR \cdot HMCR$  e a probabilidade de o improviso ser apenas retirado da HM é de  $HMCR \cdot (1 - PAR)$ .

Na versão de único objetivo do algoritmo HS, o novo improviso é avaliado (em termos do custo da função objetivo) e em seguida é comparado ao improviso de menor desempenho da memória de harmonias. Na versão multiobjetivo adotada nessa pesquisa, que se refere à primeira versão proposta por Ricart *et al.* (2011), o conceito da dominância e distância de multidão é adotado, de maneira semelhante ao algoritmo NSGA-II. Para cada nova harmonia improvisada, a seleção das

melhores harmonias é executada, como pode ser visto no pseudocódigo do algoritmo MOHS exposto na Figura 12.

```
Inicia os parâmetros HMS, HMCR, PAR e FW
 2
     Inicia a memória de harmonias (eq. 3.28)
    Avalia as harmonias da memória (eq. 3.29)
    Enquanto o critério de parada não for alcançado faça
       Inicia uma nova harmonia de dimensão D
 5
       Para d de 1 até D
 6
 7
           Executa o d-ésimo improviso da nova harmonia (eqs. 3.30, 3.31 e 3.32)
 8
       Fim para
 9
       Avalia a nova harmonia improvisada
       Agrupa a nova harmonia à memória de harmonias
10
        Filtra as HMS melhores harmonias por dominância e distância de multidão
11
    Fim enquanto
```

Figura 12 – Pseudocódigo do algoritmo MOHS. Fonte: o Autor (2016).

# 3.3 MÉTRICAS DE DESEMPENHO

Segundo Deb (2001), quanto mais diversificadas forem as soluções que constituem a fronteira de Pareto, maior a qualidade do conjunto de soluções obtido. Isso acontece devido à maior distribuição das soluções e, consequentemente, resulta em uma maior cobertura da fronteira de Pareto. Além disso, quanto mais próximas as soluções estiverem da origem, menores são os custos de todos os objetivos. Dessa maneira, uma boa técnica de otimização é aquela que consegue aproximar as soluções da origem, mas também consegue mantê-las bem distribuídas ao longo da fronteira de Pareto (DEB e SRINIVAS, 1994; DEB, 2001).

Portanto, algumas medidas de desempenho podem ser empregadas para avaliar a qualidade das soluções encontradas pelas técnicas de otimização multiobjetivo. Essas medidas podem ser divididas em dois grupos: primeiramente, aquelas que são aplicadas quando a fronteira Pareto ótimo é conhecida; o segundo grupo contém aquelas que são utilizadas quando essa condição não é atendida. Devido ao problema de otimização da presente pesquisa, cujas soluções Pareto ótimas são desconhecidas, apenas o segundo grupo interessa às análises.

Dentre as medidas do grupo de interesse estão o hipervolume, a distância média das soluções em relação à origem, o número de soluções não dominadas e o espaçamento das soluções (DEB, 2001), que são algumas das mais utilizadas na

literatura (JIANG et al., 2014). A seguir são apresentadas as definições e as equações dessas medidas.

## 3.3.1 Número de Soluções Não Dominadas (NSND)

Essa métrica está relacionada à diversidade de soluções encontradas por determinada técnica de otimização multiobjetivo e pode ser apresentada como porcentagem ou como valor absoluto. Após o término do processo de otimização, o conjunto de todas as soluções encontradas é filtrado e apenas as soluções não dominadas são mantidas, uma vez que soluções dominadas não apresentam qualquer vantagem no resultado final da otimização e, portanto, devem ser descartadas. Então, o número de soluções remanescentes é o valor atribuído à métrica NSDN (JIANG et al., 2014).

# 3.3.2 Distância Euclidiana Média (DEM)

Esse critério está atrelado à convergência das soluções não dominadas encontradas, pois trata-se de mensurar a distância média entre essas soluções e um ponto de referência (para problemas em que o objetivo é a minimização de todos os objetivos). Essa distância pode ser calculada de diferentes maneiras, sendo que a mais adequada é a Distância Euclidiana e o ponto de referência adotado é a origem (AYALA, PIEREZAN E COELHO, 2014).

Para um conjunto de *N* soluções não dominadas, portanto, a DEM pode ser calculada através da seguinte equação:

$$DEM = \frac{\sum_{n=1}^{N} \sqrt{\sum_{m=1}^{M} f_{n,m}^2}}{N},$$
(3.33)

onde M representa o número de objetivos de otimização do problema corrente e  $f_{n,m}$  o custo do m-ésimo objetivo da n-ésima solução. A Figura 13 ilustra o cálculo da DEM, sendo  $d_n = \sqrt{\sum_{m=1}^M f_{n,m}^2}$ .

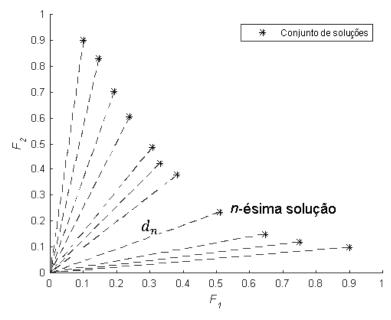


Figura 13 – Distância Euclidiana entre as soluções e a origem. Fonte: o Autor (2016).

# 3.3.3 Hipervolume (HV)

Essa métrica é utilizada para calcular a área ou volume coberto pelo conjunto de soluções não dominadas encontradas pela técnica de otimização e não prioriza nem convergência e nem diversidade das soluções. O HV é então calculado através da união de hipercubos  $v_n$  formados por um ponto de referência e uma n-ésima solução da fronteira de Pareto (FP) (DEB, 2001), tal que:

$$HV = volume(\bigcup_{n=1}^{|FP|} v_n). \tag{3.34}$$

Como exemplificado na Figura 14, onde o hipervolume equivale à razão entre a área em cinza e a área total entre a origem e o ponto de referência. Em geral, o ponto de referência pode ser definido como os piores custos conhecidos para os objetivos; de modo a facilitar o cálculo, os custos de todas as soluções são normalizados linearmente no intervalo [0,1], sendo então a área total igual a 1 e HV equivalente à área cinza. Os maiores valores de HV implicam em uma maior expansão da área cinza, indicando melhor desempenho nesse critério.

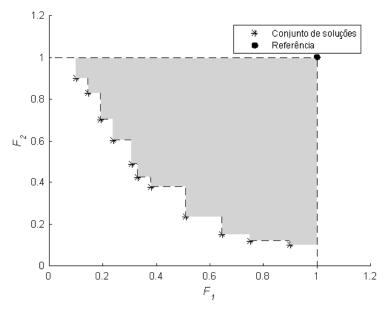


Figura 14 – Utilização da métrica hipervolume. Fonte: adaptado de Deb (2001).

# 3.3.4 Espaçamento (E)

Essa métrica é utilizada para indicar quão bem estão distribuídas as soluções da fronteira de Pareto, implicando, portanto, em um critério de diversidade das soluções (ABRAHAM, JAIN E GOLDBERG, 2005). O cálculo da métrica E acontece da seguinte maneira:

$$E = \sqrt{\frac{1}{N-1} \sum_{n=1}^{N} (\overline{d_n} - d_n^{min})^2} , \qquad (3.35)$$

onde  $\{d_n\}=\sum_{m=1}^M|f_m^n-f_m^k|\mid k\in[1,N]\cap k\neq n,\quad \overline{d_n}=m\acute{e}dia(\{d_n\})$  e  $d_n^{min}=m\acute{n}imo(\{d_n\}).$ 

Como o objetivo é obter soluções melhor distribuídas na fronteira, quanto menor for o valor calculado para E, melhor a qualidade da fronteira apresentada. Um valor de E igual a zero indica que todas as soluções estão perfeitamente à mesma distância de suas vizinhas. Como exemplo, a Figura 15 ilustra duas situações: a primeira (Figura 15.a) em que as soluções estão bem distribuídas na fronteira (E igual a 0,0390) e a segunda (Figura 15.b) em que as distâncias variam acentuadamente entre uma solução e outra (E igual a 0,0444).

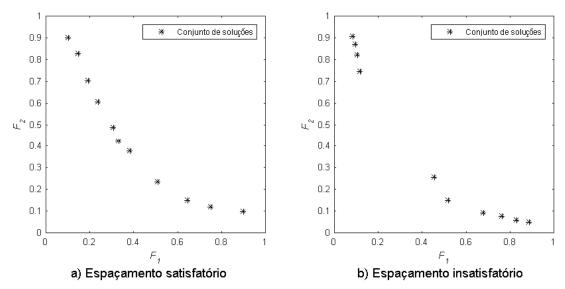


Figura 15 – Espaçamento: duas situações. Fonte: o Autor (2016).

# 4 OTIMIZAÇÃO MULTIOBJETIVO DE ROBÔS HUMANOIDES

A metodologia adotada nesta dissertação é uma extensão da pesquisa de Weihmann (2011) e de Pierezan (2013), as quais contêm uma proposta de otimização da capacidade de força estática de manipuladores robóticos e de um robô humanoide, respectivamente, em contato com o meio usando metaheurísticas de otimização global de único objetivo. Na presente pesquisa, entretanto, existem duas particularidades com relação à proposta de Weihmann, sendo a primeira similar à de Pierezan (2013):

- O mecanismo otimizado é um robô humanoide que, diferentemente de um manipulador fixado ao meio, está sujeito ao <u>deslizamento</u> e ao <u>tombamento</u>.
- Além da capacidade de força estática, o problema envolve um <u>segundo</u> <u>objetivo</u>, o qual está relacionado à requisição de torque para a realização da tarefa.

Portanto, a metodologia desta pesquisa é dividida em cinco etapas, as quais são ilustradas e enumeradas na Figura 16. As etapas destacadas na cor azul (etapas 2,3,4, e 5) são bem difundidas na área de otimização (DAS *et al.*, 2011), enquanto que, representada em amarelo (etapa 1), a definição do robô humanoide em contato com o meio é uma abordagem exclusiva do problema em questão e derivada da proposta de Weihmann. As flechas representam a existência e o sentido do fluxo de dados entre as etapas.

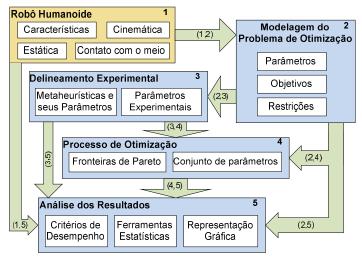


Figura 16 – Representação da metodologia adotada. Fonte: o Autor (2016).

O processo tem início com a definição do modelo de humanoide (etapa 1), cujas características são os elos, as juntas e suas respectivas propriedades. Os elos possuem determinada geometria, dimensão e massa. As juntas, por sua vez, são caracterizadas pelo respectivo GDL e pelo torque máximo suportado. Com isso, a cinemática do humanoide pode ser definida a partir das conexões entre os elos e as juntas e da escolha da estratégia (cinemática direta ou inversa) conforme a aplicação do robô.

O equilíbrio estático do humanoide, que depende obrigatoriamente da definição da cinemática, define todas as forças e momentos nas juntas e pode ser estabelecido através de diferentes estratégias. Em geral, os métodos são baseados nas leis de Newton (somatórios dos esforços devem ser nulos em relação à um referencial), o que os diferencia é a flexibilidade de manipulação dos cálculos. A existência de contato com o meio, por outro lado, resulta em fatores físicos que podem ser inclusos no modelo. Portanto, a complexidade do modelo é variável e dependente da relação estabelecida entre o humanoide e o meio.

A partir dessas informações, que são transmitidas para a etapa 2 (flecha 1,2), o problema de otimização pode ser modelado em termos de parâmetros, que são as variáveis manipuladas durante o processo de otimização, de objetivos de otimização, que dependem da tarefa em que o humanoide é empregado, e das restrições que são derivadas das características físicas do modelo de humanoide em contato com o meio. A dimensão do problema de otimização é então definida a partir do número total de variáveis de decisão, sendo tal informação compartilhada com a etapa 3 (flecha 2,3) para a configuração dos parâmetros das metaheuristicas, as quais também devem ser definidas. Essa configuração é importante, pois afeta diretamente o desempenho das metaheuristicas (ZHOU et al., 2011).

Nessa mesma etapa são definidos os parâmetros experimentais, cujo objetivo é a definição de todos os fatores que influenciam na condução dos experimentos. Em geral, os principais fatores que devem ser observados são o número de repetições experimentais e o critério de parada de execução. A etapa 4 recebe todos esses parâmetros através da flecha (3,4), bem como a modelagem do problema de otimização (que também pode ser chamada de função objetivo) e o intervalo de busca das variáveis de decisão, através da flecha (2,4). Nessa etapa as metaheuristicas são aplicadas à função objetivo conforme o delineamento

experimental, sendo coletados, ao fim de cada rodada de otimização, uma fronteira de Pareto e o conjunto com as suas respectivas soluções.

Então, a etapa 5 recebe as informações de todas as etapas anteriores para análise e exibição dos resultados. Primeiramente, os critérios de desempenho das metaheuristicas precisam ser definidos, os quais avaliam a qualidade do conjunto de soluções encontrado pelas metaheuristicas e são aplicados aos resultados fornecidos pela flecha (4,5). Posteriormente, uma análise estatística é realizada para avaliar, principalmente, a repetibilidade dos resultados (por se tratar de métodos estocásticos). Testes de hipótese de outras ferramentas também podem ser empregadas, conforme o objetivo da comparação de desempenho. A escolha das técnicas estatísticas depende, principalmente, do número de metaheuristicas, do número de experimentos (fornecidos pela flecha (3,5)) e da distribuição de probabilidade (DERRAC *et al.*, 2011).

Por fim, os resultados são convertidos para uma representação gráfica, a qual depende também das informações fornecidas pelas flechas (1,5) e (2,5). Com isso, pode-se visualizar a relação entre todas as variáveis envolvidas no processo, desde as características do modelo de robô até as soluções encontradas após o processo de otimização, conforme o interesse e objetivo de análise. As subseções a seguir contêm o detalhamento da presente pesquisa conforme as etapas da metodologia descrita e de seus respectivos elementos.

## 4.1 ROBÔ HUMANOIDE

O modelo de humanoide adotado nesta pesquisa é o mesmo descrito em Pierezan, Freire e Weihmann (2012), cujo estudo explora a capacidade de força estática do robô. A seguir são mencionadas as características do humanoide e as definições cinemática, estática e de contato com o meio.

#### 4.1.1 Características

O modelo de humanoide adotado possui doze juntas rotativas de um GDL cada e nove elos com massa definida. O tronco representado por um elo único e membros formados por dois elos, uma junta intermediária e duas extremas, uma em contato com o meio e a outra com o tronco. A Figura 17 ilustra a estrutura do robô,

onde a cabeça e o pescoço são desenhados apenas para representação e suas massas são desconsideradas.

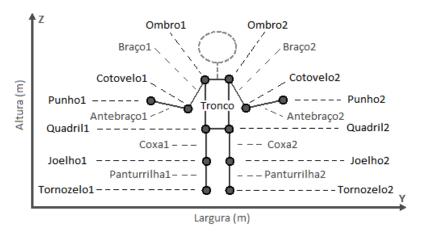


Figura 17 – Modelo adotado. Fonte: Adaptado de Pierezan, Freire e Weihmann (2012).

As características do humanoide são extraídas do mesmo estudo, dentro das quais estão o limite de torques de cada junta, o peso e a massa de cada elo. A Tabela 1 mostra essas características, sendo que tais valores não são baseados em um modelo real de humanoide, mas sim valores atribuídos para fins comparativos. Assume-se que não existe momento nas juntas de contato, pois estão em contato direto com o meio (PIEREZAN, *et al.*, 2012). Além disso, assume-se também que os elos suportam, em termos estruturais, todos os esforços necessários para manter sua integridade.

Tabela 1 – Características do robô humanoide.

Elos			Juntas	
Elo	Massa (kg)	Comprimento (m)	Junta	Torque máximo (N.m)
Antebraço	1,0	1,0	Punho	Nulo
Braço	1,0	1,0	Cotovelo	10
Tronco	2,0	2,0	Ombro	20
Coxa	2,0	1,2	Quadril	40
Panturrilha	1,5	1,2	Joelho	45
			Tornozelo	Nulo

Fonte: adaptado de Pierezan, Freire e Weihmann (2012).

### 4.1.2 Cinemática

Devido a configuração dos humanoides, os mesmos apresentam redundância cinemática. Portanto, existem infinitas possibilidades de configuração

no plano sagital para o humanoide realizar uma determinada tarefa (PIEREZAN, FREIRE E WEIHMANN, 2012). Os contatos com o meio variam (Figura 18.a), bem como as coordenadas do centro e a inclinação do tronco (Figura 18.b e Figura 18.c). É importante observar que as juntas dos ombros e quadril aparecem sobrepostas, porem cada uma está ligada a um dos membros do humanoide.

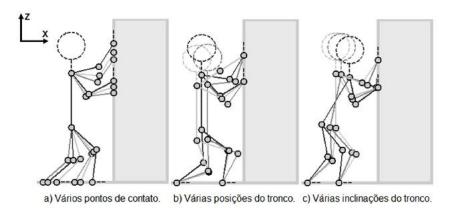


Figura 18 – Diferentes posições para o robô. Fonte: (PIEREZAN, 2013).

Devido a isso, um procedimento sistêmico é necessário para definir a cinemática completa do humanoide. O primeiro passo é o posicionamento do tronco, como mostrado na Figura 19.a. Assim, as posições dos ombros são automaticamente definidas. Posteriormente, as coordenadas dos contatos com o meio são definidas e assim as posições das juntas intermediárias são calculadas por meio da cinemática inversa, como ilustrado na Figura 19.b. Dessa maneira, o contato com o meio é garantido (note que  $d_3$  não pode exceder  $d_1 + d_2$ ) (PIEREZAN, 2013).

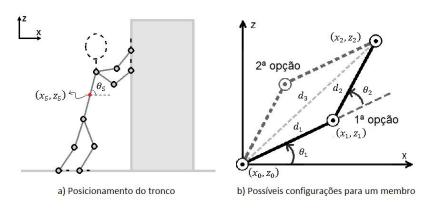


Figura 19 – Configuração da cinemática. Fonte: Adaptado de Pierezan, Freire e Weihmann (2012).

#### 4.1.3 Contato com o meio

Uma vez que o humanoide está em contato com o meio, alguns aspectos físicos devem ser considerados. Em primeiro lugar, há a força gravitacional atuando sobre os elos, o que significa que cada elo tem uma força vertical concentrada em seu respectivo centro de massa. De acordo com a Segunda Lei de Newton, esta força é calculada através da multiplicação da massa do elo pela aceleração gravitacional. No modelo de humanoide adotado, assume-se que os elos têm geometria regular. Portanto, o seu centro de massa coincide com o seu centro geométrico.

Além disso, a força gravitacional influencia diretamente o equilíbrio estático do humanoide em dois fatores: tombamento e deslizamento. Em robôs bípedes, o conceito de *Zero Moment Point* (ZMP) é adotado para evitar o tombamento (KEMP et al., 2008). A posição correta do ZMP para evitar esta situação é no interior do polígono estabilidade, que compreende a região entre os contatos com o solo, como mostrado na Figura 20.a. Se o ZMP não está localizado no interior desta região, tal como ilustrado na Figura 20.b, então o humanoide estará sujeito ao tombamento.

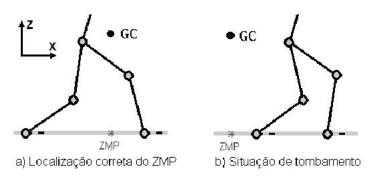


Figura 20 – Influência do contato com o meio. Fonte: o autor (2016).

Ainda, o fator do deslizamento é comumente desprezado na maioria dos estudos. Em geral, considera-se que existe rugosidade suficiente nos contatos com o meio para realizar a tarefa desejada sem que o deslizamento aconteça. No modelo em estudo, entretanto, as forças de atrito são consideradas e avaliadas para cada tarefa. Supõe-se que os materiais nos contatos são conhecidos, o que significa que os coeficientes de atrito (e, portanto, as rugosidades nos contatos) são também conhecidos. Assim, a tarefa é realizada corretamente apenas se a rugosidade

requisitada em cada contato estiver fisicamente disponível (PIEREZAN, FREIRE E WEIHMANN, 2012).

#### 4.1.4 Estática

A estática de um mecanismo consiste na definição de suas forças e momentos internos para estabelecer o equilíbrio. Entre as diferentes estratégias conhecidas para definir o equilíbrio estático, o método de Davies (DAVIES, 1983) foi adotado nesta pesquisa. Essa metodologia é adequada a esta pesquisa porque apresenta formalismo claro para resolução da análise estática de cadeias cinemáticas, facilidade de inclusão de ações externas adicionais e formulação matricial (WEIHMANN, 2011; PIEREZAN, FREIRE E WEIHMANN, 2012).

A identificação dos elos e juntas do robô humanoide em estudo é apresentada na Figura 21.a, a partir da qual obtém-se o grafo de equilíbrio do humanoide, conforme mostrado na Figura 21.b. As juntas tornam-se arestas no grafo, enquanto os elos tornam-se nós; o elo fixo, representado pelo número 0, é usando como referência para o traço dos cortes de equilíbrio. Como apenas o plano sagital (robô planar) é considerado, as ações em cada uma das juntas podem ser decompostas em duas forças na direção x e z respectivamente e um momento em torno de y. Portanto, nota-se que existem quatro juntas em contato com o meio (juntas A, D, I e L), totalizando 12 ações de contato, nove forças peso dos elos (números) que são consideradas como ações adicionais e, ainda, totalizando 24 ações das oito juntas internas (demais letras) (PIEREZAN, 2013).

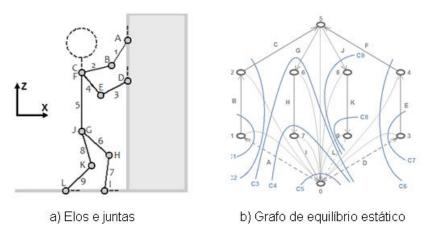


Figura 21 – Equilíbrio estático utilizando o método de Davies. Fonte: adaptado de Pierezan (2013).

Como o robô está sendo estudado no plano, a dimensão do espaço considerado ( $\lambda$ ) é igual a três. Logo, o grau bruto de restrições do mecanismo ( $C_b$ ) é igual a 45 e o grau líquido de restrições ( $C_n$ ) é igual a 18. O número de cortes necessários para incluir todas as arestas é nove (na Figura 21 os cortes são representados pela letra C seguida de um número). Conforme sugerido por Weihmann (2011), as forças peso dos elos são inclusos como ações externas no cálculo do equilíbrio, onde apenas a componente  $F_Z$  gera momento no eixo de referência e a mesma está localizada no centro de massa ( $cm_x, cm_z$ ) do elo. Então, a heliforça do e-ésimo elo é definido pela seguinte matriz:

$$\$_e^E = \begin{Bmatrix} 0\\1\\-cm_x \end{Bmatrix}. \tag{4.1}$$

A matriz das variáveis primárias é então composta pelas componentes das ações conhecidas das juntas e pelas componentes  $F_Z$  dos elos, as quais são calculadas pela multiplicação entre as massas e a aceleração gravitacional. O *i*-ésimo corte de equilíbrio é então descrito da seguinte maneira:

$$C_{i} = \{\$_{\lambda,\lambda k}^{s}\}\{S_{\lambda k,1}\} + \{\$_{\lambda,C_{n}-N_{e}}^{JP}\}\{JP_{C_{n}-N_{e},1}\} + \{\$_{\lambda,N_{e}}^{E}\}\{E_{N_{e},1}\},$$
(4.2)

onde  $\{JP_{C_n-N_e,1}\}$  é a matriz das ações primárias (conhecidas) das juntas,  $\{\$_{\lambda,C_n-N_e}^{JP}\}$  é a matriz de heliforças das mesmas,  $\{E_{N_e,1}\}$  é a matriz de ações dos elos (também conhecidas) e  $\{\$_{\lambda,N_e}^{E}\}$  é a matriz das heliforças dos mesmos. Se o elo não faz parte do corte, os valores são substituídos por zero na matriz.

Para solucionar o equilíbrio estático, para cada corte de equilíbrio as matrizes das componentes primárias e de suas respectivas heliforças são definidas, respectivamente, como:

$${P_{C_{n},1}} = ({JP_{C_{n}-N_{e},1}}; {E_{N_{e},1}})^{T}$$
e (4.3)

$$\{\$_{\lambda,C_n}^p\} = (\{\$_{\lambda,C_n-N_e}^{JP}\}; \{\$_{\lambda,N_e}^{E}\}). \tag{4.4}$$

A estratégia adotada para a definição da estática consiste na utilização dos 4 torques das juntas de contato como variáveis primárias sendo que esses são

considerados nulos (PIEREZAN, FREIRE E WEIHMANN, 2012) e das nove componentes resultantes das forças peso dos elos, cujos valores são sempre conhecidos (desde que as massas sejam constantes). As cinco variáveis primárias restantes são advindas dos torques de juntas internas arbitrárias do humanoide.

# 4.2 MODELAGEM DO PROBLEMA DE OTIMIZAÇÃO

Nesta seção são descritos os objetivos, os parâmetros e as restrições do problema de otimização multiobjetivo adotados na presente pesquisa.

### 4.2.1 Objetivos

Os objetivos do problema são maximizar a força horizontal, ou seja, obter o maior valor para a soma das forças horizontais das juntas de contato e, também, reduzir a requisição de torque da tarefa para determinada configuração. Para facilitar o processo de otimização e também a análise de desempenho das metaheurísticas, a maximização da força total é convertida à minimização do inverso da mesma, enquanto que a redução da requisição de torque ocorre de maneira direta:

$$f_1(\vec{x}) = \frac{1}{\sum_{(j \in \varphi)} |F_{x_j}|}$$
 e (4.5)

$$f_2(\vec{x}) = \frac{\sum_{(j \in \sigma)} |\tau_j|}{\sum_{(j \in \sigma)} |\tau_j^{max}|}, \tag{4.6}$$

onde  $\sigma$  é o conjunto de todas as juntas do humanoide,  $\varphi$  é o conjunto das juntas de contato superior,  $Fx_j$  é a força horizontal da j-ésima junta,  $\tau_j$  é o torque da j-ésima junta e  $\tau_j^{max}$  é o torque máximo da j-ésima junta. Essas forças e torques (com exceção dos máximos) são tratados como variáveis secundárias no cálculo do equilíbrio estático e, portanto, são variáveis de saída do método de Davies.

### 4.2.2 Parâmetros

As variáveis manipuladas no processo de otimização para o problema em estudo são derivadas dos parâmetros necessários para definir a cinemática e a estática do humanoide. Nesta pesquisa, o tronco do humanoide é posicionado através do ponto central  $(x_5, z_5)$  e do ângulo de inclinação  $(\theta)$ . Os pontos de contato

com o meio, por outro lado, são definidos diretamente pelas componentes ( $z_A$ ,  $z_D$ ,  $x_I$  e  $x_L$ ) combinadas às componentes do solo e da posição do objeto. Portanto, as sete variáveis mencionadas precisam ser definidas para obter a configuração do humanoide no plano.

Quanto à estática, cinco torques são utilizados como variáveis primárias no método de Davies:  $\tau_C$ ,  $\tau_F$ ,  $\tau_G$ ,  $\tau_J$  e  $\tau_K$ . Essa é escolha é conveniente, pois os limites de torque são conhecidos, facilitando a utilização dos mesmos no processo de otimização. Com exceção dos torques nas juntas de contato que são nulos, os demais esforços são variáveis secundárias. Então, somando o número de variáveis da cinemática e da estática, define-se que a dimensão do problema é igual a 12. O espaço de busca das variáveis mencionadas é mostrado na Tabela 2, cujos valores advém de Pierezan (2013).

Tabela 2 – Espaço de busca das variáveis de decisão.

Variável	Descrição (unidade)	Espaço de busca
$\mathbf{z}_{A}$	Contato z do punho 1 (m)	[2,2311; 4,2069]
$z_D$	Contato z do punho 2 (m)	[2,2311; 4,2069]
$x_I$	Contato x do tornozelo 1 (m)	[-0,8800; 1,0389]
$x_L$	Contato x do tornozelo 2 (m)	[-2,6389; -0,7200]
$x_5$	Centro do tronco em x (m)	[-0,3000; 0,2500]
$z_5$	Centro do tronco em z (m)	[2,1250; 2,1750]
$oldsymbol{ heta}$	Inclinação do tronco (rad.)	$[\pi/3;\pi/2]$
$ au_{\it C}$	Torque do ombro 1 (Nm)	[-20; 20]
$ au_F$	Torque do ombro 2 (Nm)	[-20; 20]
$ au_G$	Torque do quadril 1 (Nm)	[-40; 40]
$ au_J$	Torque do quadril 2 (Nm)	[-40; 40]
$ au_K$	Torque do joelho 2 (Nm)	[-45; 45]

Fonte: (PIEREZAN, 2013).

### 4.2.3 Restrições

Para um robô humanoide, assim como para um ser humano, devem ser respeitadas as limitações físicas relacionadas às suas características e também em relação ao contato com o meio. A primeira restrição do problema está relacionada aos membros do robô, os quais possuem dimensões pré-definidas e, consequentemente, possuem uma área de alcance conhecida. Logo, a seguinte condição geométrica deve ser atendida para garantir a existência de contato entre o robô e o meio:

$$g_1(\vec{x}): d_1 + d_2 - \sqrt{(x_c - x_t)^2 + (z_c - z_t)^2} \ge 0,$$
 (4.7)

onde  $d_1$  e  $d_2$  são os comprimentos dos elos que compõe o membro,  $x_c$  e  $z_c$  são as coordenadas da junta de contato com o meio e  $x_t$  e  $z_t$  da junta em contato com o tronco (ombro ou quadril). Essa restrição deve ser aplicada a todos os membros do robô.

Há ainda os torques limites das juntas, os quais, em módulo, não podem exceder o valor máximo suportado fisicamente. Caso isso aconteça, o robô não será capaz de atingir o equilíbrio e isso impede a realização de uma determinada tarefa (PIEREZAN, FREIRE E WEIHMANN, 2012). Então, a seguinte restrição deve ser atendida:

$$g_2(\vec{x}): \left(\tau_i^{max} - \tau_i\right) \ge 0, \ \forall j \in \gamma, \tag{4.8}$$

onde  $\tau_j^{max}$  é o limite de torque na j-ésima junta,  $\tau_j$  é o torque calculado nessa mesma junta e  $\gamma$  é o conjunto das juntas internas ao robô, ou seja,  $\gamma = \{j : j \in \sigma \ e \ j \notin \rho\}$ , onde  $\sigma$  representa o conjunto de todas as juntas do robô e  $\rho$  representa o conjunto das juntas de contato com o meio.

Para que o robô seja capaz de realizar força horizontalmente, é necessário que a força de atrito existente no contato com o solo seja suficiente para evitar o deslizamento durante a tarefa. O mesmo deve acontecer no contato dos membros superiores com o meio. Essa condição é verificada através do cálculo do coeficiente de atrito no contato, o qual deve ser menor ou igual ao coeficiente de atrito estático máximo, que depende exclusivamente dos materiais do robô e do meio. Logo:

$$g_3(\vec{x}): \left(\mu_j^{max} - \mu_j\right) \ge 0, \ \forall j \in \rho, \tag{4.9}$$

onde  $\mu_j^{max}$  é a rugosidade disponível no contato da j-ésima junta e  $\mu_j$  é o coeficiente de atrito resultante do equilíbrio estático. Para fins comparativos, o coeficiente de atrito limite adotado é  $\mu_j^{max} = 0.5 \ \forall \ j \in \rho$  (PIEREZAN, FREIRE E WEIHMANN, 2012). Além disso, é indispensável garantir que nenhuma das juntas esteja posicionada através dos contatos, situação que é fisicamente impossível, ou seja:

$$g_4(\vec{x}): (z_j - z_{solo}) \ge 0, \ \forall j \in \gamma, \tag{4.10}$$

$$g_5(\vec{x}): (x_{obj} - x_j) \ge 0, \ \forall j \in \gamma, \tag{4.11}$$

onde  $z_j$  e a coordenada z da j-ésima junta,  $x_{obj}$  é a coordenada de contato no eixo x e  $x_j$  é a posição da junta j no eixo x. Note que as juntas de contato não são verificadas, pois suas coordenadas são fixadas no contato com o meio, e, portanto, não há risco de assumirem valores indesejados (para essa restrição). Na presente pesquisa, foram adotadas as coordenadas  $z_{solo} = 0$  e  $x_{obj} = 1,5$ .

Quanto ao equilíbrio do humanoide, é necessário observar o posicionamento do seu ZMP. Para que o tombamento do humanoide não aconteça, o ZMP deve estar dentro do polígono de estabilidade, ou seja:

$$g_6(\vec{x}): (ZMP_x - x_{zmp}^{min}) \ge 0 \text{ e}$$

$$g_7(\vec{x}): (x_{zmp}^{max} - ZMP_x) \ge 0,$$
(4.12)

onde  $x_{zmp}^{min}$  e  $x_{zmp}^{max}$  são, respectivamente, a coordenada da junta de contato mais afastada e mais próxima ao objeto.

Como as componentes de força horizontal nos contatos são variáveis secundárias no equilíbrio estático, é possível que as mesmas estejam na direção contrária à desejada. Para evitar isso, tem-se a condição:

$$g_8(\vec{x}): \mathbf{F}_{x,j}, \ \forall \ j \in \varphi \ge 0, \tag{4.13}$$

onde  $F_{x,j}$  é a força horizontal de contato na j-ésima junta. Para cada condição não atendida, um coeficiente de valor elevado é somado aos custos da função objetivo de modo a penalizar a solução, tal que:

$$p(\vec{x}) = w * \sum_{i=1}^{8} g_i(\vec{x}) \ge 0, \tag{4.14}$$

onde w é o fator multiplicativo que amplifica a penalização. Na presente pesquisa, o valor de w foi definido como 10000.

Dessa maneira, os custos encontrados para a função objetivo são escritos como a soma entre custos reais calculados e as penalizações:

$$fobj(\vec{x}) = f(\vec{x}) + p(\vec{x}),$$
 (4.15)

sendo que esse valor elevado deve ser interpretado pelas técnicas de otimização como um resultado indesejado. Como algumas das restrições descritas são

verificadas múltiplas vezes, o número total de restrições verificadas para cada solução é igual a 36.

#### 4.3 DELINEAMENTO EXPERIMENTAL

É importante esclarecer, inicialmente, que os experimentos realizados na presente pesquisa se tratam de simulações computacionais envolvendo algoritmos. Para que tal procedimento experimental seja realizado com sucesso é necessário definir os parâmetros das metaheurísticas e os parâmetros que definem a condução experimental. Esses parâmetros são definidos a seguir.

### 4.3.1 Metaheurísticas e seus parâmetros

Nesta dissertação foram empregadas as metaheurísticas de otimização multiobjetivo NSGA-II, DEMO, MOPSO e MOHS, as quais são bem difundidas na literatura e possuem desempenho comprovado em várias áreas, principalmente em aplicações envolvendo sistemas mecatrônicos (AYALA E COELHO, 2012, FONG, DEB E CHAUDHARY, 2015).

Os parâmetros das metaheurísticas foram definidos conforme os valores encontrados na literatura especializada, sendo configurados da seguinte maneira. Os parâmetros  $N_p$ ,  $P_c$ ,  $\eta$ ,  $P_m$  e  $\eta_m$ , do algoritmo NSGA-II, foram definidos como 100, 0,9, 20, 0,1 e 20, respectivamente (DEB *et al.*, 2002). Para o algoritmo DEMO, os parâmetros N, F e CR foram definidos como 100, 0,5 e 0,3, respectivamente (ROBIČ E FILIPIČ, 2005). Para a metaheurística MOPSO os parâmetros  $N_s$ ,  $\varphi_1$ ,  $\varphi_2$ ,  $v^{max}$  e  $n_h$  foram definidos como 100 (sendo este o limite de armazenamento), 2,05, 2,05, 0,2 e 30 (COELLO COELLO e LECHUGA, 2002; ENGELBRECHT, 2005). Por fim, os parâmetros HMS, HMCR, PAR e FW da metaheurística MOHS foram configurados, respectivamente, com os valores 100, 0,95, 0,1 e 0,01 (RICART *et al.*, 2011).

#### 4.3.2 Parâmetros experimentais

Por se tratar de processos estocásticos (e não determinísticos) é preciso realizar uma série de experimentos e comparar estatisticamente os resultados

obtidos pelas metaheurísticas. Ainda, é importante garantir que a comparação seja justa, ou seja, não favoreça nenhum dos algoritmos.

Com base nisso foram definidos o número de experimentos, o critério de parada de execução das metaheurísticas e a configuração dos estados iniciais de cada rodada de otimização. Segundo Birattari *et al.* (2001), o número exato de experimentos não é implicitamente calculável, porém um número elevado é importante para reduzir a variabilidade dos resultados. O mesmo acontece para o critério de parada dos algoritmos, uma vez que o número de avaliações da função objetivo é distinto para cada metaheurística.

Portanto, baseado nas pesquisas presentes na literatura, os parâmetros foram configurados da seguinte maneira: o critério de parada das metaheurísticas foi definido como o número de avaliações da função objetivo, sendo esse igual a 500000; o número de experimentos foi definido como 30 e as simulações foram executadas com condições iniciais aleatórias independentes (MAHDAVI, SHIRI E RAHNAMAYAN, 2015).

# 4.4 PROCESSO DE OTIMIZAÇÃO

O processo de otimização da presente pesquisa visa a aplicação de múltiplas metaheurísticas a um único problema com múltiplos objetivos. Portanto, o procedimento adotado resume-se à repetição experimental entre uma metaheurística e o problema, tendo como saída de cada experimento um conjunto de soluções e uma respectiva fronteira de Pareto. Isso acontece conforme o pseudocódigo mostrado na Figura 22, onde  $N_m$  é o número de metaheurísticas aplicadas ao problema e  $N_{exp}$  o número de experimentos por metaheurística.

```
1 Definição das N_m metaheurísticas
2 Para n de 1 até N_m
3 Para e de 1 até N_{exp}
4 Define um estado inicial aleatório
5 Aplica a n-ésima metaheurística ao problema
6 Guarda a e-ésima fronteira de Pareto
7 Guarda o e-ésimo conjunto de soluções
8 Fim para
9 Guarda as N_{exp} fronteiras de Pareto
10 Guarda os N_{exp} conjuntos de soluções
11 Fim para
```

Figura 22 – Processo experimental de otimização com múltiplas metaheurísticas. Fonte: o Autor (2016).

Na presente pesquisa, os experimentos são completamente independentes, ou seja, cada rodada de otimização possui um estado inicial aleatório. Essa escolha é feita de modo a atender os requisitos dos testes de significância estatística empregados (DERRAC *et al.*, 2011).

### 4.5 ETAPAS DE ANÁLISE DE RESULTADOS

Conforme os objetivos definidos para a presente pesquisa, a análise dos resultados obtidos pode ser dividida em quatro etapas. Primeiramente, a validação e avaliação individual de cada metaheurística; depois, a comparação de desempenho entre as metaheurísticas; ainda, a sugestão de uma solução conforme um critério e das soluções das extremidades da fronteira de Pareto; e, por fim, a comparação dessas soluções com a literatura.

Os critérios e ferramentas adotadas para cumprir todas as etapas dessa análise são detalhados nas subseções seguintes.

### 4.5.1 Critérios de desempenho

O primeiro critério adotado está relacionado à validação individual de determinada metaheurística e tem como objetivo indicar se a mesma é capaz de prover um conjunto de soluções factíveis. Isso ocorre por meio da representação da fronteira de Pareto, a qual deve conter o máximo de soluções que estejam dentro do espaço de busca das variáveis manipuladas e que não tenham penalizações no domínio dos objetivos.

Quanto à comparação de desempenho entre as metaheurísticas, o objetivo é avaliar a diversidade, a qualidade e a área cobertura das soluções no domínio dos objetivos (ZITZLER *et al.*, 2003). Para isso, foram adotadas as seguintes métricas:

- Número de Soluções Não Dominadas (NSND);
- 2. Distância Euclidiana Média (DEM);
- 3. Hipervolume (HV);
- 4. Espaçamento (E).

Para as métricas DEM, HV e E é recomendado que as fronteiras de Pareto sejam normalizadas no intervalo [0,1]. Assim, evita-se a preferência por algum dos

objetivos, uma vez que os mesmos podem estar em escalas distintas (AYALA, PIEREZAN E COELHO, 2014). Além disso, o ponto de referência adequado para o cálculo do HV é [1,1].

Ainda, para cada uma das fronteiras de Pareto encontradas pelas metaheurísticas, existe uma solução para cada objetivo que contém o menor custo para o mesmo. No caso do problema corrente, existe uma solução que apresenta maior capacidade de força e outra que resulta em menor requisição de torque. Além disso, existe uma solução intermediária que apresenta o melhor compromisso entre ambos os objetivos. Para indicar essas soluções existem alguns critérios, dentre os quais estão a Média Harmônica (AYALA, PIEREZAN E COELHO, 2014), a Média Aritmética e a Distância Euclidiana. Na presente pesquisa o critério adotado é a Distância Euclidiana.

#### 4.5.2 Ferramentas estatísticas

Por se tratar de processos estocásticos, algumas ferramentas estatísticas são de extrema importância para a avaliação de desempenho das metaheurísticas. A primeira análise é a estatística descritiva, sendo considerados os valores mínimo, médio, máximo e o desvio padrão dos critérios de desempenho utilizados. Com essa análise é possível verificar a repetitividade dos resultados encontrados nos experimentos (WEIHMANN, 2011).

Além disso, é interessante analisar a tendência das amostras coletadas, o que pode ser feito por meio do cálculo da mediana. De forma a facilitar a comparação dos resultados, os gráficos de caixa (*boxplot*) de cada metaheurística para cada critério de desempenho são posicionados lado a lado. A configuração adotada para essa análise é: caixa definida entre 25% e 75% (quartis) dos valores e comprimento do bigode (*whisker length*) igual a 1,5 vezes a altura da caixa (MONTGOMERY E RUNGER, 2011).

Embora os gráficos de caixa permitam uma comparação visual entre os resultados, muitas vezes não é possível apontar se há ou não diferença significativa de desempenho. Portanto, um teste de hipótese deve ser empregado; o ideal é um teste multivariável devido à presença de múltiplos critérios de desempenho. Como a distribuição das amostras nem sempre são do tipo normal (em geral, desconhecida)

é conveniente adotar testes não paramétricos. Um teste que está em evidência na literatura é o teste de Friedman, porém o mesmo é indicado apenas na presença de um número elevado de variáveis (critérios de desempenho ou problemas de otimização) (GARCÍA et al., 2010). Logo, o teste ranksum de Wilcoxon é empregado, o qual também é classificado como não paramétrico e avalia um par de amostras a cada vez (DERRAC et al., 2011).

### 4.5.3 Representação gráfica

Para o problema de robótica humanoide adotado nesta pesquisa, a representação gráfica de uma solução consiste no posicionamento do humanoide em contato com o meio no plano bidimensional (PIEREZAN, FREIRE E WEIHMANN, 2012; PIEREZAN, 2013). Dessa maneira, visualiza-se a cinemática dos membros, tanto inferiores quanto superiores, e a inclinação da coluna.

Inclui-se nessa representação, ainda, a projeção no solo do centro de gravidade do humanoide, que é o seu ZMP. Portanto, a condição de tombamento pode ser visualmente verificada. A cinemática e o ZMP das soluções de interesse são comparados aos resultados obtidos por Pierezan, Freire e Weihmann (2012), pois, mesmo que as abordagens de otimização utilizadas sejam distintas, os parâmetros do modelo de humanoide são idênticos.

Os fatores observados nessa análise fornecem uma perspectiva de desempenho da metodologia adotada (desde a modelagem do problema até a inteligência das metaheurísticas) em comparação à inteligência humana. Em outras palavras, pode-se comparar uma determinada solução, mais precisamente o posicionamento do humanoide, com aquilo que o ser humano utiliza no cotidiano.

#### **5 RESULTADOS**

Esta seção contém os resultados obtidos através das simulações computacionais, os quais são organizados no seguinte formato. Os resultados obtidos individualmente pelas metaheurísticas são expostos em primeira instância. Posteriormente, o desempenho de cada metaheurística é comparado em termos dos critérios NSND, DEM, HV e E. As soluções em promissoras são exploradas na sequência, das quais são extraídas informações a respeito da execução da tarefa por parte do humanoide e, por fim, uma comparação com a literatura é apresentada.

#### 5.1 RESULTADOS OBTIDOS INDIVIDUALMENTE

A seguir são expostas e analisadas as fronteiras de Pareto das metaheurísticas. São ainda apresentados os parâmetros e a capacidade de força estática da solução de melhor compromisso encontrada para cada metaheurística.

### 5.1.1 DEMO

Após todos os 30 experimentos, a metaheurística DEMO encontrou um conjunto 291 soluções não dominadas e factíveis, as quais podem ser visualizadas na Figura 23. Nota-se que, embora exista uma pequena lacuna em torno de  $f_2 = 0.65$ , as soluções estão bem distribuídas ao longo da fronteira de Pareto (FP), sendo que os custos de  $f_1$  cobrem o intervalo entre 0,0182 e 0,0494 enquanto os custos de  $f_2$  variam de 0,4653 até 0,8335.

Dentre as soluções da FP, a de melhor compromisso entre os objetivos, conforme o critério da menor distância Euclidiana em relação à origem, apresentou capacidade de força estática igual a 37,85N requisitando 55,61% da capacidade de torque total do humanoide. O posicionamento resultante de tal conjunto de parâmetros é ilustrado na Figura 24, cujos contatos dos membros com o meio encontram-se próximos; os valores exatos dessas coordenadas, utilizadas como parâmetros manipulados no processo de otimização, são  $z_A = 2,2311$ ,  $z_D = 2,2569$ ,  $x_I = -0.5970$  e  $z_L = -0,7305$ . A inclinação encontrada para o tronco é  $\theta = 1,0472$ , ou seja, aproximadamente 60 graus, enquanto que o centro está localizado em  $x_5 = 0,0232$  e  $z_5 = 2,1748$ . As forças horizontais nos contatos superiores são iguais

a  $F_{x_A} = 28,43$  e  $F_{x_D} = 9,42$ ; já as forças verticais nos contatos inferiores são  $F_{z_I} = 58,88$  e  $F_{z_L} = 56,72$ .

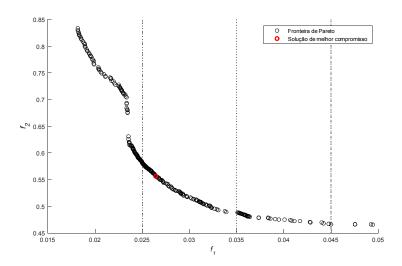


Figura 23 – Fronteira de Pareto da metaheurística DEMO. Fonte: o Autor (2016).

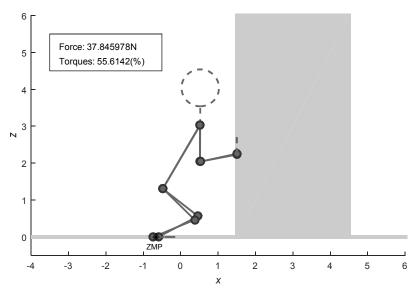


Figura 24 – Posicionamento resultante da solução de melhor compromisso da metaheurística DEMO. Fonte: o Autor (2016).

O ZMP está localizado em  $ZMP_x=-0.6625$ , e, como o mesmo está localizado entre os pontos de contato inferiores, o fator tombamento está descartado para essa solução. Quanto às rugosidades requisitadas para a realização da tarefa, pode-se afirmar que as mesmas são menores do que a rugosidade disponível; nos contatos superiores, os coeficientes calculados  $\mu_A=0.28$  e  $\mu_D=0.41$ ; nos contatos

inferiores, os valores são  $\mu_I=0.29$  e  $\mu_L=0.37$ . Logo, o fator deslizamento também está descartado para essa solução.

Os torques calculados para cada umas das juntas internas do humanoide são mostrados na Tabela 3, na qual os torques utilizados como variáveis de decisão no processo de otimização estão destacados. Nota-se que os joelhos são as juntas que estão saturadas para tal configuração, bem como um dos ombros. Por outro lado, no quadril os esforços são mínimos, quase nulos.

Tabela 3 – Torques calculados para as juntas internas da solução de melhor compromisso: DEMO.

Torque	Nm	%
$ au_B$	8,40	83,97
$ au_{\it C}$	-20,00	100,00
$ au_E$	1,01	10,07
$ au_F$	-8,41	42,07
$ au_G$	-0,08	0,21
$ au_H$	45,00	100,00
$ au_J$	0,01	0,03
$ au_K$	45,00	100,00

Fonte: o Autor (2016).

#### 5.1.2 MOHS

A metaheurística MOHS encontrou um conjunto de 137 soluções não dominadas, cujos custos cobrem o intervalo [0,0240; 0,0400] para  $f_1$  e [0,4980; 0,6315] para  $f_2$ , como pode ser visto na Figura 25. Nota-se ainda que as soluções não estão bem distribuídas na fronteira, visto que há uma lacuna considerável em torno de  $f_1$  = 0,037 e as soluções estão claramente mais concentradas no centro da fronteira.

A solução de melhor compromisso, localizada bem ao centro da fronteira, apresentou capacidade de força estática igual a 35,05N, sendo  $F_{x_A}=21,12$  e  $F_{x_D}=13,94$ , requisitando 53,17% da capacidade de torque total do humanoide. O posicionamento do humanoide é de membros próximos nos contatos, como pode ser visto na Figura 26, sendo que as coordenadas dos mesmos são  $z_A=2,2311$ ,  $z_D=2,2527,\ x_I=-0,4499$  e  $z_L=-0,7207,\ a$  inclinação da coluna é  $\theta=1.0472$  (aproximadamente 60 graus) e o centro do tronco está em  $x_5=0,0610$  e  $z_5=2,1734$ . Como o ZMP está localizado em  $ZMP_x=-0.5827,\ a$  hipótese de tombamento é descartada. A hipótese de deslizamento também é descartada, uma

vez que as rugosidades calculadas são equivalentes a  $\mu_A=0.30\,$  e  $\mu_D=0.46;$  nos contatos superiores, e  $\mu_I=0.23$  e  $\mu_L=0.38$  nos contatos com o solo.

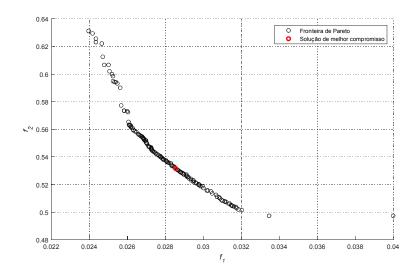


Figura 25 – Fronteira de Pareto da metaheurística MOHS. Fonte: o Autor (2016).

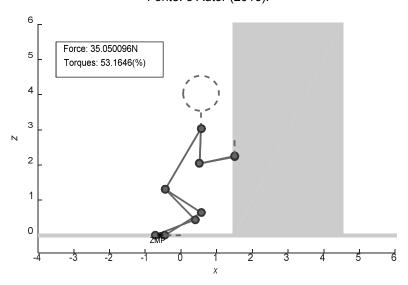


Figura 26 – Posicionamento resultante da solução de melhor compromisso da metaheurística MOHS. Fonte: o Autor (2016).

Os torques calculados para as juntas internas são mostrados na Tabela 4, sendo que a junta de um dos joelhos está saturada e a do outro está próxima da saturação. Com exceção do quadril, no qual ambas as juntas apresentam valores quase nulos, as demais juntas possuem valores intermediários. As juntas destacadas são aquelas utilizadas como variáveis de decisão no processo de otimização.

Tabela 4 – Torques calculados para as juntas internas da solução de melhor compromisso: MOHS.

Torque	Nm	%
$ au_B$	5,40	54,04
$ au_{\it C}$	-15,33	76,67
$ au_E$	4,46	44,59
$ au_F$	-9,15	45,75
$ au_G$	-0,01	0,02
$ au_H$	42,89	95,31
$ au_J$	-0,03	0,08
$ au_K$	45,00	100,00

Fonte: o Autor (2016).

### 5.1.3 MOPSO

A MOPSO apresentou uma FP com 117 soluções não dominadas após os 30 experimentos, conforme mostra a Figura 27, cujas soluções estão parcialmente bem distribuídas; há algumas lacunas e a maioria das soluções está concentrada no centro. Entretanto, os custos de  $f_1$  variam de 0,0185 até 0,0657 e os custos de  $f_2$  começam em 0,4619 e chegam até 0,9208.

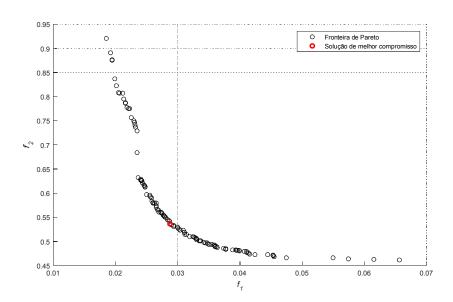


Figura 27 – Fronteira de Pareto da metaheurística MOPSO. Fonte: o Autor (2016).

A solução de melhor compromisso encontrada apresentou capacidade de força estática igual a 34.77N requisitando 53,62% da capacidade de torque total do humanoide (conforme parciais expostas na Tabela 5), com a configuração ilustrada na Figura 28. Os pontos de contato superiores são  $z_A = 2,2311$  e  $z_D = 2,2527$ ,

enquanto que os pontos de contato com o solo são  $x_I = -0.5412$  e  $z_L = -0.7269$ , o centro do tronco localizado em  $x_5 = -0.0080$  e  $z_5 = 2.1566$  e a inclinação da coluna é  $\theta = 1.0507$  (aproximadamente 60,2 graus).

O ZMP, por estar localizado em  $ZMP_x=-0.6328$ , garante que não haverá tombamento, enquanto que as rugosidades requisitadas  $\mu_A=0.49$ ,  $\mu_D=0.26$ ,  $\mu_I=0.25$  e  $\mu_L=0.36$  garantem fixação em todos os contatos com o meio e, portanto, garantem que não haverá deslizamento. Com exceção às juntas dos joelhos, os torques calculados para as demais juntas internas apresentam valores não muito próximos à saturação, conforme descrito na Tabela 5. Os esforços são mínimos em ambas as juntas do quadril.

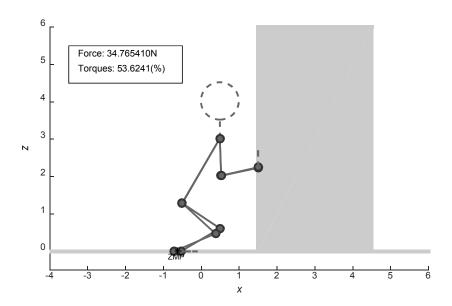


Figura 28 – Configuração resultante da solução de melhor compromisso da metaheurística MOPSO. Fonte: o Autor (2016).

Tabela 5 – Torques calculados para as juntas internas da solução de melhor compromisso: MOPSO.

Torque	Nm	%
$ au_B$	7,33	73,27
$ au_{\it C}$	-10,62	53,12
$ au_E$	3,42	34,16
$ au_F$	-13,96	69,79
$ au_G$	0,21	0,54
$ au_H$	43,16	95,92
$ au_J$	-0,16	0,41
$ au_K$	44,47	98,82

Fonte: o Autor (2016).

#### 5.1.4 NSGA-II

Após todos os 30 experimentos, a metaheurística NSGA-II encontrou um conjunto 221 soluções não dominadas e factíveis, as quais podem ser visualizadas na Figura 29. Nota-se que, embora exista uma pequena lacuna em torno de  $f_2=0,65$ , outra entre  $f_1=0,035$  e  $f_1=0,04$  e outra entre (aproximadamente)  $f_2=0,72$  e  $f_2=0,74$ , as soluções estão, de maneira geral, bem distribuídas ao longo da FP. Considerando toda a fronteira, os custos de  $f_1$  cobrem o intervalo entre 0,0189 e 0,0389 enquanto os custos de  $f_2$  variam de 0,4768 a 0,8488.

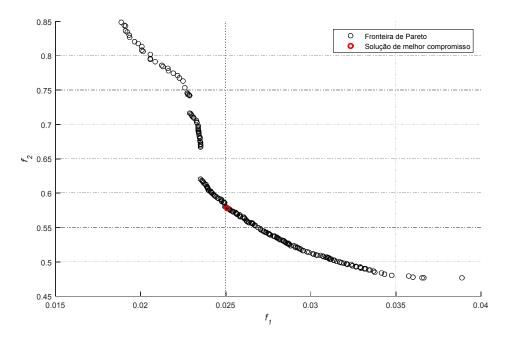


Figura 29 – Fronteira de Pareto da metaheurística NSGA-II. Fonte: o Autor (2016).

A solução de melhor compromisso apresentou capacidade de força estática igual a 39,90N, onde  $F_{x_A}=28,40$  e  $F_{x_D}=11,50$ , requisitando 57,82% da capacidade de torque total do humanoide e com a configuração ilustrada na Figura 30. Para essa configuração, os pontos de contato resultantes são:  $z_A=2,2311, z_D=2,2479, x_I=-0,8800$  e  $z_L=-1,1239$ ; o tronco está localizando em  $x_5-0,2714, z_5=2,1750$  com inclinação  $\theta=1,0472$  (aproximadamente 60 graus). O ZMP por estar localizado em  $ZMP_x=-0,9979$  garante o não tombamento do humanoide, enquanto que os coeficientes de atrito calculados,  $\mu_A=0,35, \mu_D=0,29, \mu_I=0,28$  e  $\mu_L=0,42$ 

garantem que não ocorra o deslizamento em nenhum dos contatos, tanto nos superiores, quanto nos inferiores.

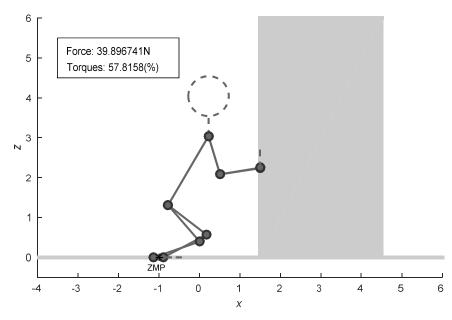


Figura 30 – Configuração resultante da solução de melhor compromisso da metaheurística NSGA-II. Fonte: o Autor (2016).

O conjunto dos torques das juntas internas está dentro das restrições físicas do problema, como pode ser visto na Tabela 6, na qual nota-se, ainda, que os dois joelhos e um dos ombros estão muito próximos da saturação. No quadril, entretanto, os torques resultantes são praticamente nulos, indicando que quase não há carga em tais juntas.

Tabela 6 – Torques calculados para as juntas internas da solução de melhor compromisso: NSGA-II.

Torque	Nm	%
$ au_B$	9,08	90,81
$ au_{\it C}$	-19,54	97,71
$ au_E$	0,39	3,93
$ au_F$	-13,86	69,31
$ au_G$	-0,05	0,12
$ au_H$	44,97	99,93
$ au_J$	-0,08	0,20
$ au_K$	45,00	100,00

Fonte: o Autor (2016).

# 5.2 COMPARAÇÃO DE DESEMPENHO ENTRE AS METAHEURÍSTICAS

Os conjuntos de soluções de todas as metaheurísticas são sobrepostas para fins de comparação visual e os desempenhos são comparados em termos das fronteiras de Pareto e dos critérios NSND, DEM, HV e E. Para as métricas DEM, HV e E as fronteiras foram normalizadas no intervalo [0,1] para não existir preferência por algum dos objetivos.

#### 5.2.1 Fronteiras de Pareto

As metaheurísticas DEMO, MOHS, MOPSO e NSGA-II encontraram, respectivamente, 291, 137, 117 e 221 soluções não dominadas após os 30 experimentos independentes realizados. O conjunto de todas essas soluções é ilustrado na Figura 31, na qual os eixos de  $f_1$  e  $f_2$  estão em escala logarítmica para facilitar a visualização das soluções que se sobrepõe. A partir dessas informações, as seguintes observações são válidas:

- Distinções a parte, todas as metaheurísticas encontraram um conjunto de soluções factíveis capazes de solucionar presente o problema de otimização.
- A metaheurística DEMO encontrou o maior número de soluções não dominadas após os 30 experimentos realizados, seguida pela NSGA-II, MOHS e MOPSO;
- 3) A lacuna em torno de  $f_2 = 0.65$  existe em todas as fronteiras de Pareto, indicando ser um provável fator relacionado ao problema de otimização;
- 4) Com base na observação anterior, supõe-se uma divisão da FP em duas partes: antes e depois da lacuna; na porção superior, nota-se uma vantagem da DEMO em relação às demais metaheurísticas; além disso, nota-se a ausência de soluções encontradas pela MOHS nessa região; na porção inferior, por outro lado, nota-se maior concentração de soluções, por parte de todas as metaheurísticas, sendo que, na região central, as soluções da MOPSO e MOHS aparentemente são dominadas pelas soluções de NSGA-II e DEMO; na região da extremidade, nota-se a ausência de soluções da MOHS e NSGA-II, sendo essa uma região mais

- explorada pela DEMO e MOPSO, com certa vantagem da MOPSO, que aparece por maior extensão com relação à DEMO;
- 5) Na parcela logo acima à lacuna em questão, há uma região em que as fronteiras se sobrepõe de maneira quase que vertical; nessa parcela, que se estende até, aproximadamente,  $f_2 = 0.7$ , há um aumento significativo no custo  $f_2$  sem que haja uma redução proporcional do custo  $f_1$ ; logicamente, a relação entre custo e benefício dessa região não é interessante para o problema;
- 6) Com exceção da extremidade inferior do gráfico, a maioria das soluções da metaheurística MOPSO aparenta estar dominada pelas demais metaheurísticas;
- 7) A metaheurística MOHS apresenta soluções apenas na região central do gráfico, sendo que, em termos de  $f_2$ , o valor mínimo explorado está relativamente distante das demais metaheurísticas e
- 8) A DEMO e a NSGA-II apresentam comportamento ligeiramente similar, com duas principais diferenças: primeiramente, a DEMO domina a NSGA-II na maior parte da parcela superior do gráfico; depois, a DEMO ocupa uma maior extensão na extremidade inferior do gráfico.

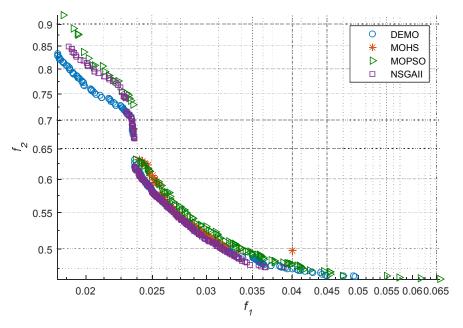


Figura 31 – Conjunto das fronteiras de Pareto encontradas pelas metaheurísticas. Fonte: o Autor (2016).

Com base nas observações citadas, a DEMO e a NSGA-II apresentaram tênue vantagem com relação às demais metaheurísticas: cada uma encontrou um valor próximo ou até maior que o dobro de soluções em relação à MOHS e MOPSO e apresentaram uma ocupação mais interessante no domínio dos objetivos.

### 5.2.2 Métricas de desempenho

Devido à complexidade do problema de otimização em termos de restrições, em alguns experimentos as metaheurísticas não foram capazes de encontrar nem ao menos uma solução factível. Nesses casos, o que aconteceu foi a obtenção de uma FP local com todas as soluções penalizadas em ambos os objetivos, vide exemplo exposto na Figura 32. Esse problema ocorreu em 6,7%, 60%, 13,3% e 50% dos experimentos para as metaheurísticas DEMO, MOHS, MOPSO e NSGA-II, respectivamente.

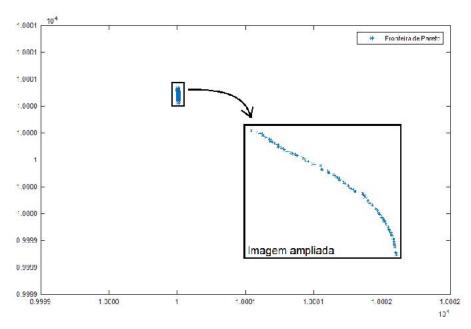


Figura 32 – Exemplo de fronteira de Pareto com todas as soluções penalizadas. Fonte: o Autor (2016).

Visando simplesmente a análise de desempenho das metaheurísticas, poder-se-ia considerar tais experimentos, entretanto a decisão tomada para a presente análise foi atribuir a esses casos o pior valor possível para cada uma das métricas:

- a) Para o NSND, o pior valor é 0;
- b) Para a DEM a pior situação seria se todas as soluções estivessem no ponto mais distante da origem, que, considerando a normalização realizada, seria [1,1]. Logo, o valor atribuído é  $\sqrt{2}$ ;
- c) Para o HV, a situação menos desejada é a não existência de uma área de expansão da FP, que resulta no valor 0 e
- d) Por fim, o pior E acontece quando todas as soluções possuem mesma localização e resulta em valor 0.

Ainda, na existência de apenas uma solução factível, os valores citados são aplicados, com exceção do NSND que recebe valor 1. A prova disso é que, normalizando tal solução, a mesma estaria localizada em [1,1]. E, assim, HV seria igual a 0, a DEM em relação à origem seria  $\sqrt{2}$  e o E igual a 1 (única solução).

Os gráficos de caixa das métricas é então ilustrado na Figura 33, no qual os traços horizontais em vermelho são as medianas, os símbolos '+' em vermelho são os *outliers*, os traços horizontais em preto indicam o final do conjunto de amostras e as caixas, nos casos de presença das mesmas, são ilustradas em azul.

Na Figura 33.a são comparadas as caixas relativas à métrica NSND e podese notar, inicialmente, que a DEMO encontrou na maioria dos experimentos o número máximo de soluções não dominadas. Porém, há um *outlier* localizado em 0 indicando que houve experimentos com o problema citado anteriormente. O mesmo acontece com a MOPSO, entretanto sua mediana está pouco abaixo da DEMO, com valores em torno dos 50 e 80. A NSGA-II apresenta valores entre 0 e 90, sendo que a respectiva mediana está localizada exatamente ao meio, sem apresentar tendência significativa. Por fim, a MOHS encontrou poucas soluções não dominadas na maioria dos casos, com exceção de alguns experimentos que chegaram até à 100, mas estes são *outliers*.

Já na Figura 33.b são comparadas as caixas relativas à métrica DEM, na qual nota-se um comportamento semelhante entre as caixas da DEMO e MOPSO. Entretanto, a MOPSO apresenta mediana abaixo (e, portanto, mais bem localizada) em relação à DEMO. A NSGA-II apresenta, novamente, uma caixa que se estende por boa parte do gráfico, sendo que a mediana acusa pequena tendência para cima. A MOHS alcançou poucas vezes resultados satisfatórios, sendo que os mesmos são

tratados como *outliers*; a mediana está sobre o valor máximo atribuído aos experimentos que não convergiram.

Os gráficos de caixas do HV são mostrados na Figura 33.c, sendo estes muito semelhantes à DEM: DEMO e MOPSO com caixas pequenas e bem localizadas, NSGA-II ocupando boa parte do gráfico e MOHS apenas com alguns experimentos bem sucedidos. O mesmo comportamento das caixas acontece para a métrica E, como pode ser visto na Figura 33.d, sendo que, aparentemente, a caixa da DEMO é menor com relação à MOPSO.

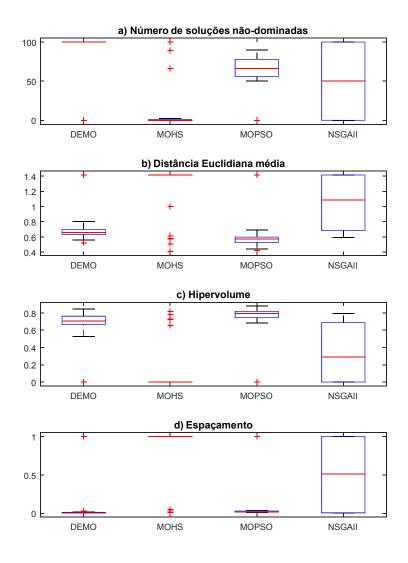


Figura 33 – Gráfico de caixa das métricas empregadas. Fonte: o Autor (2016).

Para uma observação mais precisa dos valores encontrados pelas metaheurísticas, a Tabela 7 contém a estatística descritiva dos resultados dessas métricas em termos de valores mínimos, médios, máximos e desvio padrão. Os piores resultados estão sublinhados, os quais são consequência dos experimentos malsucedidos, enquanto que os melhores valores obtidos para cada umas das métricas estão destacados em preto.

Tabela 7 – Estatística descritiva dos resultados obtidos pelas metaheurísticas

Métrica	Metaheurística	Mínimo	Média	Máximo	Desvio Padrão
	DEMO	0,0000	93,3333	100,0000	25,3708
NSND	MOHS	0,0000	15,4333	100,0000	34,8105
NSND	MOPSO	0,0000	60,2667	90,0000	26,0185
	NSGAII	0,0000	50,0000	100,0000	50,8548
	DEMO	0,5227	0,7053	<u>1,4142</u>	0,2023
DEM	MOHS	0,4062	1,2541	<u>1,4142</u>	0,3364
DEIVI	MOPSO	0,4220	0,6671	<u>1,4142</u>	0,3035
	NSGAII	0,5910	1,0437	<u>1,4142</u>	0,3783
	DEMO	0,0000	0,6673	0,8427	0,1952
HV	MOHS	0,0000	0,1235	0,8142	0,2818
ПV	MOPSO	0,0000	0,6911	0,8786	0,2793
	NSGAII	0,0000	0,3480	0,7901	0,3562
	DEMO	0,0057	0,0772	<u>1,0000</u>	0,2509
E	MOHS	0,0100	0,8377	<u>1,0000</u>	0,3691
	MOPSO	0,0106	0,1519	<u>1,0000</u>	0,3384
	NSGAII	0,0059	0,5054	<u>1,0000</u>	0,5030

Fonte: o Autor (2016).

Através da Tabela 7 pode-se dizer que a DEMO apresenta melhor desempenho para as métricas NSND e E. Por outro lado, a MOPSO é melhor em termos de média nas métricas DEM e HV. A MOHS, embora tenha executado poucos experimentos bem-sucedidos, apresentou o melhor valor mínimo para a métrica DEM.

Para averiguar se as diferenças de desempenho são significantes, o teste ranksum de Wilcoxon foi empregado, comparando os algoritmos individualmente. Seja a hipótese  $h_0$  de que as amostras pertencem à mesma população e a hipótese alternativa  $h_1$  de que as amostras pertencem a populações distintas, a Tabela 8 expõe os resultados dos testes, sendo que os valores destacados representam a hipótese  $h_1$  (portanto, diferença significativa) para um nível de significância  $\alpha = 0.01$ .

Para a métrica NSND, pode-se notar que há diferença significativa entre a DEMO e todas as demais metaheuristicas, enquanto que há empate entre MOHS e NSGA-II e ainda entre MOPSO e NSGA-II. Nesse caso, é conveniente assumir empate entre MOHS e MOPSO. Como o valor médio para a DEMO é superior às demais e há diferença significativa nas amostras, pode-se dizer que a mesma é superior às demais nesse critério.

No quesito DEM, há apenas um empate entre MOHS e NSGA-II, enquanto que a hipótese  $h_0$  é recusada para todas as comparações das metaheurísticas MOPSO e DEMO. Nesse caso, pode-se dizer que a MOPSO é superior às demais pois apresenta melhor valor médio, enquanto que a DEMO fica como a segunda melhor por ter apresentado a segunda melhor média. A mesma análise é válida para o HV. Em termos da métrica E, a hipótese nula  $h_0$  não é recusada para o teste entre MOPSO e NSGA-II. Para a DEMO e a MOHS, todos os testes recusam a hipótese nula, indicando diferença significativa nas amostras. Como a DEMO apresenta melhor valor médio, pode-se dizer que seu desempenho é superior em relação às demais.

Tabela 8 – Significâncias dos testes de Wilcoxon entre as metaheuristicas.

NSND	DEMO	MOHS	MOPSO	NSGA-II
DEMO				
MOHS	2,6494E-09			
MOPSO	8,1565E-10	1,3553E-04		
NSGA-II	2,2979E-04	6,5097E-02	6,5496E-01	
DEM	DEMO	MOHS	MOPSO	NSGA-II
DEMO				
MOHS	8,5883E-06			
MOPSO	4,1903E-04	1,3833E-06		
NSGA-II	4,7946E-04	6,4516E-02	3,6623E-07	
HV	DEMO	MOHS	MOPSO	NSGA-II
DEMO				
MOHS	2,7389E-07			
MOPSO	2,3683E-03	4,4967E-08		
NSGA-II	6,3268E-04	1,7355E-02	7,9954E-07	
E	DEMO	MOHS	MOPSO	NSGA-II
DEMO				
MOHS	2,0542E-09			
MOPSO	3,0599E-06	1,0954E-06		
NSGA-II	7,2658E-03	1,9246E-03	7,6954E-01	

Fonte: o Autor (2016).

Computando essas informações em formato de ranqueamento, monta-se uma tabela de colocação geral das metaheurísticas, sendo que, em caso de empate, os *rankings* são divididos (semelhante ao teste *ranksum* de Wilcoxon). Com base nos resultados desse ranqueamento, mostrado na Tabela 9, pode-se afirmar que a metaheurística DEMO obteve melhor desempenho em relação às demais, somando 6 ao seu *ranking* agregado. Logo em seguida, a MOPSO com *ranking* 7,8 ocupa a segunda colocação. A NSGA-II ocupa a terceira colocação com 12,8 e, finalizando o *ranking*, a MOHS obteve 14,3.

Tabela 9 – Ranqueamento final das metaheurísticas conforme as métricas de desempenho

Métrica	DEMO	MOHS	MOPSO	NSGA-II
NSND	1	3,3	3,3	3,3
DEM	2	3,5	1	3,5
HV	2	3,5	1	3,5
E	1	4	2,5	2,5
SOMA	6	14,3	7,8	12,8

Fonte: o Autor (2016).

#### 5.2.3 Fronteira única

Na análise das métricas de desempenho apresentadas anteriormente, os experimentos cujas fronteiras de Pareto eram compostas apenas por soluções penalizadas acabaram gerando alguns problemas. Para contornar essa situação, foi mantida apenas uma fronteira filtrada com as soluções não dominadas dentre todas as metaheurísticas, com o objetivo de comparar a qualidade das soluções obtidas. Conforme ilustrado na Figura 34, essa fronteira é composta por 301 soluções, sendo que 49,5017% das mesmas foram encontradas pela NSGA-II, 48,5050% pela DEMO, 1,3289% pela MOPSO e 0,6645% pela MOHS.

Portanto, as metaheurísticas DEMO e NSGA-II ocupam, juntas, aproximadamente 98% de toda a FP, sendo que as soluções da NSGA-II se encontram bem centralizadas e da DEMO mais distribuídas nas extremidades. Cruzando essas informações com os resultados das métricas de desempenho (Figura 33 e Tabela 7, Tabela 8 e Tabela 9), pode-se fazer as seguintes observações:

a) Considerando as métricas, a MOPSO é igual ou superior em todos os valores médios em relação à NSGA-II, sendo seu ranking final muito

- melhor do que a NSGA-II; já na FP filtrada, a NSGA-II é extremamente superior em relação à MOPSO;
- b) Nas métricas, a MOPSO é superior nas médias em relação à DEMO em DEM e HV, sendo seu ranking final próximo à DEMO; já na fronteira filtrada, a DEMO extremamente superior em relação à MOPSO;
- c) Nas métricas, a MOHS apresentou os piores valores médios em todos os critérios, obtendo sempre o pior ranking ou de maneira isolada ou por meio de empate; na FP filtrada, MOHS foi a que menos contribuiu com soluções;
- d) Os testes de significância apontam diferença em todas as comparações entre DEMO e NSGA-II, sendo que no final há uma diferença notável nos rankings dessas duas metaheurísticas; já na FP, a porcentagem de soluções fornecidas por ambas é muito próxima, sendo que há uma sutil superioridade por parte da NSGA-II e
- e) No ranqueamento final das métricas, a sequência da melhor para a pior é: DEMO, MOPSO, NSGA-II e MOHS; na FP filtrada, essa sequência torna-se: NSGA-II, DEMO, MOPSO e MOHS.

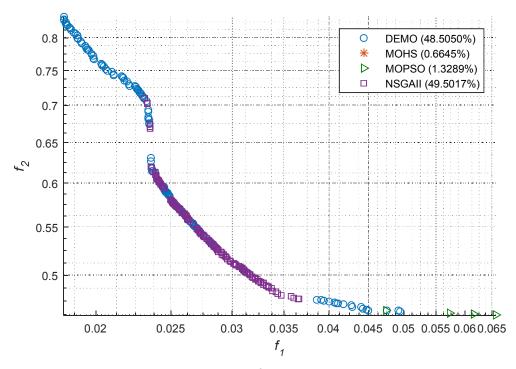


Figura 34 – Fronteira de Pareto filtrada de todas as metaheurísticas. Fonte: o Autor (2016).

### 5.3 COMPARATIVO ENTRE AS SOLUÇÕES PROMISSORAS

Dentre as inúmeras soluções para o problema, algumas são exploradas detalhadamente a fim de entender como os parâmetros influenciam na capacidade de força e na requisição de torque do humanoide. A seguir estão essas soluções e os detalhes pertinentes à tal análise.

### 5.3.1 Soluções promissoras

A partir da FP filtrada após os 30 experimentos de todas as metaheurísticas são extraídas três soluções de maior relevância para a análise. A primeira é a soluções de melhor compromisso e as outras duas são as soluções das extremidades da fronteira, uma que apresenta maior força estática e outra que resulta em menor requisição de torque total.

Além dessas três soluções, a solução encontrada por Pierezan (2013) é inclusa na análise. Tal solução foi obtida por meio de uma otimização global da capacidade de força estática usando a metaheurística Evolução Diferencial rand/1/bin com  $N_P = 120$ , F = 0.5, CR = 0.9 e 120000 avaliações da função objetivo, sendo a modelagem cinemática, estática, de contato com o meio e das restrições similares ao presente documento.

As quatro soluções descritas estão destacadas na FP ilustrada na Figura 35, na qual os eixos estão ambos em escala logarítmica para facilitar a visualização das soluções. Nota-se que a solução de Pierezan (2013) poderia compor a FP apresentada, uma vez que não é dominada por nenhuma das demais soluções e tampouco as domina.

Por meio da solução de Pierezan (2013) pode-se verificar a região que não foi explorada pelas metaheuristicas. Na Figura 35, nota-se uma lacuna entre a solução de maior força estática encontrada pela DEMO e a solução da literatura. A mesma análise poderia ser feita na outra extremidade da FP, porém não há resultados da otimização da requisição de torque na literatura.

As informações detalhadas a respeito das soluções promissoras estão na subseção a seguir.

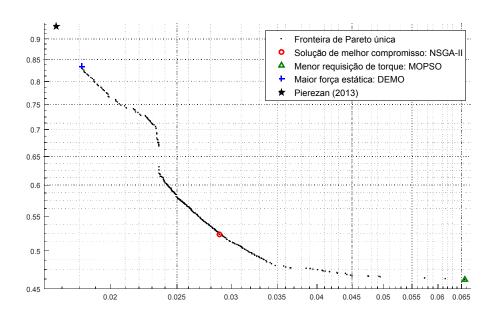


Figura 35 – Fronteira de Pareto filtrada e soluções destacadas. Fonte: o Autor (2016).

### 5.3.2 Comparação entre as soluções

As soluções ditas promissoras são comparadas em termos dos parâmetros geométricos, da distribuição de forças, conjunto de torques resultantes, rugosidades requisitadas e posicionamento do ZMP. O conjunto de todas essas variáveis resulta nos custos dos objetivos de otimização, os quais também são comparados na sequência. As configurações finais dessas soluções são mostradas nas Figura 36, Figura 37, Figura 38 e Figura 39 para a solução de menor requisição de torque, a de melhor compromisso entre os objetivos, a de maior capacidade de força estática e a de Pierezan (2013), respectivamente.

As variáveis relevantes são expostas de forma agrupada e comparativa na Tabela 10, sendo que os resultados de cada uma das soluções são alocados nas colunas e cada linha representa uma variável. Além disso, um traço horizontal destacado separa as variáveis por grupos: parâmetros geométricos, forças de contato e rugosidades, ZMP, torques internos (os torques de contato são nulos), capacidade de força e requisição de torque.

Analisando primeiramente os parâmetros geométricos pode-se observar que as soluções de melhor compromisso e de maior capacidade de força apresentam

valores relativamente similares à Pierezan (2013), sendo que o posicionamento da segunda (Figura 38) é o mais próximo da solução da literatura. As alturas da coluna ( $z_5$ ) também são próximas, 2,1750 e 2,1734, respectivamente, comparadas a 2,1750, tendendo ao valor máximo (2,175). O ângulo de inclinação da coluna ( $\theta$ ) é relativamente similar para essas soluções, sendo que o mesmo tende a  $\pi/3$ , limite definido no processo de otimização.

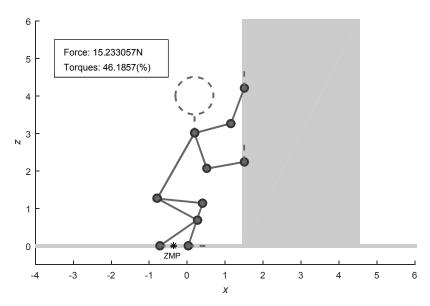


Figura 36 – Cinemática da solução de menor requisição de torque. Fonte: o Autor (2016).

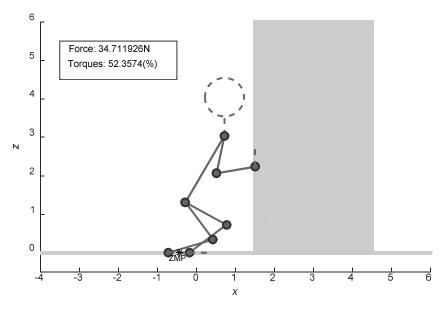


Figura 37 – Cinemática da solução de melhor compromisso da pesquisa. Fonte: o Autor (2016).

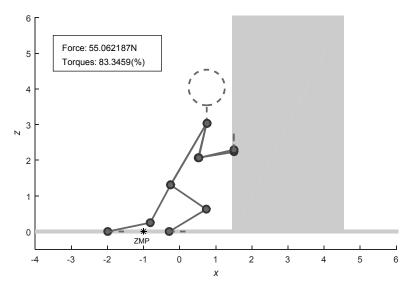


Figura 38 – Cinemática da solução de maior força estática da pesquisa. Fonte: o Autor (2016).

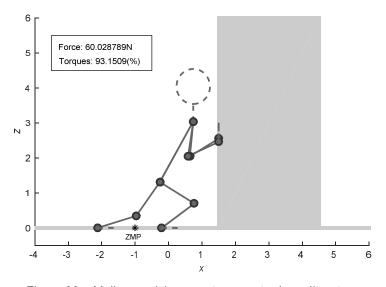


Figura 39 – Melhor posicionamento encontrado na literatura. Fonte: adaptado de Pierezan (2013)

A solução de menor requisição de torque, por outro lado, apresenta posicionamento da coluna mais afastada do contato ( $x_5 = -0.3$ ), contatos inferiores mais próximos entre si e também em relação ao objeto. Já os contatos superiores estão distantes, sendo que um está próximo ao limite superior e o outro ao limite inferior.

Outro fator que deve ser destacado é o posicionamento da solução de melhor compromisso, pois esta contém configurações dos membros inferiores similares à solução de menor requisição de torque e dos membros superiores similares às outras duas soluções. A coluna de tal solução também está com inclinação próxima à  $\pi/3$  e mais próximo ao contato em comparação à solução de menor requisição de torque. Em geral, todas as soluções apresentam inclinação igual ou próxima ao limite inferior.

Tabela 10 – Comparativo entre as variáveis das soluções promissoras.

Variável	Solução de menor	Solução de melhor	Solução de maior	Pierezan
variavei	requisição de torque	compromisso	capacidade de força	(2013)
$Z_A$	4,206920	2,231091	2,231093	2,553258
$Z_D$	2,239960	2,238214	2,295064	2,456982
$x_I$	0,025970	-0,184597	-0,286715	-0,207280
$z_L$	-0,720000	-0,720819	-1,987811	-2,122344
$x_5$	-0,300000	0,218946	0,250000	0,238680
$Z_5$	2,135000	2,174994	2,173426	2,174987
heta	1,058230	1,047205	1,047354	1,047198
$\mu_A$	0,4818	0,3649	0,0229	0,0901
$F_{x_A}$	8,1474	22,6380	23,5590	31,0138
$F_{z_A}$	-3,9252	-8,2612	-0,5390	2,7945
$\mu_D$	0,4841	0,2696	0,2092	0,0373
$F_{x_D}$	7,0856	12,0739	31,5032	29,0150
$F_{z_D}$	-3,4302	-3,2557	-6,5903	1,0826
$\mu_I$	0,0396	0,1578	0,4276	0,4269
$F_{z_I}$	57,8429	62,0022	69,2132	76,6844
$F_{x_I}$	2,2909	9,7850	29,5986	32,7332
$\mu_L$	0,2081	0,4626	0,4987	0,5000
$F_{z_L}$	62,2017	53,8809	51,0575	54,5926
$F_{x_L}$	12,9422	24,9269	25,4636	27,2956
ZMP	-0,3606	-0,4339	-1,0089	-1,0037
$ au_B$	7,3132	7,1370	-0,4575	9,0981
$ au_{\it C}$	-0,9548	-13,7051	-20,0000	-20,0000
$ au_E$	-0,1782	0,5103	8,9019	6,2538
$ au_F$	-10,5483	-8,9853	-20,0000	-19,9972
$ au_G$	-23,6470	-0,0692	-19,4822	-28,9012
$ au_H$	16,4341	44,9958	44,8520	44,9985
$ au_J$	-2,1516	0,0194	33,0019	39,9999
$ au_K$	45,0000	45,0000	45,0000	44,9984
Força (N)	15,2331	34,7119	55,0622	60,0288
Torque	46,19%	52,36%	83,35%	93,15%

Fonte: o Autor (2016).

Com relação às rugosidades requisitadas para realização da tarefa, pode-se notar que a solução de maior capacidade de força e a solução de Pierezan (2013) apresentam valores elevados nos contatos inferiores (no total, 92,63% e 92,69% do disponível, respectivamente), sendo que a solução de Pierezan está no limite do deslizamento em um dos contatos. Pelo contrário, a solução mais econômica apresenta valores elevados nos contatos superiores (96,59% no total) e pouco significantes nos contatos inferiores (24,77%). A solução de melhor compromisso requer valores intermediários em todos os pontos de contato (em média, 31,37% em cada contato).

Quanto à distribuição de forças, pode-se dizer que nos contatos superiores as forças  $F_x$  foram distribuídas com valores próximos para a solução de menor requisição de torque e para Pierezan (2013), com relação de proporção próxima a 50%-50%. Para as demais soluções as proporções aproximadas são 60%-40% e 35%-65% para a de melhor compromisso e de maior capacidade de força, respectivamente. Por outro lado, nos contatos inferiores a solução de menor requisição de torque apresenta proporção aproximada de 15%-85% comparado à 25%-75% da solução de melhor compromisso e 50%-50% das outras duas soluções.

Quanto às forças  $F_Z$  nos contatos inferiores, nota-se que todas as soluções apresentam distribuição próxima a 50%-50%. As soluções de menor requisição de torque e de melhor compromisso, por possuírem os contatos inferiores mais próximos ao objeto, possuem o ZMP também mais próximo do objeto. As demais soluções apresentam ZMP mais afastado do objeto; como os contatos estão também mais afastados, o ZMP acaba sendo posicionado em uma região intermediária do polígono de estabilidade.

Quanto aos torques em cada uma das juntas, a seguinte análise é apresentada. A solução de maior capacidade de força possui três juntas saturadas  $(\tau_C, \tau_F \in \tau_K)$  e outra com valores muito próximos  $(\tau_H)$ , enquanto a solução de melhor compromisso possui a junta  $\tau_K$  (joelho) saturada e a junta  $\tau_H$  (joelho) muito próxima da saturação, totalizando 52,36% de requisição total de torque. A solução de menor requisição de torque possui apenas a junta  $\tau_K$  saturada (requisitando 46,19% do total de torque disponível) e a solução de Pierezan (2013) apresenta valores próximos ou iguais à saturação para os ombros  $(\tau_C \in \tau_F)$ , joelhos  $(\tau_H \in \tau_K)$  e quadril  $(\tau_I)$ . Portanto, nota-se que as juntas dos joelhos  $(\tau_H \in \tau_K)$  apresentam maior

índice de saturação, sendo a junta do joelho mais afastado do objeto a primeira a saturar. Nas soluções de maior força estática, os ombros ( $\tau_C$  e  $\tau_F$ ) também apresentam valores próximos ou iguais à saturação.

Quanto às forças e requisições resultantes, a solução de Pierezan (2013) apresenta maior força (60,0288 N) e também maior requisição (93,15%), seguida pela solução de maior força do presente documento (55,0622 N e 83,35%), da solução de melhor compromisso (34,7119 N e 52,36%) e da solução de menor requisição (15,2331 N e 46,19%). Por meio de uma razão simples entre a força (cujo objetivo é o maior valor) e a requisição (quanto menor, melhor) nota-se que a solução de melhor compromisso apresenta valor mais favorável (0,6630), seguido pela solução de maior força do presente documento (0,6606), da solução de Pierezan (0,6444) e da solução de menor requisição de torque (0,3298). Isso indica que as soluções das extremidades ao priorizarem um dos objetivos acabam apresentando menor desempenho na relação "custo x benefício" no domínio dos objetivos de otimização.

# **6 CONSIDERAÇÕES FINAIS**

Visando a proposta de metaheuristicas de otimização multiobjetivo eficientes na otimização de problemas complexos de robótica humanoide, o presente documento contém uma avaliação de desempenho de metaheuristicas difundidas da literatura aplicadas à um problema complexo de força estática e requisição de torque de um robô humanoide. Uma discussão a respeito desse tema e dos resultados obtidos, as conclusões, as contribuições do presente documento, as publicações relacionadas e as perspectivas de pesquisa futura são apresentadas nas próximas subseções.

### 6.1 DISCUSSÃO

Primeiramente, é importante observar que apenas um conjunto de parâmetros foi testado para cada metaheurística por dois motivos: o tempo de simulação elevado para testar mais parâmetros e os poucos conjuntos avaliados na literatura. O tempo de execução das metaheurísticas não foi comparado devido ao uso variável do computador em que as simulações foram realizadas. Hora o mesmo estava sobrecarregado, hora estava apenas com a simulação em andamento. Portanto, os dados poderiam ser inválidos e prejudicar/beneficiar injustamente alguma das metaheurísticas.

Entretanto, baseado na complexidade dos algoritmos e nos dos tempos de execução, constata-se que a DEMO e a NSGA-II levam tempos muito próximos, pois ambas geram um novo conjunto de soluções a cada iteração e executam o ranqueamento apenas uma vez por iteração. A MOPSO, por sua vez, atualiza as velocidades e posições das partículas e executa a seleção baseada em hipercubos apenas uma vez por iteração. Porém, a estratégia de hipercubos exige mais processamento com relação ao ranqueamento e, portanto, a MOPSO leva aproximadamente três vezes mais tempo em relação à DEMO e NSGA-II. Já a MOHS executa o ranqueamento das soluções em todos os improvisos (ou seja, a cada avaliação da função objetivo). Assim, a MOHS leva em torno de dez vezes o tempo de simulação em relação à DEMO e NSGA-II.

O número máximo de avaliações da função objetivo, que foi escolhido como critério de parada das simulações, foi configurado como 500000. Na otimização

monoobjetivo, o valor recomendado para o problema em questão seria 120000 (10000 vezes a dimensão do problema). Entretanto, os primeiros testes mostraram que esse valor não era suficiente para as metaheurísticas encontrarem fronteiras de Pareto satisfatórias. Então, valores acima de 500000 foram testados e constataram que as metaheurísticas ainda convergem para as fronteiras de Pareto com soluções penalizadas, ou seja, para fronteiras locais indesejadas. Logo, as metaheurísticas comprovaram que são dependentes das condições iniciais (população/ enxame/ conjunto de harmonias iniciais).

Outro fator interessante é que a solução de Pierezan (2013) quando agregada à fronteira de Pareto filtrada da presente pesquisa aparece, claramente, como uma solução que poderia ser agregada às demais. Tal solução foi encontrada visando apenas a maior força estática e, portanto, é superior às soluções do presente documento nesse quesito. Logo, essa solução é importante para verificar a eficiência da presente metodologia em termos de expansão da fronteira de Pareto para as extremidades.

É importante salientar que o humanoide foi submetido a apenas uma tarefa, visando maior capacidade de força horizontal e menor requisição de torque. Então, as análises da presente pesquisa se aplicam apenas a essa situação, sendo possível que o panorama apresentado com relação ao desempenho das metaheurísticas seja alterado no caso de outra modelagem de otimização relacionada ao mesmo humanoide. Quanto à modelagem do problema da presente pesquisa, o peso atribuído às restrições (10000) foi escolhido arbitrariamente, pois a partir de experimentos iniciais, observou-se que os valores para a capacidade de força ficariam na casa de dezenas (o objetivo é o inverso); para o segundo objetivo, o valor máximo possível é 1 (100% do torque total disponível). Então, o peso atribuído é um valor suficientemente elevado em relação aos valores dos objetivos e é válido para a penalização das soluções infactíveis.

Com relação aos objetivos, o segundo está diretamente relacionado ao custo energético das soluções encontradas. O termo adotado foi "requisição de torque" por não ser possível estimar o gasto energético devido à não variação temporal. Entretanto, sabe-se que a requisição de torque em uma junta rotativa (fisicamente, um motor) implica em maior corrente elétrica e, automaticamente, aumenta a

potência, resultando em maior gasto energético no momento da execução real da tarefa.

# 6.2 CONCLUSÕES SOBRE O PROBLEMA DE OTIMIZAÇÃO

Um dos objetivos específicos da presente pesquisa é a modelagem do problema de otimização multiobjetivo do humanoide em termos de parâmetros, restrições e funções de custo. A modelagem foi realizada com sucesso e o modelo, inicialmente proposto por Pierezan, Freire e Weihmann (2012), inclui as ações gravitacionais e, portanto, o possível deslizamento nos contatos com o meio, o possível tombamento e as forças-peso geradas pelos elos. O equilíbrio estático foi resolvido através do método de Davies.

O problema da maneira como foi implementado apresentou um total de 36 restrições, tornando-se complexo e dificultando o processo de otimização por parte das metaheurísticas. Porém, os resultados provam que o mesmo é possível de ser resolvido e possui múltiplas soluções, algumas favorecendo a capacidade de força, outras a menor requisição de torque. Quanto à essas soluções, não é possível afirmar que são Pareto ótimo para o problema, pois as soluções ótimas são desconhecidas.

Quanto aos parâmetros encontrados para as soluções, pode-se dizer que, de modo geral, as juntas dos joelhos são as mais sobrecarregadas. É ainda possível correlacionar a melhor configuração geométrica para a realização da tarefa com o menor ângulo de inclinação do tronco. Todas as soluções promissoras encontraram valores iguais ou tendendo ao menor ângulo permitido. Dentre as soluções com maior capacidade de força, pode-se afirmar que o posicionamento resultante se assemelha (em geral) com o comportamento de um ser humano para a realização de uma tarefa de força horizontal.

### 6.3 CONCLUSÕES SOBRE AS METAHEURÍSTICAS

Conforme objetivos específicos, as metaheuristicas de otimização multiobjetivo e os critérios de desempenho das mesmas foram implementadas vide descrição da literatura. As soluções promissoras foram expostas e uma comparação de desempenho entre as metaheuristicas foi apresentada.

Embora tenham falhado em alguns dos experimentos, as metaheurísticas provaram ser capazes de otimizar o problema de otimização modelado. Quanto ao desempenho alcançado pelas mesmas, pode-se dizer que a mais apta é a DEMO, a qual ficou melhor colocada conforme as métricas de desempenho e contribuiu com pouco menos de 50% das soluções de uma fronteira de Pareto única formada pelas soluções obtidas a partir de todas as simulações. A NSGA-II encontrou soluções mais próximas da origem (menores custos) da região central da fronteira de Pareto, entretanto não foi capaz de explorar as extremidades que, de maneira geral, são importantes pois fornecem as soluções que priorizam exclusivamente algum dos objetivos. A MOPSO contribuiu com poucas soluções, sendo que uma se tornou destaque em requisição de torque. A MOHS, por sua vez, demonstrou resultados aquém das demais metaheurísticas.

Com base nas análises de desempenho relatadas, pode-se dizer que a DEMO e a NSGA-II mostraram-se mais aptas a tratar o problema modelado. Como a grande diferença entre essas duas metaheurísticas e as demais está no operador de recombinação (estas possuem, as demais não), pode-se concluir que tal operador é eficiente para tratar problemas com restrições. Quanto à diversidade e a região das soluções propostas, pode-se dizer que o mecanismo de hipercubos dinâmicos da MOPSO, embora seja um pouco custoso em termos de tempo de execução, apresentou bom desempenho e que pode ser testado em novos algoritmos de otimização multiobjetivo.

# 6.4 CONTRIBUIÇÕES DA DISSERTAÇÃO

Os resultados apresentados nesse documento permitem a avaliação de metaheuristicas já difundidas e a identificação dos fatores de maior influência nos respectivos desempenhos. Além disso, o presente documento ainda contribui com:

- a) A modelagem multiobjetivo do problema de otimização de um robô humanoide em contato com o meio considerando as forças de atrito (deslizamento), ZMP (tombamento) e as forças-peso dos elos;
- b) A extensão da metodologia proposta por Weihmann (2011) de otimização da capacidade de força estática de manipuladores, que já havia sido aplicada à um problema monoobjetivo de robô humanoide por Pierezan,

Freire e Weihmann (2012) e por Pierezan (2013) para a versão de modelagem e análise multiobjetivo; essa extensão pode ser aplicada à múltiplos problemas de robótica;

- c) A análise do desempenho das metaheurísticas DEMO, MOHS, MOPSO e NSGA-II aplicadas à um problema de robótica humanoide, segundo as métricas de desempenho NSND, DEM, H, E e fronteira de Pareto combinada e a detecção dos fatores de maior influência nos resultados;
- d) A correlação entre os parâmetros da cinemática e da estática do humanoide com os objetivos de capacidade de força e requisição de torque.

# 6.5 PUBLICAÇÕES RELACIONADAS

O conhecimento adquirido durante o período de desenvolvimento da presente pesquisa permitiu a elaboração de estudos que resultaram nas seguintes publicações:

a) Tipo de publicação: artigo em congresso;

**Nome do Congresso**: CBA 2014 – Congresso Brasileiro de Automática:

**Título do artigo**: Busca Harmônica Dinâmica Auto Ajustável Aplicada a Parametrização Multiobjetivo de Controladores<sup>1</sup>;

Data de publicação: setembro de 2014.

b) Tipo de publicação: artigo em congresso;

**Nome do Congresso**: CICA 2014 – IEEE Symposium on Computational Intelligence in Control and Automation;

**Título do artigo**: Improved Multiobjective Particle Swarm Optimization for Designing PID Controllers Applied to Robotic Manipulator;

Data de publicação: dezembro de 2014.

-

<sup>&</sup>lt;sup>1</sup> Participação como coautor.

c) Tipo de publicação: artigo em congresso;

**Nome do Congresso**: CBIC 2015 – Congresso Brasileiro de Inteligência Computacional;

**Título do artigo**: Otimização da Capacidade de Força Estática de Robôs Humanoides usando Metaheurísticas Bio-inspiradas<sup>2</sup>;

Data de publicação: outubro de 2015.

d) Tipo de publicação: artigo em congresso;

**Nome do Congresso**: SBAI 2015 – Simpósio Brasileiro de Automação Inteligente;

**Título do artigo**: Evolução Diferencial Multiobjetivo Modificada Aplicada ao Projeto Integrado de um Manipulador Robótico com Dois Graus de Liberdade;

Data de publicação: outubro de 2015.

e) Tipo de publicação: artigo em congresso;

**Nome do Congresso**: ESSAN 2016 – European Symposium on Artificial Neural Networks:

**Título do artigo**: On the Improvement of Static Force Capacity of Humanoid Robots based on Plants Behavior;

Data de publicação: abril de 2016;

**Situação**: aprovado para apresentação e para constar nos anais do congresso.

f) **Tipo de publicação**: artigo em periódico;

Nome do Periódico: Computers & Structures;

**Título do artigo**: Coyote Optimization Algorithm (COA): a new bioinspired metaheuristic for global optimization applied to the truss structures:

Data de submissão: dezembro de 2015;

**Situação**: aguardando parecer do editor.

Premiado como primeiro colocado no congresso pela contribuição na área de Inteligência Computacional. g) Tipo de publicação: artigo em periódico;

Nome do Periódico: Computers & Operations Research;

Título do artigo: Static force capacity optimization of humanoid robots

based on modified self-adaptive differential evolution;

Data de submissão: dezembro de 2015;

Situação: em processo de revisão.

#### 6.6 PERSPECTIVAS FUTURAS

Com base no conhecimento adquirido e nos resultados obtidos na presente pesquisa, os prováveis temas de pesquisa futura são:

- a) Evoluir no modelo de humanoide através da inclusão de novos fatores, tais como a rigidez nas juntas, otimização das características (comprimento dos elos, massa, etc.) e otimização de determinada tarefa ao longo de uma trajetória (modelagem quase-estática);
- Aplicar a metodologia da presente pesquisa a um robô humanoide considerando o espaço tridimensional;
- c) Construir um robô humanoide e validar fisicamente as análises apresentadas nessa pesquisa.

# REFERÊNCIAS BIBLIOGRÁFICAS

- ABHISHEK, K.; CHATTERJEE, S.; DATTA, S.; *et al.* Application of NSGA II for Optimization of Multi-Performance Characteristics During Machining of GFRP (epoxy) Composites. **Materials Today: Proceedings**, v. 2, n. 4-5, p. 2353–2358, 2015.
- ABRAHAM, A.; JAIN, L.; GOLDBERG, R. Evolutionary multiobjective optimization. **Evolutionary Multi-Objective Optimization: Theoretical Advances and Applications**, 2005.
- AFFI, Z.; EL-KRIBI, B.; ROMDHANE, L. Advanced mechatronic design using a multiobjective genetic algorithm optimization of a motor-driven four-bar system. **Mechatronics**, v. 17, n. 9, p. 489–500, 2007.
- AYALA, H. V. H.; COELHO, L. S. Tuning of PID controller based on a multiobjective genetic algorithm applied to a robotic manipulator. **Expert Systems with Applications**, v. 39, n. 10, p. 8968–8974, 2012.
- AYALA, H. V. H.; PIEREZAN, J.; COELHO, L. S. Busca Harmônica Dinâmica Auto-Ajustável Aplicada à Parametrização Multiobjetivo de Controladores. **20º Congresso Brasileiro de Automática (CBA)**, Belo Horizonte, Minas Gerais, Brasil, p.1522–1529, 2014.
- BÄCK, T.; FOGEL, D. B.; MICHALEWICZ, Z. Handbook of Evolutionary Computation. **Evolutionary Computation**, v. 2, p. 1–11, 1997.
- BAUER, J.; KOPACEK, P.; DÀPOLITO, F.; *et al.* Cost Oriented (humanoid) robots. **IFAC-Papers Online**, v. 48, n. 24, p. 173–177, 2015.
- BELFIORE, N. P.; DI BENEDETTO, A. Connectivity and Redundancy in Spatial Robots. **The International Journal of Robotics Research**, v. 19, n. 12, p. 1245–1261, 2000.
- BIRATTARI, M.; PAQUETE, L.; STÜTZLE, T.; *et al.* Classification of Metaheuristics and Design of Experiments for the Analysis of Components, **Tech. Rep. AINDA-01-05**. Darmstadt, Germany, 2001.
- BOUSSAÏD, I.; LEPAGNOT, J.; SIARRY, P. A survey on optimization metaheuristics. **Information Sciences**, v. 237, p. 82–117, 2013.
- BRUEMMER, D. J.; SWINSON, M. S. Humanoid Robots. In: Encyclopedia of Physical Science and Technology, Elsevier, p.401–425, 2003.
- CARBONE, G.; LIM, H.; TAKANISHI, A.; *et al.* Stiffness analysis of biped humanoid robot WABIAN-RIV. **Mechanism and Machine Theory**, v. 41, n. 1, p. 17–40, 2006.

- CARLUCCI, S.; CATTARIN, G.; CAUSONE, F.; *et al.* Multi-objective optimization of a nearly zero-energy building based on thermal and visual discomfort minimization using a non-dominated sorting genetic algorithm (NSGA-II). **Energy and Buildings**, v. 104, p. 378–394, 2015.
- CHENG, J.; ZHANG, G. Multi-objective Differential Evolution: A Recent Survey. **Soft Computing with Applications (SCA)**, v. 1, n. 1, p. 1–9, 2013.
- COELLO COELLO, C. A.; PULIDO, G. T.; LECHUGA, M. S. Handling multiple objectives with particle swarm optimization. **IEEE Transactions on Evolutionary Computation**, v. 8, n. 3, p. 256–279, 2004.
- COELLO COELLO, C. A.; LECHUGA, M. S. MOPSO: A proposal for multiple objective particle swarm optimization. **Proceedings of the 2002 Congress on Evolutionary Computation, CEC 2002**, v. 2, p. 1051–1056, 2002.
- COLLETTE, Y.; SIARRY, P. Multiobjective optimization: principles and case studies. Springer Berlin Heidelberg, 2003.
- DA COSTA, B. R.; VIEIRA, E. R. Risk factors for work-related musculoskeletal disorders: A systematic review of recent longitudinal studies. **American Journal of Industrial Medicine**, v. 53, n. 3, p. 285–323, 2010.
- DAS, S.; MAITY, S.; QU, B.-Y.; *et al.* Real-parameter evolutionary multimodal optimization A survey of the state-of-the-art. **Swarm and Evolutionary Computation**, v. 1, n. 2, p. 71–88, 2011.
- DAS, S.; SUGANTHAN, P. N. Differential evolution: A survey of the state-of-the-art. **IEEE Transactions on Evolutionary Computation**, v. 15, n. 1, p. 4–31, 2011.
- DAVIES, T. H. Mechanical networks III Wrenches on circuit screws. **Mechanism and Machine Theory**, v. 18, n. 2, p. 107–112, 1983.
- DEB, K. **Multi-Objective Optimization Using Evolutionary Algorithms,** London: John Wiley & Sons, Inc., 2001.
- DEB, K.; AGRAWAL, R. B. Simulated Binary Crossover for Continuous Search Space. **Complex Systems**, v. 9, p. 1–34, 1994.
- DEB, K.; KUMAR, A. Real-coded Genetic Algorithms with Simulated Binary Crossover: Studies on Multimodal and Multiobjective Problems. **Complex Systems**, v. 9, p. 431–454, 1995.
- DEB, K.; PRATAP, A.; AGARWAL, S.; *et al.* A fast and elitist multiobjective genetic algorithm: NSGA-II. **IEEE Transactions on Evolutionary Computation**, v. 6, n. 2, p. 182–197, 2002.
- DERRAC, J.; GARCÍA, S.; MOLINA, D.; et al. A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and

- swarm intelligence algorithms. **Swarm and Evolutionary Computation**, v. 1, n. 1, p. 3–18, 2011.
- DIRICAN, C. The Impacts of Robotics, Artificial Intelligence On Business and Economics. **Procedia Social and Behavioral Sciences**, Elsevier B.V., v. 195, p. 564–573, 2015.
- EL-KRIBI, B.; HOUIDI, A.; AFFI, Z.; *et al.* Application of multi-objective genetic algorithms to the mechatronic design of a four bar system with continuous and discrete variables. **Mechanism and Machine Theory**, v. 61, p. 68–83, 2013.
- ENGELBRECHT, A. P. **Fundamentals of Computational Swarm Intelligence**. 1st ed. London: John Wiley & Sons, Inc., 2005.
- FONG, S.; DEB, S.; CHAUDHARY, A. A review of metaheuristics in robotics. **Computers and Electrical Engineering**, v. 43, p. 278–291, 2015.
- GARCÍA, S.; FERNÁNDEZ, A.; LUENGO, J.; *et al.* Advanced nonparametric tests for multiple comparisons in the design of experiments in computational intelligence and data mining: Experimental analysis of power. **Information Sciences**, v. 180, n. 10, p. 2044–2064, 2010.
- GARG, V.; NOKLEBY, S. B.; CARRETERO, J. A. Wrench capability analysis of redundantly actuated spatial parallel manipulators. **Mechanism and Machine Theory**, v. 44, n. 5, p. 1070–1081, 2009.
- GEEM, Z. W.; KIM, J. H.; LOGANATHAN, G. V. A New Heuristic Optimization Algorithm: Harmony Search. **SIMULATION**, v.76, n. 2, p. 60-68, 2001.
- GOERTZEL, B.; HANSON, D.; YU, G. A Software Architecture for Generally Intelligent Humanoid Robotics. **Procedia Computer Science**, v. 41, p. 158–163, 2014.
- GOUAILLIER, D.; BLAZEVIC, P. A Mechatronic Platform, The Aldebaran Robotics Humanoid Robot. **IEEE Industrial Electronics, IECON 2006 32nd Annual Conference on**, Paris, France, p. 4049-4053, 2006.
- HANDL, J.; KELL, D. B.; KNOWLES, J. Multiobjective optimization in bioinformatics and computational biology. **IEEE/ACM transactions on computational biology and bioinformatics / IEEE, ACM**, v. 4, n. 2, p. 279–92, 2007.
- HAO, S.; LI, D.; HALFOND, W. G. J.; *et al.* Estimating mobile application energy consumption using program analysis. **35th International Conference on Software Engineering (ICSE)**, San Francisco, CA, USA, p. 92–101, 2013.
- HIBBELER, R. C. **Estática: Mecânica para Engenharia**. 12° ed. Prentice Hall Brasil, 2011.

- INAMURA, T.; OKADA, K.; TOKUTSU, S.; *et al.* HRP-2W: A humanoid platform for research on support behavior in daily life environments. **Robotics and Autonomous Systems**, v. 57, n. 2, p. 145–154, 2009.
- ISMAIL, L. I.; SHAMSUDIN, S.; YUSSOF, H.; *et al.* Robot-based Intervention Program for Autistic Children with Humanoid Robot NAO: Initial Response in Stereotyped Behavior. **Procedia Engineering**, v. 41, p. 1441–1447, 2012.
- JEONG, K.-S.; KIM, M.; JO, H.; *et al.* Search of optimal locations for species- or group-specific primer design in DNA sequences: Non-dominated Sorting Genetic Algorithm II (NSGA-II). **Ecological Informatics**, v. 29, p. 214–220, 2015.
- JIANG, S.; ONG, Y.-S.; ZHANG, J.; *et at.* Consistencies and Contradictions of Performance Metrics in Multiobjective Optimization. **IEEE Transactions on Cybernetics**, v. 44, n. 12, p. 2391–2404, 2014.
- LEI, J.; SONG, M.; LI, Z.-N.; *et al.* Whole-body humanoid robot imitation with pose similarity evaluation. **Signal Processing**, v. 108, p. 136–146, 2015.
- KAJITA, S.; ESPIAU, B. Legged Robots. In: B. Siciliano; O. Khatib (Orgs.); **Springer Handbook of Robotics**, Springer Berlin Heidelberg, p. 361–389, 2008.
- KATO, I.; OHTERU, S.; SHIRAI, K.; *et al.* The robot musician "wabot-2" (waseda robot-2). **Robotics**, v. 3, p. 143–155, 1987.
- KEMP, C. C.; FITZPATRICK, P.; HIRUKAWA, H.; *et al.* Humanoids. In: B. Siciliano; O. Khatib (Orgs.); **Springer Handbook of Robotics,** Springer Berlin Heidelberg, p.1307–1333, 2008.
- KENNEDY, J.; EBERHART, R. Particle swarm optimization., **Proceedings, IEEE International Conference on Neural Networks**, v. 4, p. 1942–1948 vol.4, 1995.
- KLÖPPER, B.; AUFENANGER, M.; ADELT, P. Planning for mechatronics systems—Architecture, methods and case study. **Engineering Applications of Artificial Intelligence**, v. 25, n. 1, p. 174–188, 2012.
- KNASEL, T. M. Mobile robotics state of the art review. **Robotics**, v. 2, n. 2, p. 149–155, 1986.
- LADKANY, G. S. A Genetic Algorithm with Weighted Average Normally-Distributed Arithmetic Crossover and Twinkling. **Applied Mathematics**, v. 03, n. 30, p. 1220–1235, 2012.
- LIU, S.; SUN, D. Optimal motion planning of a mobile robot with minimum energy consumption. **2011 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM)**, Budapest, Hungary, p.43–48, 2011.

- LIU, S.; SUN, D. Minimizing Energy Consumption of Wheeled Mobile Robots via Optimal Motion Planning. **IEEE/ASME Transactions on Mechatronics**, v. 19, n. 2, p. 401-411, 2014.
- LOHMEIER, S.; LOFFLER, K.; GIENGER, M.; *et al.* Computer System and Control of Biped "Johnnie". **Proceedings of the 2004 IEEE International Conference on Robotics and Automation**. p.4222–4227, 2004.
- MAHDAVI, S.; SHIRI, M. E.; RAHNAMAYAN, S. Metaheuristics in large-scale global continues optimization: A survey. **Information Sciences**, v. 295, p. 407–428, 2015.
- MANJARRES, D.; LANDA-TORRES, I.; GIL-LOPEZ, S.; *et al.* A survey on applications of the harmony search algorithm. **Engineering Applications of Artificial Intelligence**, v. 26, n. 8, p. 1818–1831, 2013.
- MARTINS, D.; CARBONI, A. P. Variety and connectivity in kinematic chains. **Mechanism and Machine Theory**, v. 43, n. 10, p. 1236–1252, 2008.
- MEJIA, L.; SIMAS, H.; MARTINS, D. Advances on Theory and Practice of Robots and Manipulators: **Proceedings of Romansy 2014 XX CISM-IFToMM Symposium on Theory and Practice of Robots and Manipulators**. p.537–545, 2014.
- MEZURA-MONTES, E.; REYES-SIERRA, M.; COELLO COELLO, C. A. Multi-objective optimization using differential evolution: a survey of the state-of-the-art. In: C. Uday (Org.); **Advances in Differential Evolution**, Springer Berlin Heidelberg, p. 173–196, 2008.
- MICHEL, J.-P. The future of geriatric medicine. **European Geriatric Medicine**, v. 3, n. 4, p. 233–237, 2012.
- MONTGOMERY, D. C.; RUNGER, G. C. Applied Statistics and Probability for Engineers. John Wiley & Sons, Inc., 2011.
- MORAN, M. E. The da Vinci Robot. **Journal of Endourology**, v. 20, n. 12, p. 986–990, 2006.
- NEGRI, J. R.; CERVENY, G. C. D. O.; MONTEBELO, M. I. D. L.; *et al.* Perfil sociodemográfico e ocupacional de trabalhadores com LER/DORT: estudo epidemiológico. **Revista Baiana de Saúde Pública**, v. 38, n. 3, p. 555–570, 2014.
- NOKLEBY, S. B.; FISHER, R.; PODHORODESKI, R. P.; FIRMANI, F. Force capabilities of redundantly-actuated parallel manipulators. **Mechanism and Machine Theory**, v. 40, n. 5, p. 578–599, 2005.
- OAKMAN, J.; CHAN, S. Risk management: Where should we target strategies to reduce work-related musculoskeletal disorders? **Safety Science**, v. 73, p. 99–105, 2015.

- OKITA, S. Y.; NG-THOW-HING, V.; SARVADEVABHATLA, R. Learning together: ASIMO developing an interactive learning partnership with children. **Proceedings IEEE International Workshop on Robot and Human Interactive Communication**. p.1125–1130, 2009.
- ORMELEZ, C.; L. ULBRICHT. Análise ergonômica do trabalho aplicada a um posto de trabalho com sobrecarga física. **Revista Uniandrade**, v. 11, p. 69–84, 2010.
- PELLEGRINELLI, S.; BORGIA, S.; PEDROCCHI, N.; *et al.* Minimization of the Energy Consumption in Motion Planning for Single-robot Tasks. **Procedia CIRP**, v. 29, p. 354–359, 2015.
- PÉREZ ABRIL, I. NSGA-II phase balancing of primary distribution circuits by the reconnection of their circuit laterals and distribution transformers. **Electric Power Systems Research**, v. 109, p. 1–7, 2014.
- PFEIFFER, S.; ANGULO, C. Gesture learning and execution in a humanoid robot via dynamic movement primitives. **Pattern Recognition Letters**, v. 67, p. 100–107, 2015.
- PIEREZAN, J.; FREIRE, R. Z.; WEIHMANN, L. Static Force Capacity Modeling and Optimization of Humanoid Robots. **The 5th International Conference on Optimization and Control with Application**. Beijing, China, p.41–50, 2012.
- PIEREZAN, J. Aplicação de Meta-heurísticas na Otimização da Capacidade de Força Estática de Robôs Humanoides, 2013, 121 p. Trabalho de Conclusção de Cusro (Graduação, Engenharia de Controle e Automação), Pontifícia Universidade Católica do Paraná (PUCPR), Curitiba, Brasil.
- PONSICH, A.; JAIMES, A. L.; COELLO COELLO, C. A. A Survey on Multiobjective Evolutionary Algorithms for the Solution of the Portfolio Optimization Problem and Other Finance and Economics Applications. **IEEE Transactions on Evolutionary Computation**, v. 17, n. 3, p. 321–344, 2013.
- RABBITT, S. M.; KAZDIN, A. E.; SCASSELLATI, B. Integrating socially assistive robotics into mental healthcare interventions: Applications and recommendations for expanded use. **Clinical psychology review**, v. 35C, p. 35–46, 2015.
- RICART, J.; HÜTTEMANN, G.; LIMA, J.; *et al.* Multiobjective Harmony Search Algorithm Proposals. **Electronic Notes in Theoretical Computer Science**, v. 281, p. 51–67, 2011.
- ROBIČ, T.; FILIPIČ, B. DEMO: Differential Evolution for Multiobjective. **Evolutionary Multi-Criterion Optimization**, v. 3410, p. 520–533, 2005.
- ROCHA, C. R.; TONETTO, C. P.; DIAS, A. A comparison between the Denavit–Hartenberg and the screw-based methods used in kinematic modeling of robot manipulators. **Robotics and Computer-Integrated Manufacturing**, v. 27, n. 4, p. 723–728, 2011.

- ROY, S. S.; PRATIHAR, D. K. Dynamic modeling, stability and energy consumption analysis of a realistic six-legged walking robot. **Robotics and Computer-Integrated Manufacturing**, v. 29, n. 2, p. 400–416, 2013.
- SAKAGAMI, Y.; WATANABE, R.; AOYAMA, C.; *et al.* The intelligent ASIMO: system overview and integration. **IEEE/RSJ International Conference on Intelligent Robots and System**, v. 3, p. 2478–2483, 2002.
- SHAMSUDDIN, S.; ISMAIL, L. I.; YUSSOF, H.; *et al.* Humanoid robot NAO: Review of control and motion exploration. **Proceedings 2011 IEEE International Conference on Control System, Computing and Engineering**, ICCSCE 2011, p.511–516, 2011.
- SOKAS, R. K.; SPRINCE, N. L. Occupational health: overview. **International Encyclopedia of Public Health**. p.639–649, 2008.
- STANTON, C.; WILLIAMS, M.-A. Robotics: State of the Art and Future Challenges. Imperial College Press (2008). **Artificial Intelligence**, v. 172, n. 18, p. 1967–1972, 2008.
- STORN, R.; PRICE, K. Differential Evolution A simple and efficient adaptive scheme for global optimization over continuous spaces. **Technical report, International Computer Science Institute**, TR-95-012, p. 1–15, 1995.
- STORN, R.; PRICE, K. Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces. **Journal of global optimization**, v. 11, p. 341–359, 1997.
- TSAI, L. Robot analysis: the mechanics of serial and parallel manipulators, John Wiley & Sons, Inc., 1999.
- WANG, J.; LI, Y. A survey on the structures of current mobile humanoid robots. **IEEE Asia-Pacific Conference on Circuits and Systems, Proceedings, APCCAS**, p. 1826–1829, 2008.
- WECK, O. DE. Multiobjective optimization: History and promise. **The Third China-Japan-Korea Joint Symposium on Optimization of Structural and Mechanical Systems**, Kanazawa, Japan, p.403–408, 2004.
- WEIHMANN, L. Modelagem e otimização de forças e torques aplicados por robôs com redundância cinemática e de atuação em contato com o meio, 2011, 332 p. Tese de Doutorado (Engenharia Mecânica), Universidade Federal de Santa Catarina (UFSC), Florianópolis, Brasil.
- WEIHMANN, L.; MARTINS, D.; COELHO, L S. Modified differential evolution approach for optimization of planar parallel manipulators force capabilities. **Expert Systems with Applications**, v. 39, n. 6, p. 6150–6156, 2012.

- VUKOBRATOVIĆ, M.; GLUHAJIĆ, N.; STOKIĆ, D.; *et al.* One method of control for large scale humanoid systems. **Mathematical Biosciences**, v. 36, n. 3-4, p. 175–198, 1977.
- XUE, F.; SANDERSON, A. C.; GRAVES, R. J. Pareto-based Multi-Objective Differential Evolution. **Evolutionary Computation**, p. 862–869, 2003.
- YANG, X. S.; KOZIEL, S.; LEIFSSON, L. Computational optimization, modelling and simulation: Past, present and future. **Procedia Computer Science**, v. 29, n. Coms, p. 754–758, 2014.
- YOO, J.-K.; LEE, B.-J.; KIM, J.-H. Recent progress and development of the humanoid robot HanSaRam. **Robotics and Autonomous Systems**, v. 57, n. 10, p. 973–981, 2009.
- YUSSOF, H. Biped Locomotion of a 21-DOF Humanoid Robot for Application in Real Environment. **Procedia Engineering**, v. 41, p. 1566–1572, 2012.
- ZHOU, A.; QU, B.-Y.; LI, H.; *et al.* Multiobjective evolutionary algorithms: A survey of the state of the art. **Swarm and Evolutionary Computation**, v. 1, n. 1, p. 32–49, 2011.
- ZITZLER, E.; THIELE, L.; LAUMANNS, M.; *et al.* Performance assessment of multiobjective optimizers: an analysis and review. **IEEE Transactions on Evolutionary Computation,** v. 7, n. 2, p. 117–132, 2003.